



**UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO
CENTRO TECNOLÓGICO
COLEGIADO DE ENGENHARIA MECÂNICA**

Arthur Cancellieri Pires, Guilherme Reis Mendes

**Identificação indireta das forças do rodeiro de
um vagão ferroviário utilizando modelos de
Machine Learning**

Vitória, ES

2020

Arthur Cancellieri Pires, Guilherme Reis Mendes

Identificação indireta das forças do rodeiro de um vagão ferroviário utilizando modelos de Machine Learning

Trabalho de Conclusão de Curso apresentado
ao Departamento de Engenharia Mecânica do
Centro Tecnológico da Universidade Federal
do Espírito Santo, como requisito parcial para
obtenção do grau de Engenheiro Mecânico.

Universidade Federal do Espírito Santo – UFES

Centro Tecnológico

Departamento de Engenharia Mecânica

Orientador: Prof. Dr. Guilherme Fabiano Mendonça dos Santos

Vitória, ES

2020

Arthur Cancellieri Pires, Guilherme Reis Mendes

Identificação indireta das forças do rodeiro de um vagão ferroviário utilizando
modelos de Machine Learning/ Arthur Cancellieri Pires, Guilherme Reis Mendes. –
Vitória, ES, 2020-

90 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Guilherme Fabiano Mendonça dos Santos

Trabalho de Conclusão de Curso – Universidade Federal do Espírito Santo – UFES
Centro Tecnológico
Departamento de Engenharia Mecânica, 2020.

1. Simulação dinâmica. 2. Machine Learning 3. Análise de dados. 4. Medição
da dinâmica do vagão 5. Critério de Nadal II. Universidade Federal do Espírito
Santo. IV. Identificação indireta das forças do rodeiro de um vagão ferroviário
utilizando modelos de Machine Learning

Arthur Cancellieri Pires, Guilherme Reis Mendes

Identificação indireta das forças do rodeiro de um vagão ferroviário utilizando modelos de Machine Learning

Trabalho de Conclusão de Curso apresentado ao Departamento de Engenharia Mecânica do Centro Tecnológico da Universidade Federal do Espírito Santo, como requisito parcial para obtenção do grau de Engenheiro Mecânico.

Trabalho aprovado. Vitória, ES, 5 de agosto de 2020:

**Prof. Dr. Guilherme Fabiano
Mendonça dos Santos**
Orientador

Prof. Lucas Silveira Campos
Convidado 1

Eng. Bruno Brito
Convidado 2

Vitória, ES
2020

Resumo

A segurança e a estabilidade do vagão ferroviário são fatores importantes para o seu bom desempenho. Para isso, existem dois indicadores responsáveis por quantificar a qualidade da ferrovia. Os mais utilizados são os TQIs (*Track Quality Index*), e o critério de Nadal. Os TQIs são responsáveis por quantificar a qualidade geométrica da via enquanto o Nadal estabelece a razão entre a força lateral e vertical (L/Q) critico do contato roda trilho. Compara-se esses indicadores com as normas e se o valor extrapolar tal limite, a manutenção deve ser realizada. Ao adotar ambos os indicadores conjuntamente, é possível ter mais certeza na hora de planejar a manutenção, no entanto, existem limitações para sua aplicação em tempo real. Existem métodos de medir irregularidades através de sensores relativamente baratos como acelerômetros, mas esse não é o caso para as forças presentes no rodeiro. A instrumentação típica consiste de um rodeiro instrumentado com extensômetros que, a partir da sua deformação, obtém-se as forças laterais e verticais do rodeiro. Esse método possui dificuldades de instalação e a constante necessidade de recalibração dos extensômetros do rodeiro devido ao desgaste da roda tornaram essa opção muito cara.

Diante desse contexto, esse trabalho possui como objetivo implementar modelos de *Machine Learning* (ML) capazes de fornecer o valor de da razão entre a força lateral e vertical do rodeiro (L/Q) a partir de informações que sensores mais baratos e fáceis de manusear forneceriam, como os sensores inerciais. O vagão instrumentado da ferrovia BRA1 foi utilizado como referência e criado virtualmente no software *Universal Mechanism*. Três conjuntos de variáveis são geradas através da simulação dinâmica deste veículo. O primeiro conjunto de variáveis são aquelas que são capazes de serem medidas pelo veículo BRA1 real. O segundo conjunto são variáveis que são utilizadas em outros vagões instrumentados (IRV), mas não no BRA1 por falta de instrumentação. Apesar disso, essas medidas podem ser geradas virtualmente. O terceiro conjunto é o L/Q para cada roda do truque dianteiro. A partir deste conjunto de dados, o modelo de ML é treinado para fornecer o L/Q a partir dos dados medidos (real e virtual). Após a validação com dados de teste, diferentes modelos de ML e taxas de amostragem são comparados entre si.

Palavras-chaves: Simulação dinâmica, Análise de Dados, Machine Learning, Nadal.

Abstract

Rail car safety and stability are important factors for its good performance. There are two common indicators that are used to quantify the quality of the railway. The most used are the TQI (Track Quality Index), and the Nadal criteria. The TQI are responsible for quantifying the geometric quality of the road while Nadal establishes the critical ratio between lateral and vertical wheel rail contact forces (L/Q). These indicators are compared to the railway standards and if the value exceeds a certain limit, maintenance must be performed. By using both indicators simultaneously to diagnose the railway track, maintenance planning is more precise and reliable, although there are some limitations to their real-time application. There are methods of measuring irregularities using inexpensive sensors such as accelerometers but this is not the case with the wheelset forces. The typical instrumentation for measuring wheel rail contact forces is a wheelset with strain gauges that obtains the lateral and vertical force values from its deformation. The difficulty of installation and the constant need for recalibration of these strain gauges due to wheel wear have made this option very expensive.

Given the context, this work aims to implement a Machine Learning (ML) model capable of providing the ratio between the lateral and vertical wheelset forces (L/Q) from information given by cheaper and easier to handle sensors such as inertial sensors. A virtual model of the BRA1 instrumented railway vehicle (IRV) was created in the software *Universal Mechanism*. Three sets of variables are generated through the dynamic simulation of this vehicle. The first set of variables are those that are capable of being measured by the real BRA1 vehicle. The second set are variables that are used in other IRVs but not in the BRA1 due to lack of instrumentation, however, these measurement can be generated virtually through the dynamic model. The third set is the ratio L/Q for each wheel of the leading bogie. From this dataset, the ML model is trained to give L/Q as the output from measured data. After validation with a test dataset, different ML models and sampling rates are compared to one another.

Palavras-chaves: Dynamic simulation, Data analysis, Machine Learning, Nadal

Listas de ilustrações

Figura 1 – Exemplo de um carro controle EM100 - (SANTOS, 2015)	16
Figura 2 – Sistema de medição inercial de um carro controle - (KARIS, 2018).	17
Figura 3 – Vagão instrumentado, com imagem ampliada do sensor instalado (célula de carga) - (SANTOS; REICHL et al., 2014)	18
Figura 4 – Processo de descarrilhamento por escalada no flange - (DERAILMENT,)	27
Figura 5 – Representação gráfica da equação de Nadal - (SANTOS, 2015)	28
Figura 6 – Resumo dos resultados de detecção de defeitos usando o critério FRA e o critério PBTG - (LI et al., 2006)	30
Figura 7 – Resposta dinâmica ruim do veículo numa tangente devido ao cross-level, desalinhamento e deviações superficiais (<i>velocidade = 69km/h</i>) - (LI et al., 2006)	31
Figura 8 – L/Q para as rodas 1l (esquerda) e 1r (direita) do rodeiro frontal, considerando o efeito das irregularidades - (VAZ et al., 2018)	32
Figura 9 – Irregularidades a) lateral b) bitola c) vertical d) superelevação - (Zhai, 2015) modificado pelo autor	34
Figura 10 – Influência do comprimento de onda na geração das irregularidades - (BERAWI, 2013)	35
Figura 11 – Fluxograma do processo	36
Figura 12 – Componentes do vagão GDE	37
Figura 13 – Principais constituintes do truque	38
Figura 14 – Seis graus de liberdade de um vagão ferroviário	39
Figura 15 – Posição dos sensores da caixa de eixo	41
Figura 16 – Exemplo de instalação de sensores na caixa de rolamento do rodeiro - (GÓMEZ et al., 2020)	41
Figura 17 – Posição dos sensores da travessa lateral	42
Figura 18 – Exemplo de posicionamento dos acelerômetros na travessa lateral - (LEE et al., 2011b)	42
Figura 19 – Posição do acelerômetro triaxial da caixa do vagão	43
Figura 20 – Descrição dos parâmetros que compõem a curva - (LOCOMOTIVES, 2019)	44
Figura 21 – Curvatura da macrogeometria da via	44
Figura 22 – Etapas para execução de um modelo de aprendizagem de máquina	49
Figura 23 – Variáveis medidos pelos sensores reais	52
Figura 24 – Variáveis medidos pelos sensores virtuais	52
Figura 25 – Valores do L/Q	53
Figura 26 – Histograma dos sensores reais e virtuais	54

Figura 27 – Boxplot dos sensores reais e virtuais	55
Figura 28 – <i>Heatmap</i> da interdependência entre os sensores reais e virtuais	56
Figura 29 – Correlação do L/Q do rodeiro 1 para sensores reais	57
Figura 30 – Correlação do L/Q do rodeiro 2 para sensores reais	58
Figura 31 – Valor médio de SHAP para os sensores reais	60
Figura 32 – Valor médio de SHAP para os sensores virtuais	60
Figura 33 – Valor local de SHAP em uma tangente	61
Figura 34 – Valor local de SHAP em uma curva	61
Figura 35 – Implementação do modelo de empilhamento	64
Figura 36 – Resíduos do L/Q do rodeiro 1 esquerdo - 100Hz com irregularidades . .	66
Figura 37 – Comparação do L/Q do rodeiro 1 esquerdo predito com o real	66
Figura 38 – Resíduos do L/Q do rodeiro 1 direito - 100Hz com irregularidades . .	67
Figura 39 – Comparação do L/Q rodeiro 1 direito predito com o real	67
Figura 40 – Resíduos do L/Q do rodeiro 2 esquerdo - 100Hz com irregularidades .	68
Figura 41 – Comparação do L/Q do rodeiro 2 esquerdo predito com o real	68
Figura 42 – Resíduos do L/Q do rodeiro 2 direito - 100Hz com irregularidades . .	69
Figura 43 – Comparação do L/Q do rodeiro 2 direito predito com o real	69
Figura 44 – Correlações Lineares	78
Figura 45 – Correlações PPS	79
Figura 46 – Lineplots Reais	80
Figura 47 – Lineplots Virtuais	81
Figura 48 – Boxplot	82
Figura 49 – Histograma	83
Figura 50 – SHAP Real Rodeiro 1 Esquerdo	84
Figura 51 – SHAP Real Rodeiro 1 Direito	84
Figura 52 – SHAP Real Rodeiro 2 Esquerdo	85
Figura 53 – SHAP Real Rodeiro 2 Direito	85
Figura 54 – SHAP Virtual Rodeiro 1 Esquerdo	86
Figura 55 – SHAP Virtual Rodeiro 1 Direito	86
Figura 56 – SHAP Virtual Rodeiro 2 Esquerdo	87
Figura 57 – SHAP Virtual Rodeiro 2 Direito	87
Figura 58 – Correlação Nadal Rodeiro 1 Virtual	89
Figura 59 – Correlação Nadal Rodeiro 2 Virtual	89

Lista de tabelas

Tabela 1 – Tipos de sensores mais usados na medição de parâmetros ferroviários - (HODGE et al., 2014) adaptado pelo autor	19
Tabela 2 – Quadro resumo dos artigos usados na revisão bibliográfica	21
Tabela 3 – Sensores apropriados para o tipo específico de monitoramento - (WARD et al., 2011) adaptado pelo autor	23
Tabela 4 – Critérios para avaliação dos requisitos de vagões em serviço	29
Tabela 5 – Tipos de irregularidades da via e do trilho - (MELO, 2016)	32
Tabela 6 – Classificação das irregularidades pela norma EN 13848-5 - (EN, 2003; PODWÓRNA, 2015; ZHAI, 2015) adaptado pelo autor	35
Tabela 7 – Macrogeometria da via	45
Tabela 8 – Parâmetros da função PSD para diferentes classes de via - (BERAWI, 2013) modificado	47
Tabela 9 – Descrição dos sensores e parâmetros estatísticos calculados após a simulação dinâmica	51
Tabela 10 – Seleção KBest com sensores reais	62
Tabela 11 – Ranking das variáveis selecionadas com SelectKBest	62
Tabela 12 – Algoritmos e transformações utilizados pelo TPOT	63
Tabela 13 – Modelos - L/Q Rodeiro 1 Esquerdo	65
Tabela 14 – Modelos - L/Q Rodeiro 1 Direito	66
Tabela 15 – Modelos - L/Q Rodeiro 2 Esquerdo	67
Tabela 16 – Modelos - L/Q Rodeiro 2 Direito	68
Tabela 17 – Resultados dos Modelos utilizando R-quadrado como Métrica	69
Tabela 18 – Resultados dos Modelos utilizando Erro absoluto médio como Métrica	70
Tabela 19 – Modelos - Nadal Rodeiro 2 Esquerdo	88
Tabela 20 – Ranking das variáveis selecionadas com SelectKBest utilizando sensores reais e virtuais	90

Listas de abreviaturas e siglas

AE	Sensor de emissão acústica
AED	Análise exploratória dos dados
EFVM	Estrada de ferro Vitória-Minas
FBG	<i>Fiber Bragg Grating</i>
FRA	<i>Federal Railroad Administration</i>
IMU	Unidade de medida inercial
IRV	<i>Instrumented railway vehicle</i> ou vagão instrumentado
LabTDF	Laboratório de Tribologia e Dinâmica Ferroviária
LVDT	transdutor de deslocamento linear variável
MAE	Erro médio absoluto
MBS	Simulação multi-corpos
MSE	Erro médio quadrático
ML	<i>Machine Learning</i> ou Aprendizado de máquina
PBTG	<i>Performance-based track geometry</i>
PSD	<i>Power spectral density</i> ou densidade espectral de potência
SAW	Sensores de onda acústica superficial
SHAP	<i>Shapley Additive Explanation</i>
PPS	<i>Predict Power Score</i>
TPOT	<i>Tree-based Pipeline Optimization Tool</i>
TQIs	<i>Track Quality Index</i>

Lista de símbolos

L	Força lateral
Q	Força Vertical
L/Q	Razão entre a força lateral e vertical do contato roda trilho
μ	Coeficiente de atrito
z_t	Irregularidade na direção vertical (ou longitudinal)
z_l	Coordenadas verticais do trilho esquerdo
z_r	Coordenadas verticais do trilho direito
y_t	Irregularidade na direção lateral (ou alinhamento ou transversal)
y_l	Coordenadas laterais do trilho esquerdo
y_r	Coordenadas laterais do trilho direito
g_o	Valor teórico de bitola
g_t	Desvio na bitola
λ	Comprimento de onda da irregularidade
V	Velocidade do trem
P	Comprimento da região de transição tangente-curva
R	Raio da curva
h	Superelevação
L	Comprimento do trecho tangente da via
$F_{espacial}$	Frequência no domínio espacial
F_{tempo}	Frequência no domínio do tempo
V_{max}	Velocidade máxima do vagão
z_r1_esq_real	Aceleração Vertical Rodeiro 1 Esquerdo
z_travessa_r1_dir	Aceleração Vertical Rodeiro 1 Direito

z_travessa_r2_esq	Aceleração Vertical Rodeiro 2 Esquerdo
z_travessa_r2_dir	Aceleração Vertical da Travessa Lateral Rodeiro 2 Direito
triaxial-y	Aceleração Lateral da Caixa
triaxial-z	Aceleração Vertical da Caixa
s1_mola1	Deslocamento da suspensão secundária Truque 1 Esquerdo
s1_mola2	Deslocamento da suspensão secundária Truque 1 Direito
s2_mola1	Deslocamento da suspensão secundária 2 Esquerdo
s2_mola2	Deslocamento da suspensão secundária Truque 2 Direito
y_eixo_r1_esq	Aceleração Lateral da Caixa de Eixo Rodeiro 1 Esquerdo
z_eixo_r1_esq	Aceleração Vertical da Caixa de Eixo Rodeiro 1 Esquerdo
y_eixo_r1_dir	Aceleração Lateral da Caixa de Eixo Rodeiro 1 Direito
z_eixo_r1_dir	Aceleração Vertical da Caixa de Eixo Rodeiro 1 Direito
y_eixo_r2_esq	Aceleração Lateral da Caixa de Eixo Rodeiro 2 Esquerdo
z_eixo_r2_esq	Aceleração Vertical da Caixa de Eixo Rodeiro 2 Esquerdo
y_eixo_r2_dir	Aceleração Lateral da Caixa de Eixo Rodeiro 2 Direito
z_eixo_r2_dir	Aceleração Vertical da Caixa de Eixo Rodeiro 2 Direito
roll	Roll do Truque
pitch	Pitch do Truque
L/Q_1_esq	Valor de L/Q Rodeiro 1 Esquerdo
L/Q_1_dir	Valor de L/Q Rodeiro 1 Direito
L/Q_2_esq	Valor de L/Q Rodeiro 2 Esquerdo
L/Q_2_dir	Valor de L/Q Rodeiro 2 Direito
y_{pred}	Valor predito
\hat{y}_{real}	Valor real
\bar{y}	Valor real médio

Sumário

1	INTRODUÇÃO	14
1.1	Motivação	14
1.2	Relevância da pesquisa	14
1.3	Objetivo geral	15
1.3.1	Objetivos específicos	15
2	INSTRUMENTAÇÃO DOS VEÍCULOS FERROVIÁRIOS	16
2.1	Tipos de veículos ferroviários instrumentados	16
2.1.1	Carro controle	16
2.1.2	Vagão instrumentado	17
2.2	Tipos de Sensores	18
2.3	Influência da taxa de amostragem na leitura do sensor	22
2.3.1	Conversão da taxa de amostragem do domínio do tempo para o espacial	25
3	AVALIAÇÃO DA VIA COM BASE NA GEOMETRIA E DINÂMICA DO VAGÃO	27
3.1	Critério de Nadal	27
3.2	Norma AAR M976	29
3.3	Dependência da geometria da via com o Nadal	30
3.4	Irregularidades	31
3.4.1	Norma EN 13848-5	34
4	METODOLOGIA	36
5	SIMULAÇÃO DINÂMICA	37
5.1	Modelo do vagão instrumentado	37
5.1.1	Posição dos sensores	40
5.2	Macrogeometria da via	43
5.3	Perfil de roda + trilho	44
5.4	Perfil de velocidade	45
5.5	Irregularidades da via	46
6	MACHINE LEARNING	49
6.1	Pré-processamento dos dados	50
6.1.1	Análise exploratória dos dados (AED)	50
6.2	Modelagem/Aprendizagem	58
6.2.1	Explicabilidade do modelo	59

6.2.2	Algoritmo de <i>Machine Learning</i>	63
7	RESULTADOS	65
7.1	Nadal rodeiro 1 esquierdo	65
7.2	L/Q rodeiro 1 direito	66
7.3	L/Q rodeiro 2 esquierdo	67
7.4	L/Q rodeiro 2 direito	68
7.5	Conclusão	69
7.6	Disponibilização do código utilizado	71
8	REFERÊNCIAS	72
8	APENDICE	78
8.1	Apêndice A	78
8.2	Apêndice B	80
8.3	Apêndice C	82
8.4	Apêndice D	83
8.5	Apêndice E	84
8.6	Apêndice F	88
8.7	Apêndice G	89
8.8	Apêndice H	90

1 Introdução

1.1 Motivação

A malha ferroviária brasileira é um dos mais utilizados meios de transporte, seja para passageiros ou para transporte de produtos. Desde o início das concessões ferroviárias ao setor privado em 1997, houve uma melhoria contínua na produtividade das ferrovias. As ferrovias aumentaram significativamente o volume transportado, que chegou a ser de 569 milhões de toneladas úteis em 2018, representando um aumento de 125% desde a época das concessões ([FERROVIÁRIOS](#), 2019). Mais recentemente, houve um aumento de 5.7% sobre o volume transportado em 2017 (539 milhões de toneladas úteis) ([FERROVIÁRIOS](#), 2019).

Segundo [Jenkins et al. \(1974\)](#), para manter o crescimento da malha ferroviária, é necessário que os veículos ferroviários tenham maiores velocidades e maiores cargas suportadas por eixo e, historicamente, essa tendência provavelmente continuará. Para ilustração, os vagões GDT usados originalmente possuíam uma carga por eixo de 30.5 toneladas, que foi aumentada para 32.5 toneladas. No caso dos vagões GDU, a carga por eixo aumentou para 37.5 toneladas ([SANTOS, 2015](#)). Isso acarreta em maiores tensões e forças de contato, portanto, a condição da ferrovia torna-se mais severa. Como consequência, vai existir uma degradação mais acentuada no trilho e necessidade de realizar manutenções mais frequentes ([VAZ et al., 2018](#)).

1.2 Relevância da pesquisa

Como visto acima, a tendência é o setor ferroviário brasileiro continuar crescendo, entretanto, é necessário continuar garantindo segurança ao transporte de cargas e passageiros, assim como conforto.

A forma mais utilizada para se estudar segurança no meio ferroviário é o critério de Nadal, que representa o limite crítico para a razão entre as forças laterais e verticais presentes no contato roda trilho (L/Q) ([SANTOS, 2015](#)). Se esse limite for ultrapassado, existe um grande risco do vagão descarrilar, ou seja, sair do trilho e tombar. Então é possível estabelecer um limite seguro de operação na qual o vagão deve sempre seguir. A opção normalmente utilizado para medir L/Q é o rodeiro instrumentado, no entanto, existem três limitações importantes na sua implementação prática:

1. A medição das forças é uma tarefa complexa e necessita de uma equipe especializada para instalar e utilizar o equipamento ([BARBOSA, 2017](#));

2. Trata-se de um equipamento custoso (extensômetros elétricos, tacômetro, sistema coletor de informações, algoritmo sofisticado de tratamento de dados) (BARBOSA, 2017; BARBOSA, 2016b);
3. Descarrilhamento depende de outros fatores além das forças de contato, como irregularidades, lubrificação, perfil de trilho, rigidez da pista, velocidade e a resposta dinâmica do vagão (SANTOS, 2015; HAIGERMOSE et al., 2015; BAI et al., 2015; BARBOSA, 2017; LI et al., 2006).

Portanto, é de grande relevância para o setor ferroviário explorar outras opções para medição dos esforços do vagão visando diminuir o custo, complexidade e aumentar a confiabilidade da detecção de defeitos.

1.3 Objetivo geral

O objetivo é desenvolver uma alternativa de se obter as forças de contato do vagão através de experimentos virtuais.

1.3.1 Objetivos específicos

1. Verificar o efeito da taxa de amostragem na precisão do modelo;
2. Verificar a efeito da taxa de amostragem no valor dos dados obtidos;
3. Determinar quais são os sensores e as variáveis mais importantes para o modelo de ML;
4. Verificar se a instrumentação atual do vagão instrumentado é capaz de fornecer a razão entre a força lateral e vertical do contato roda trilho;
5. Comparar o desempenho de diferentes modelos de ML.

2 Instrumentação dos veículos ferroviários

2.1 Tipos de veículos ferroviários instrumentados

2.1.1 Carro controle

Carro controle é um veículo ferroviário projetado para avaliar diretamente a geometria da via permanente ([SANTOS, 2015](#)), exemplificado pela figura 1. Ele é capaz de fornecer a verdadeira grandeza dos dados geométricos por meio de sensores transmitidos para registradores no interior do carro ([REZENDE, 2008](#)). As variáveis normalmente medidas pelo carro controle são:

- Bitola;
- Nivelamento transversal;
- Nivelamento longitudinal;
- Alinhamento;
- Empeno ou torção;
- Desgaste do boleto do trilho.



Figura 1 – Exemplo de um carro controle EM100 - ([SANTOS, 2015](#))

O carro controle é normalmente equipado com sistemas de medição inerciais que usam acelerômetros, giroscópios e lasers para gravar a geometria da via ([KARIS, 2018](#)). A instrumentação pode ser complexa conforme ilustrado pela figura 2. Este veículo é equipado com acelerômetros verticais e laterais, transdutores de deslocamento linear variável (LVDT), um sistema óptico com laser e câmeras para coletar dados da pista.

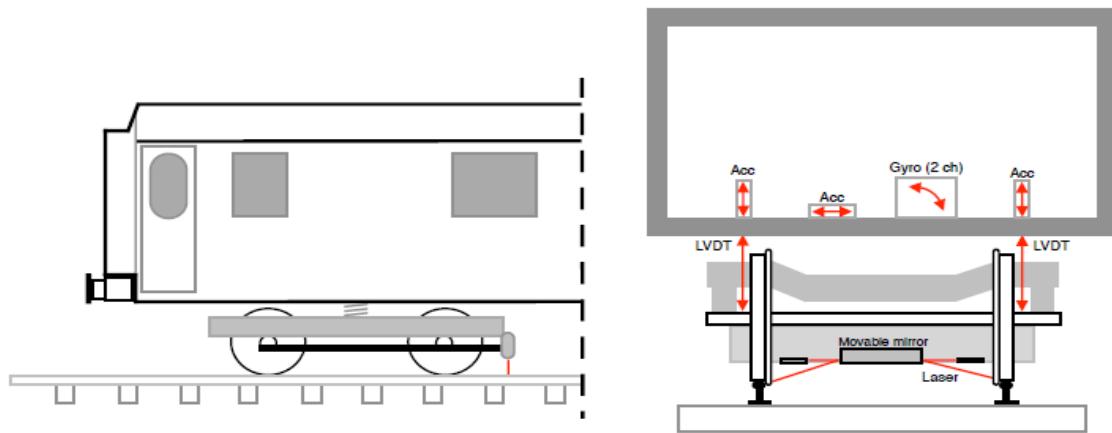


Figura 2 – Sistema de medição inercial de um carro controle - ([KARIS, 2018](#)).

2.1.2 Vagão instrumentado

Vagões instrumentados são vagões de serviço regulares que possuem equipamentos e sensores montados capazes de medir, armazenar e comunicar a sua performance nas condições normais de operação ([SANTOS; REICHL et al., 2014](#)). As principais vantagens de se utilizar o vagão instrumentado são:

- A operação não é interrompida; ([SANTOS; REICHL et al., 2014; CHONG et al., 2017](#));
- O equipamento mede a resposta do vagão em tempo real nas condições normais de operação, tanto carregado quanto descarregado ([RAVITHARAN, 2018; SANTOS; REICHL et al., 2014](#)).

A figura 3 mostra um exemplo de vagão instrumentado. É possível perceber a instalação de placas solares na lateral da caixa do vagão para o sistema ser autossuficiente na figura da esquerda. A figura da direita mostra uma imagem ampliada do sensor instalado no vagão original para medir o deslocamento axial do conjunto de molas, chamado de célula de carga.



Figura 3 – Vagão instrumentado, com imagem ampliada do sensor instalado (célula de carga) - ([SANTOS; REICHL et al., 2014](#))

2.2 Tipos de Sensores

Em termos de localização do sensor, existem dois tipos de monitoramento: fixo (estático) e móvel (a bordo do vagão) ([HODGE et al., 2014](#); [NGAMKHANONG; KAEWUNRUEN; COSTA, 2018](#)). Os sensores usados no monitoramento fixo são instalados na ferrovia. Eles podem ser usados para medir a condição do veículo ferroviário que passou pelo ponto específico na qual o sensor foi instalado. Para monitoramento móvel ou contínuo, os sensores são instalados nos componentes do veículo ferroviário como no rodeiro, motor ou na caixa por exemplo.

O monitoramento fixo é destinado principalmente para mensurar os parâmetros da superestrutura ou subestrutura da via, enquanto que o monitoramento contínuo é usado nos vagões. Como o objetivo do trabalho é obter a razão L/Q das forças do rodeiro, é necessário analisar os sensores usados no monitoramento contínuo. Para detalhes sobre aplicações de monitoramento fixo, recomenda-se os trabalhos de ([HODGE et al., 2014](#)) e ([NGAMKHANONG; KAEWUNRUEN; COSTA, 2018](#)). O tabela 1 mostra um quadro resumo que fornece a definição dos sensores normalmente utilizados na medição de parâmetros da ferrovia assim como uma breve descrição de cada sensor.

Tipo de sensor	Descrição e exemplo de uso
Acelerômetro	Acelerômetros são usados para medir vibrações na infraestrutura na pista ou acelerações laterais e verticais do corpo acoplado. Eles são robustos, confiáveis, fáceis de calibrar e baratos.
Transdutor de deslocamento linear variável (LVDT)	Um LVDT converte um deslocamento linear ou angular em um sinal para ser gravado. Eles são utilizados para monitorar trincas e juntas durante o movimento para garantir a estabilidade da estrutura.
Sensor de fibra óptica(Fiber Bragg Grating - FBG)	Sensores FBG podem ser usados para mensurar temperatura, tensão ou aceleração. Mudança na temperatura ou tensão translada o comprimento de onda de Bragg (comprimento de onda da luz refletida pela fibra óptica) e isso permite fazer a medição por um mapeamento. Esses sensores possuem longa vida útil (>20 anos).
Sensor de fibra óptica por interferência (Interferometric Fiber Sensor)	Sensores de fibra óptica por interferência detectam a fase do sinal senoidal de saída. O comprimento de onda da luz nesse sensor independe da existência de campo magnético, ou seja, possui aplicação em ferrovias eletrificadas.
Giroscópios	Giroscópios medem a velocidade angular do veículo em torno dos eixos e pode fornecer indiretamente o roll, pitch e yaw, o que torna eles ideais para analisar vagões, caixas e truques.
Inclinômetro	Inclinômetros medem o ângulo de inclinação através da geração de uma plano horizontal artificial e verificando a inclinação com relação a esse plano. Esse sensor detecta distorção das estruturas ferroviárias através da mudança dessa inclinação.
Transdutor de pressão	Um transdutor de pressão produz um sinal que reflete a pressão imposta no sensor. Eles podem determinar o deslocamento vertical a partir de uma linha hidráulica de referência. Qualquer deslocamento será refletido através de mudanças na pressão.
Piezômetros	Piezômetros são usados para medir a pressão positiva da água absorvida pelo lastro do trilho. Eles são robustos e confiáveis, mas precisam ser calibrados para contabilizar a pressão atmosférica.
Extensômetros (Strain Gauges)	Extensômetros medem deformações locais e geram um sinal que reflete a tensão aplicada ao sensor. Eles são normalmente usados na medição das forças verticais e laterais entre os dormentes dos trilhos ou nas próprias rodas (rodeiro instrumentado).
Termopares	Termopares são usados para medir a temperatura do ar atmosférico, chassis do vagão e equipamentos mecânicos
Extensômetros ultrassônicos	Extensômetros ultrassônicos gravam ondas acústicas elásticas causadas pela vibração da estrutura quando, por exemplo, um vagão passa. Eles são mais fáceis de instalar e são mais sensíveis que os extensômetros normais e podem ser realocados diferentemente dos extensômetros piezoelétricos
Piezoelétricos	<p>Sensores piezoelétricos geram um sinal quando o material piezoelétrico (quartzo por exemplo) é comprimido. Eles são usados para medir tensão, pressão, vibração e choques. Esse sensor possui boa repetibilidade então são colocados nas rodas do vagão para monitorar qualquer deslocamento da superfície da roda e identificar os defeitos da roda. São mais fáceis de fabricar e mais baratos do que os sensores ópticos.</p>
	<p>Sensores piezoresistivos de pressão possuem um diafragma de silicone com extensômetros piezoresistivos. Eles produzem um sinal maior comparado aos outros sensores, aumentando a sua sensibilidade. Eles são usados para medir e monitorar mudanças na resistência de porcas e parafusos da via para garantir que elas não se soltem.</p>
	<p>Sensores de emissão acústica (AE) são transdutores piezoelétricos de alta frequência. Ondas acústicas são geradas quando uma energia de deformação é liberada como, por exemplo, em trincas de fadiga. Os sensores AE detectam essas ondas acústicas enquanto filtram o ruído do ambiente. Então os sensores AE são capazes de detectar danos internos de estruturas onde nucleou-se as trincas. Uma desvantagem é que os dados obtidos são grandes e requer um algoritmo preciso e eficiente para processar e interpretar as informações.</p>
	<p>Surface acoustic wave sensors (SAW) converte um sinal elétrico de entrada em ondas mecânicas usando um material piezoelétrico. Depois convertem essa onda de volta para um sinal elétrico para análise. Ondas mecânicas são afetadas por fenômenos físicos como temperatura então os sensores SAW são usados para monitorar mudanças de temperatura no rolamento da caixa de eixo dos veículos ferroviários. Esses sensores são sensíveis e estáveis, mas podem ser distorcidos na presença de líquidos, então eles precisam estarem secos.</p>

Tabela 1 – Tipos de sensores mais usados na medição de parâmetros ferroviários - ([HODGE et al., 2014](#)) adaptado pelo autor

É necessário, então, focar o escopo dos sensores para aqueles que já são normalmente utilizados no monitoramento das condições do vagão. De posse das definições dos sensores da tabela 1, a tabela 2 mostra um resumo dos artigos pesquisados. É possível encontrar nele o tipo de sensor, a variável medida e o objetivo do trabalho.

Estudo	Objetivo do trabalho	Veículo usado na obtenção dos dados	Sensor/Indicador	Local de instalação do sensor	Variável medida	Método utilizado	Referência
Nadal	Prever a degradação da via	Carro controle	Indicador TQI (Track Quality Index)	N/A	Bitola, superelevação, torção, alinhamento vertical e horizontal	Modelo de processo estocástico de Markov	(BAI et al., 2015)
	Desenvolver um modelo de simulação para avaliar a degradação da via causado pelo esmerilhamento do trilho e definir um intervalo para a manutenção da via	Carro controle	Acelerômetros, câmeras e lasers	N/A	Irregularidade lateral	Modelo linear com simulação Monte Carlo	(MUNINDE, 2018)
	Obter L/V a partir de aceleração	Vagão virtual	N/A	Caixa e duas travessas laterais	Aceleração vertical, lateral e pitch	Modelo inverso	(SUN; COLE; SPIRYAGIN, 2015)
	Medir L/V	Vagão instrumentado	Sensor de vão	Suspensão primária e disco da roda	Deslocamento do disco e da suspensão primária	-	(MATSUMOTO et al., 2012; MATSUMOTO et al., 2008)
	Medir L/V	Vagão instrumentado	Extensômetro, LVDT e acelerômetro	Caixa de rolamento, suspensão primária	Deslocamento da suspensão primária, aceleração e deformação da caixa de rolamento	Modelo matemático	(WEI et al., 2014)
	Obter o valor de Nadal a partir da aceleração e velocidade angular do vagão	Carro controle	N/A	Caixa	Aceleração e velocidades angulares	Modelo inverso (caixa cinza)	(XIA; COLE; WOLFS, 2008)
Detecção de defeitos	Obter o valor de Nadal e identificar locais problemáticos da via	Vagão instrumentado	IMU e magnetômetro,	IMU: Centro da caixa do primeiro carro de passageiro	IMU: Aceleração e velocidade angular X,Y e Z da caixa. Magnetômetro: velocidade angular, roll, pitch e yaw	Modelo matemático inverso	(BARBOSA, 2016b)
	Obter o valor de Nadal a partir da geometria da via	Vagão instrumentado	2 rodeiros instrumentados. Sistema de medição da geometria. 8 Acelerômetros: 4 verticais e 4 laterais	Rodeiro instrumentado: rodeiro dianteiro do truque 1 e 2. Acelerômetros: aceleração vertical e lateral da caixa do vagão	Acelerômetros: aceleração vertical e lateral da caixa. Curvatura, superelevação, alicanhamento lateral, vertical e bitola	Redes neurais (Machine Learning)	(LI et al., 2006; LI et al., 2005)
	Desenvolvimento de dois sistemas de monitoramento da via para detectar irregularidades e corrugação	Vagão instrumentado	Microfone, acelerômetros, giroscópio	Caixa e caixa de eixo do truque dianteiro	Aceleração da caixa: detectar corrugação. Giroscópio: roll. Aceleração da caixa de eixo: irregularidades lateral e vertical	Técnicas de processamento de sinais digitais. Análise de multiresolução usando Wavelets (MRA)	(TSUNASHIMA et al., 2012)
	Obter dados geométricos da via e classificá-los em 4 níveis	Vagão instrumentado	Acelerômetros, sensor de roll e yaw e SND (sensor de deslocamento da suspensão primária)	Acelerômetro: caixa do vagão e caixa de eixo. SND: caixa de eixo Sensor de roll e yaw: Travessa central	Acelerômetro: aceleração vertical e lateral da caixa de eixo, irregularidade vertical. SND: Superelevação. Sensor de roll e yaw: curvatura da via e irregularidade lateral	Modelo de classificação e regressão (Supervised Machine Learning)	(LINGAMANA IK et al., 2017; NADARA-JAH et al., 2018)
Irregularidades	Detectar defeitos como corrugação, desnível e irregularidade longitudinal	Vagão instrumentado	3 acelerômetros triaxiais, 1 giroscópio	Caixa do trem	Aceleração vertical	Análise de multiresolução usando Wavelets (MRA)	(TSUNASHIMA et al., 2015)
	Monitorar as irregularidades usando acelerômetros	Vagão instrumentado	2 Acelerômetros	Caixa de eixo e travessa lateral	Aceleração vertical e horizontal. Deslocamento vertical e horizontal	Filtro de Kalman, filtro passa faixa e filtro de compensação	(LEE et al., 2011a; LEE et al., 2011b)
	Desenvolvimento de um IMU. Medir irregularidade vertical. Mensurar degradação da via com dados históricos das rondas	Trem instrumentado	IMU	Topo do truque	Aceleração X,Y,Z, roll, pitch e yaw	Filtro Bryson-Frazier (Filtro de Kalman modificado)	(YEO, 2017)
	Obter irregularidade vertical a partir da aceleração	Vagão instrumentado	Acelerômetros, LVDTs e giroscópios	Acelerômetro na travessa lateral e caixa de eixo. LVDT na suspensão primária	Aceleração vertical e pitch	Modelo matemático	(WESTEON et al., 2007)
Exibição de dados do vagão instrumentado	Obter irregularidade lateral usando sensores	Vagão instrumentado	Acelerômetro e giroscópio	Acelerômetro	Aceleração lateral e yaw	Modelo inverso	(WESTON et al., 2007)
	Obter irregularidade a partir da resposta dinâmica do vagão	Simulação	N/A	N/A	Bitola, superelevação e irregularidade vertical	Identificação de sistemas (função de transferência)	(LUBER, 2009)
	Criação de um vagão instrumentado	Vagão instrumentado	N/A	N/A	Suspension travel, rock, bounce, aceleração da caixa de eixo	N/A	(DARBY et al., 2003)
	Visualização e integração de dados medidos continuamente por um vagão instrumentado	Vagão instrumentado	acelerômetros e céluha de carga	N/A	Deslocamento do truque, aceleração lateral, força do acoplamento, pressão do freio	Heatmap, regressão linear	(REICHL; RIBEIRO; SANTOS, 2015)

Tabela 2 – Quadro resumo dos artigos usados na revisão bibliográfica

No que tange aos artigos cujo objetivo é medir as forças do rodeiro, existem diversas alternativas para o posicionamento dos sensores. É fundamental que o modelo de vagão

virtual contemple o maior número possível de variáveis que o IRV consegue medir. Baseado na revisão bibliográfica sobre sensores, o modelo virtual contempla as seguintes variáveis:

1. Caixa de eixo:

- Aceleração lateral (Y) e vertical (Z);

2. Truque:

- *Roll, Pitch*;
- Deslocamento vertical da suspensão secundária;
- Aceleração lateral e vertical (sensor na travessa lateral alinhada com a linha de centro do rodeiro).

3. Caixa:

- Aceleração Y e Z;

Para efeito de comparação, o trabalho do autor ([WARD et al., 2011](#)) mostra uma tabela com a posição dos sensores e qual característica ele seria capaz de medir, mostrado na tabela 3.

2.3 Influência da taxa de amostragem na leitura do sensor

A taxa de amostragem do sensor afeta diretamente a precisão na obtenção dos dados, visualização e detecção de defeitos na via. Altas taxas de amostragem são preferíveis pois permitem visualizar defeitos que causam cargas de impacto devido a irregularidades locais como por exemplo soldas mal executadas ([COWIE et al., 2015](#)), no entanto, torna mais complicado o armazenamento e transmissão desses dados ([ATTOH-OKINE, 2017](#)). Além disso, o custo é mais elevado para os sensores de maior taxa. [RealityAI \(2020\)](#) discute se a utilização de altas taxas de amostragem é realmente necessário em algumas aplicações. Segundo o autor, ambientes com muito ruído ou que variam muito necessitam de uma alta resolução na frequência e, portanto, uma alta taxa de amostragem. No caso do sistema ferroviário, as irregularidades geométricas da via representam este tipo de ambiente.

Sensores posicionados na caixa de eixo necessitam, portanto, de uma maior taxa de amostragem pois mede a resposta do vagão às irregularidades da via sem ser filtrado. Sensores no truque podem ter uma taxa de aquisição menor que os da caixa de eixo pois ele mediria sinais filtrados mecanicamente pela suspensão primária. Além disso, o efeito de filtro e amortecimento diminui a amplitude do sinal, com isso, o range do sensor também pode ser menor. Segundo [Bernal, Spirugin e Cole \(2018\)](#), instalar sensores na caixa de eixo não é desejável por motivos de manutenibilidade e robustez. Os componentes colocados na

Característica	Caixa de eixo			Truque			Caixa
	Acelerômetro vertical	Acelerômetro lateral	Acelerômetro vertical	Acelerômetro lateral	Giroscópio (Pitch)	Giroscópio (yaw)	
Comprimento de onda curto (<8m), irregularidades verticais (juntas afundadas, vazios, superelevação, torção)	X						
Comprimento de onda curto (<8m), irregularidades laterais (dobras e desalinhamentos)		X					
Irregularidades verticais >8m			X				
Irregularidades laterais >8m				X			
Alinhamento vertical da pista					X		
Alinhamento lateral da pista						X	
Supelelevação			X			X	
Torção (Twist)	X					X	
Características da suspensão lateral	X			X		X	X
Estimar velocidade de trem			X			X	
Características do contato roda trilho	X			X	X	X	X

Tabela 3 – Sensores apropriados para o tipo específico de monitoramento - ([WARD et al., 2011](#)) adaptado pelo autor

caixa de eixo podem sofrer acelerações de 100 g, enquanto que os fixados no truque ou caixa podem ter acelerações de 10 g e 1 g respectivamente.

Para o caso da caixa do vagão, o sinal lido seria filtrado tanto pela suspensão primária quanto pela suspensão secundária. ([REALITYAI, 2020](#)) diz que, apesar de ser necessário mais banda e espaço para transmitir e armazenar os dados, é mais fácil colher dados a uma taxa alta e depois fazer o *downsampling* do que refazer as medições com uma taxa maior. O vagão instrumentado BRA1 adota essa prática, adquirindo os dados a uma taxa grande e fazendo um *downsampling* para 1 Hz. Nesse *downsampling*, são escolhidos os maiores picos e vales no intervalo de 1 s para serem armazenados.

Não existe uma definição clara de qual a melhor taxa para cada localização no vagão, pois, depende da aplicação, no entanto, é possível ter uma noção da faixa de valores esperados. A seguir, tem-se alguns exemplos de taxas de amostragem utilizados por pesquisadores da área de medição de parâmetros da via:

- [RealityAI \(2020\)](#) afirma que dados com altas taxas de aquisição seriam maiores que 100 Hz para vibração (podendo chegar até MHz) e 8-44kHz para som;
- [Gómez et al. \(2020\)](#) utilizaram acelerômetros na caixa de eixo com uma taxa de 12.8 kHz para monitorar a existência de trincas do eixo do rodeiro (figura 18);
- [Tsunashima et al. \(2012\)](#) utilizaram uma taxa de 2 kHz para a aceleração da caixa do vagão para detectar corrugação da via;
- [Lingamanaik et al. \(2017\)](#), [Nadarajah et al. \(2018\)](#) fizeram um *downsampling* para que todos os sinais captados pelo vagão instrumentado fossem 100 Hz para garantir a consistência do conjunto de dados;
- Os dados de [Weston et al. \(2007\)](#), [Westeon et al. \(2007\)](#) foram amostrados com 4 kHz (taxa excessivamente alta) para acomodar os acelerômetros da caixa de eixo para a obtenção do valor das irregularidades laterais. Informações sobre o range dos sensores podem ser visto em [Westeon et al. \(2007\)](#);
- [Lee et al. \(2011b\)](#), [Lee et al. \(2011a\)](#) adquiriu os seus dados dos acelerômetros da caixa de eixo e travessa com uma taxa de 2048 Hz. A medição da velocidade da via foi feito de modo que os dados filtrados fossem rearranjados do domínio do tempo para o domínio espacial em intervalos de 0,25 m;
- [Tsunashima et al. \(2015\)](#) utilizaram uma taxa de 860Hz para medir a aceleração vertical da caixa do vagão e utilizou Wavelets para detectar defeitos da via utilizando uma análise multimodal. Depois foi utilizado uma taxa de 86Hz para dados medidos visto que não era desejado observar corrugação;

- Yeo (2017) usa uma taxa de 8kHz e depois um *downsampling* para 250 Hz. Ele diz que um acelerômetro com range máximo de $100m/s^2$ para o truque e $10m/s^2$ para a caixa satisfaz enquanto que um giroscópio com 10 Hz para o truque e 1.25 Hz para a caixa é suficiente;
- Hardie et al. (2016) aprimoraram a taxa de aquisição dos sensores do vagão instrumentado para 2500 Hz.
- Darby et al. (2005) dizem que as frequências de interesse de parâmetros como aceleração da caixa de eixo ou travessa precisa são de 100 Hz para cima. O modelo deste vagão instrumentado é muito próximo do utilizado na ferrovia BRA1;

Bernal, Spirugin e Cole (2018) apresentam um resumo dos sistemas de monitoramento dos parâmetros da via com foco na taxa de amostragem e o sistema de monitoramento utilizado para cada autor e em qual aplicação específica. Recomenda-se visualizar a tabela 3 deste autor para mais informações.

De posse desses exemplos, é possível concluir que a taxa de amostragem mínima necessária para aplicações de medição de parâmetros do vagão instrumentado é de 100 Hz, no entanto, a literatura recomenda adquirir a uma taxa consideravelmente maior (na faixa dos kHz) e depois realizar o *downsampling*. Na seção 6.1.1, são comparados os dados adquiridos com as taxas de amostragem de 1 Hz (utilizado atualmente na BRA1) e 100 Hz (valor normalmente utilizado segundo a revisão bibliográfica da seção 2.3).

2.3.1 Conversão da taxa de amostragem do domínio do tempo para o espacial

A taxa de amostragem é geralmente dada em amostras por segundo, mas é importante obter a leitura no domínio espacial para localizar o ponto exato da via onde foi detectado a anomalia. No trabalho de Yeo (2017), uma taxa de 8 amostras por metro é suficiente para representar as condições geométricas da via de até 1 m. Uma taxa de 250 Hz fornece aproximadamente 8 amostras por metro a uma velocidade de 70 milhas por hora (31,3 m/s). A fórmula utilizada para obter esse resultado é a (2.1).

$$F_{espacial} = \frac{F_{tempo}}{V_{max}} \quad (2.1)$$

onde:

- $F_{espacial}$ = frequência no domínio espacial (amostras/metro)
- V_{max} = velocidade máxima do vagão (m/s)
- F_{tempo} = frequência no domínio do tempo (amostras/segundo)

No caso deste trabalho, a velocidade máxima da via é 65 km/h (18,06 m/s). Comparando as taxas de 1 Hz, 10 Hz e 100 Hz, a precisão no domínio espacial será de 0,055 , 0,55 e 5,5 amostras por metro respectivamente. Em outras palavras, teríamos 1 amostra a cada 18,2 m, 1,82 m e 0,182 m respectivamente.

3 Avaliação da via com base na geometria e dinâmica do vagão

3.1 Critério de Nadal

A estabilidade e a capacidade de executar curvas de um vagão depende das forças do contato roda-trilho (XIA; COLE; WOLFS, 2007). Dependendo do valor dessas forças, é possível que ocorra descarrilhamento, ou seja, o veículo sair do trilho. Segundo Santos (2015), uma ocorrência ferroviária tem danos imprevisíveis, desde um simples atraso de horário até prejuízos milionários com perda de ativos e, em casos extremos, vidas humanas. Um tipo de descarrilhamento comum de acontecer é o que envolve a escalada do flange, mostrada na figura 4.

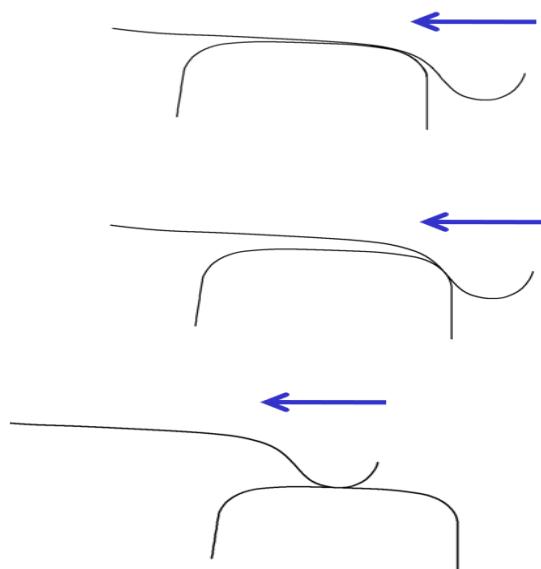


Figura 4 – Processo de descarrilhamento por escalada no flange - ([DERAILMENT](#),)

O índice que é utilizado para definir o limite para a ocorrência desse tipo de descarrilhamento é o índice de Nadal, cuja fórmula está representada na equação (3.1), onde L é a força lateral e Q a força vertical. Segundo Barbosa (2016b), a quantificação da razão das forças laterais e verticais é uma indicação da qualidade da via e, portanto, da segurança do veículo. Para valores acima desse limite, a segurança fica comprometida e é provável a ocorrência de descarrilhamento.

$$\text{Critério de Nadal} = \left(\frac{L}{Q} \right)_{limite} = \frac{\tan \alpha - \mu}{1 + \mu \tan \alpha} \quad [\text{adimensional}] \quad (3.1)$$

A figura 5 mostra a representação gráfica da equação de Nadal. É possível observar que quanto menor coeficiente de atrito (μ), ou seja, quanto mais lubrificado a via, maior o limite de Nadal para um mesmo ângulo de contato. A situação mais recorrente é trabalhar com condições de via seca ($\mu = 0,5$). Para um valor típico de ângulo de contato igual a 65° , o critério de Nadal terá valor igual a 0,8. Com uma via melhor lubrificada ($\mu = 0,2$ por exemplo), o valor limite de $(L/Q)_{limite}$ seria de 1,35, ou seja, 68% mais difícil de descarrilar. Claramente, rodas com baixos ângulos de flange e altos coeficientes de atrito possuem um menor valor de $(L/Q)_{limite}$ e, consequentemente, um maior risco de ocorrer descarrilhamento por escalada do flange.

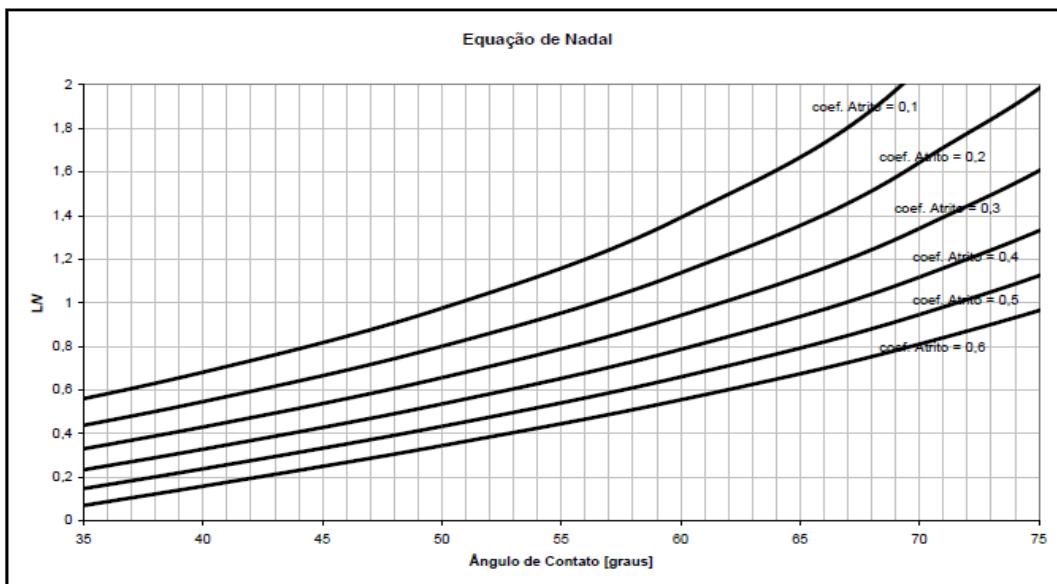


Figura 5 – Representação gráfica da equação de Nadal - (SANTOS, 2015)

É necessário então obter a razão entre as forças laterais e verticais para comparação com o limite de Nadal normatizado a fim de estabelecer o quão seguro o veículo está operando. Para isso, as duas técnicas mais utilizadas para o monitoramento contínuo dessas forças são:

1. Medição das forças usando rodeiros instrumentados;
2. Simulação multicorpos (MBS) do veículo em condições operacionais específicas (KRAFT; CAUSSE; COUDERT, 2018);

Existem sistemas que monitoram essas forças em locais fixos da ferrovia onde os sensores são instalados (CAZZULANI et al., 2017), no entanto, o objetivo é medir a variação do L/Q do vagão continuamente ao longo da via. No caso desse estudo, não é possível utilizar rodeiros instrumentados visto que o objetivo é justamente propor alternativas a essa forma de medir tais forças.

3.2 Norma AAR M976

A norma AAR M976 aborda aprovação, requisitos de performance e validação do design de truques, dispositivos e sistemas de suspensão aplicado em vagões ferroviários. Para vagões em serviço, existem diversos critérios que são testados para verificar o seu desempenho, mostrado na tabela 4. Valores superiores aos descritos nesta tabela são considerados como um comportamento indesejável enquanto que valores abaixo desses limites representam uma performance aceitável.

Regime	Paragraph	Criterion	Limiting Value
Hunting (empty)	11.7.2	maximum lateral acceleration (g)	1.5 ^{a/}
		standard deviation of lateral acceleration (G)	0.13
Constant curving (empty and loaded)	11.7.3	95th percentile maximum wheel L/V	0.8
		95th percentile maximum axle sum L/V	1.5
Spiral (empty and loaded)	11.7.4	minimum vertical load (%)	10 ^{b/}
		maximum wheel L/V	1.0 ^{c/}
		maximum axle sum L/V	1.5 ^{c/}
Twist, roll (empty and loaded)	11.8.2	maximum roll (deg) ^{a/}	6
		maximum axle sum L/V	1.5 ^{c/}
		minimum vertical load (%)	10 ^{b/}
		dynamic augment acceleration (G)	1.0
		loaded spring capacity maximum	95%
Pitch, bounce (loaded) (empty at EEC discretion)	11.8.3	minimum vertical load (%)	10 ^{b/}
		dynamic augment acceleration (G)	1.0
		loaded spring capacity maximum	95%
Yaw, sway (loaded)	11.8.4	maximum L/V truck side	0.6 ^{d/}
		maximum axle sum L/V	1.5 ^{c/}
Dynamic curving (empty and loaded)	11.8.5	maximum wheel L/V	1.0 ^{c/}
		maximum axle sum L/V	1.5 ^{c/}
		maximum roll (deg) ^{a/}	6
		minimum vertical load (%)	10 ^{c/}

^{a/} Peak-to-peak.

^{b/} Not to fall below indicated value for a period greater than 50 milliseconds and for a distance greater than 3 ft per instance.

^{c/} Not to exceed indicated value for a period greater than 50 milliseconds and for a distance greater than 3 ft per instance.

^{d/} Not to exceed indicated value for a duration equivalent to 6 ft of track per instance.

Tabela 4 – Critérios para avaliação dos requisitos de vagões em serviço

Pela tabela 4 na linha *Constant curving (empty and loaded)*, é possível ver que existem dois limites para o Nadal durante a execução de curvas, que é a situação mais crítica. A primeira definição é o Nadal para cada roda individual enquanto que a segunda definição é o Nadal do eixo, que é a soma do módulo de Nadal individual das rodas em um mesmo eixo. Neste trabalho, será considerado que o limite de Nadal como sendo 0,8.

3.3 Dependência da geometria da via com o Nadal

A figura 6 mostra o número de situações defeituosas detectadas dado o critério FRA (Federal Railroad Administration) e o PBTG (performance-based track geometry). O critério FRA detecta defeitos por meio da medição das irregularidades enquanto o PBTG utiliza a resposta dinâmica do veículo.

Na barra da esquerda, o número de defeitos geométricos detectados pelo critério FRA foi alto, no entanto, apenas uma pequena parcela do critério PBTG é detectado, representado pela barra preta. Isso significa que uma falha na geometria não significa necessariamente uma dinâmica ruim.

Já na barra da direita, cerca de 50% das ocorrências de geometria ruim (FRA) também corresponde a uma carga dinâmica alta. Portanto, é insuficiente analisar isoladamente a geometria da via ou a resposta dinâmica do veículo, conforme já relatado por (LASISI; ATTOH-OKINE, 2019; BARBOSA, 2016a; SANTOS, 2015; BARBOSA, 2017; LI et al., 2006; HAIGERMOSEN et al., 2015; HAIGERMOSEN et al., 2014)

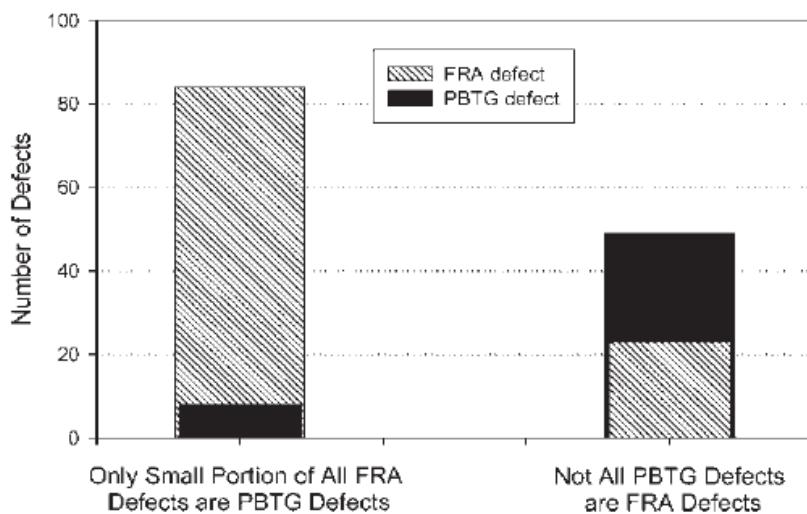


Figura 6 – Resumo dos resultados de detecção de defeitos usando o critério FRA e o critério PBTG - (LI et al., 2006)

Com isso, é possível identificar três problemas relacionados à segurança associado a adoção de critérios apenas geométricos para realização da manutenção:

- Os padrões geométricos da via podem não identificar uma resposta dinâmica indesejável (LI et al., 2006; BARBOSA, 2016a);
- Locais que não atendem aos padrões geométricos podem não causar desempenho dinâmico ruim (LI et al., 2006; BARBOSA, 2016a);
- O planejamento da manutenção pode ser inadequado (KRAFT; CAUSSE; COUDERT, 2018);

Um exemplo ilustrativo dos dois primeiros itens é mostrado na figura 7 com dados

colhidos em campo. É estabelecido que o limite para a resposta dinâmica do vagão seria $L/Q = 1$, conforme ditado pela FRA. Nesse caso, nenhum parâmetro individual da pista possui variações que excedem os limites geométricos estabelecidos pela FRA (indicado pelas setas verticais). Segundo (LI et al., 2006), foi a combinação entre as geometrias que levaram a duas exceções nesse segmento de via.

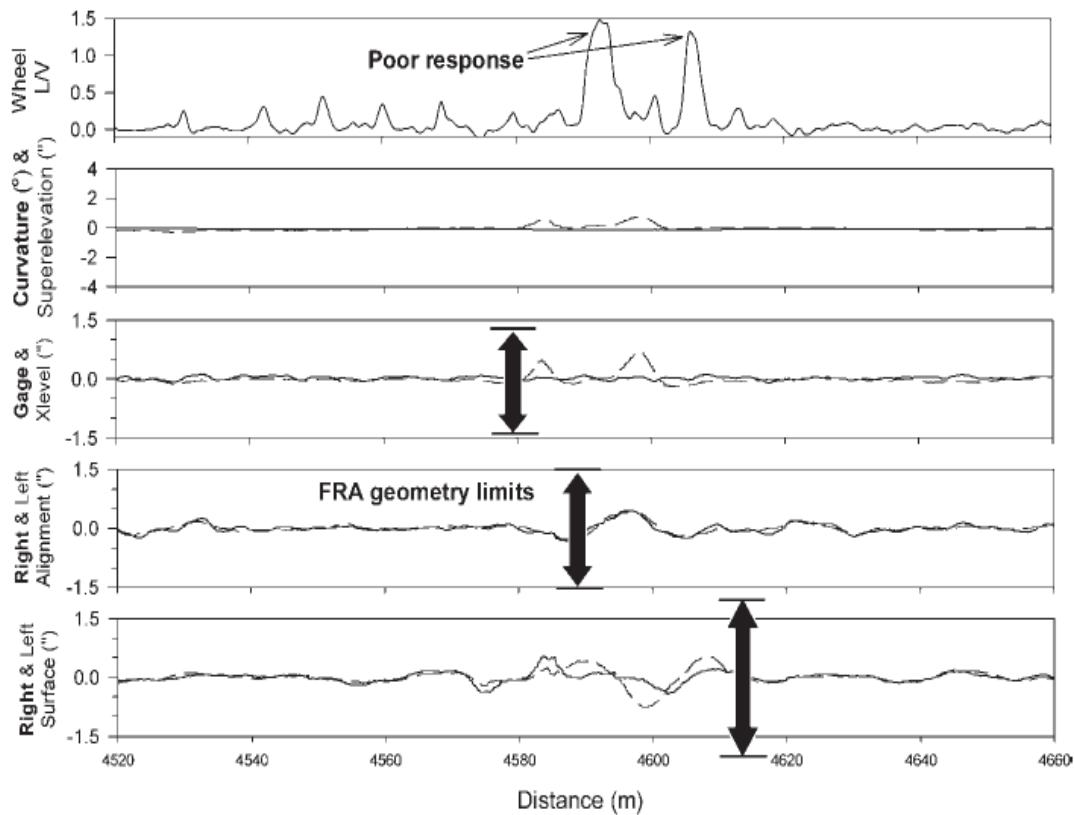


Figura 7 – Resposta dinâmica ruim do veículo numa tangente devido ao cross-level, desalinhamento e deviações superficiais (*velocidade = 69km/h*) - (LI et al., 2006)

3.4 Irregularidades

Define-se irregularidade como sendo a diferença entre a geometria da via e o seu estado ideal (ZHAI, 2015; KARIS, 2018). Elas são parâmetros importantes para o desempenho geral da ferrovia e afeta significativamente a segurança operacional e conforto dos passageiros (BAI et al., 2015; HAIGERMOSEN et al., 2015; ATTOH-OKINE, 2017; KARIS, 2018). Um exemplo ilustrativo pode ser visualizado na figura 8. Sabendo que o limite de Nadal normalmente é 0,8, a existência das irregularidades fez com que existissem pontos onde esse limite de segurança seja superado, tendo assim um grande risco de descarrilhamento.

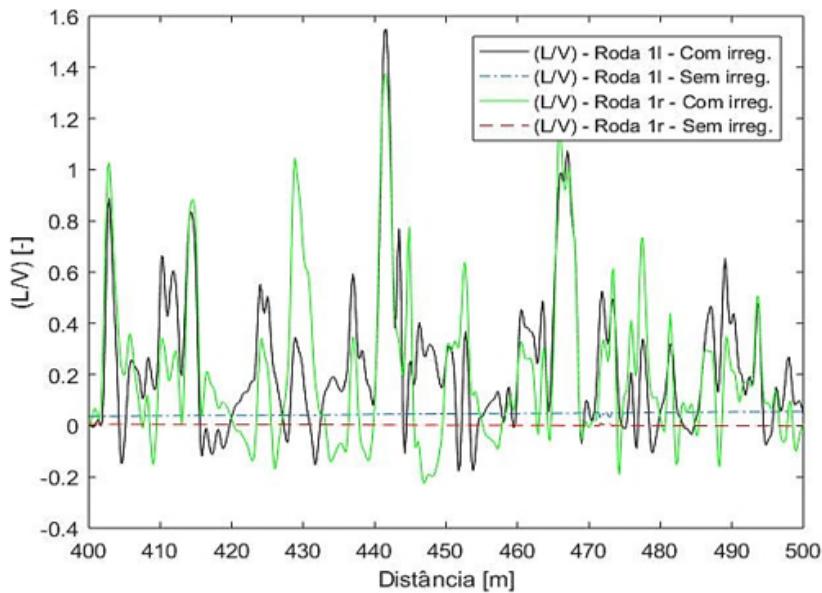


Figura 8 – L/Q para as rodas 1l (esquerda) e 1r (direita) do rodeiro frontal, considerando o efeito das irregularidades - (VAZ et al., 2018)

Os tipos de irregularidades mais comuns na ferrovia são mostrados na tabela 5. As irregularidades distribuídas são essencialmente caracterizadas pela amplitude e pelo comprimento de onda do defeito, podendo este ser longo, médio ou curto (MELO, 2016) e a medição precisa preservar essas informações. Isso significa que cada irregularidade no alcance do comprimento de onda deve ser medido com sua amplitude real e nenhuma mudança de fase entre a forma real e a mensurada deve existir (HAIGERMOSEN et al., 2015).

Uma irregularidade real é uma superposição de harmônicos aleatórios com diferentes comprimentos de onda, fases e amplitudes (ZHAI, 2015), portanto este será o tipo de irregularidade estudada.

	Periódicas	- desgaste ondulação do trilho - juntas do trilho igualmente espaçadas
Irregularidades distribuídas		- variação do alinhamento - variação do nivelamento longitudinal
Aleatórias		- variação do nivelamento transversal - variação de bitola - empeno
Irregularidades isoladas		- endentação do trilho - defeito isolado - defeito em uma junta do trilho - travessa não apoiada

Tabela 5 – Tipos de irregularidades da via e do trilho - (MELO, 2016)

A norma europeia EN 13848-1 (EN, 2003), descreve quatro tipos de irregularidades: irregularidade vertical, irregularidade lateral, desvio da bitola (*gauge*) e superelevação

(crosslevel), mostrado na figura 9.

A irregularidade vertical (ou longitudinal) é a média dos desvios verticais dos trilhos direito e esquerdo a partir do centro da pista, onde z_l e z_r representam as coordenadas verticais dos trilhos esquerdo e direito, respectivamente.

$$z_t = \frac{z_l + z_r}{2} \quad (3.2)$$

A irregularidade lateral (ou transversal) é a média dos desvios laterais dos trilhos direito e esquerdo a partir do centro da pista, onde y_l e y_r representam as coordenadas laterais dos trilhos esquerdo e direito, respectivamente.

$$y_t = \frac{y_l + y_r}{2} \quad (3.3)$$

Desvio da bitola é devido aos desvios laterais dos trilhos direito e esquerdo a partir do valor teórico da bitola g_0 .

$$g_t = y_l - y_r - g_0 \quad (3.4)$$

Irregularidade da superelevação é a diferença de altura entre o trilho direito e esquerdo causado pelo desvio vertical.

$$\delta z_t = z_l - z_r \quad (3.5)$$

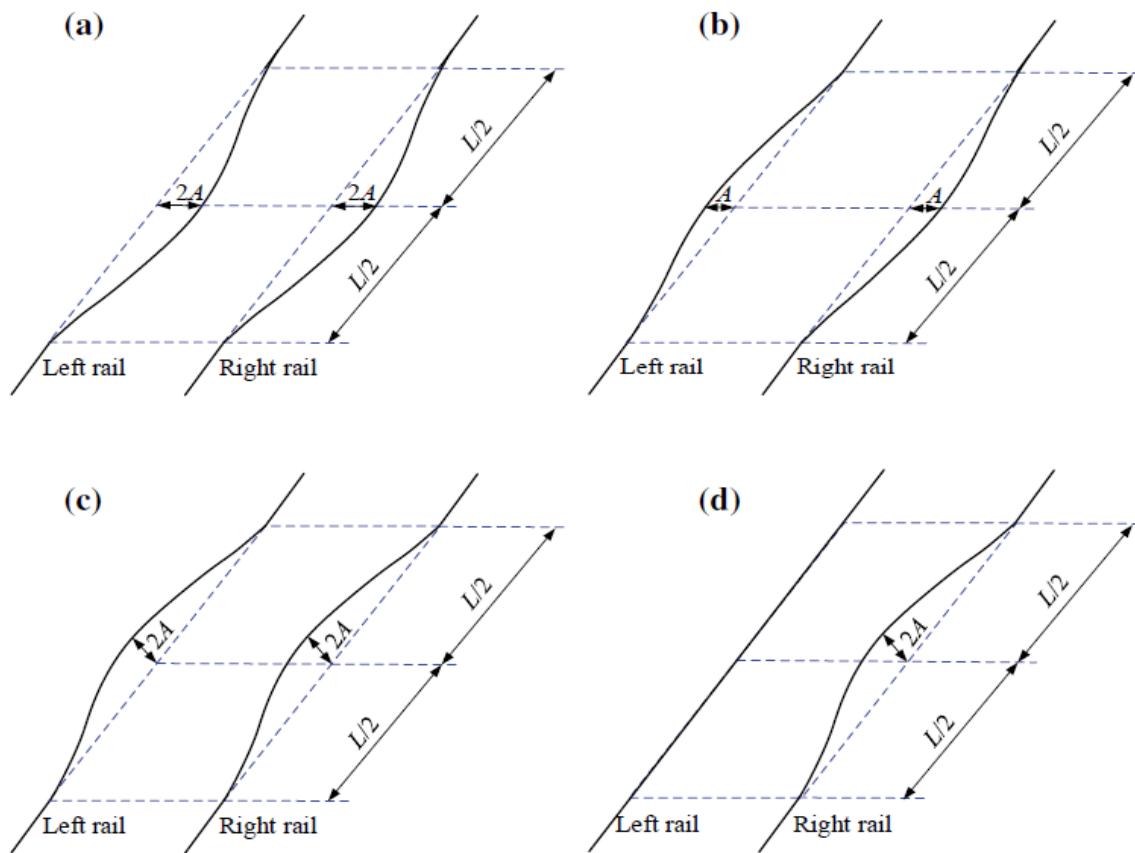


Figura 9 – Irregularidades a) lateral b) bitola c) vertical d) superelevação - (ZHAI, 2015) modificado pelo autor

3.4.1 Norma EN 13848-5

A norma europeia EN 13848-5 (13848-5, 2008) descreve os requisitos mínimos de qualidade para a geometria da via e também especifica os limites de segurança sobre cada tipo de irregularidade. Além disso, esses limites são dados em função da velocidade do vagão e da classe da irregularidade.

Durante a avaliação, as medições das irregularidades são filtradas de modo a isolar diferentes comprimentos de onda (KARIS, 2018). A norma EN 13848-5 faz referência a cinco intervalos de comprimento de onda no qual as medições podem ser feitas, mostrado na tabela 6.

A corrugação dos trilhos (irregularidades verticais de baixo comprimento de onda) corresponde a uma de comprimento de onda entre $0,03 < \lambda < 1,0m$ (KARIS, 2018). Como o comprimento de onda é menor quando comparado às outras irregularidades, a corrugação resulta em uma vibração audível. Segundo Berawi (2013), esse tipo de defeito não representa um risco de descarrilhamento imediato, no entanto, outros problemas indesejáveis podem ocorrer como um aumento do ruído e das vibrações, deterioração dos lastros e maiores ciclos de manutenção.

Tipo	Intervalo do comprimento de onda [m]	Unidade	Tipo de irregularidade na formação	Consequências
λ muito baixo	$\lambda < 3$	m	Corrugação, desgaste ondulatório e defeitos isolados	Ruido e vibrações
D1 (baixo λ)	$3 < \lambda < 25$	m	Alinhamento, cant, twist, gauge, etc.	Redução da segurança
D2 (médio λ)	$25 < \lambda < 70$	m	Alinhamento	Redução da segurança e do conforto
D3 (alto λ)	$70 < \lambda < 150$ verticalmente $70 < \lambda < 200$ lateralmente	m	Geometria da via	Redução do conforto

Tabela 6 – Classificação das irregularidades pela norma EN 13848-5 - (EN, 2003; PODWÓRNA, 2015; ZHAI, 2015) adaptado pelo autor

Segundo Hung e Hsu (2018), irregularidades de baixo comprimento de onda afetam principalmente o descarrilhamento e também causam um maior ruído.

Já para grandes comprimentos de onda, as irregularidades afetam o movimento do carro, vibração e o nível de conforto (HUNG; HSU, 2018). Segundo Xin, Wang e Ding (2019), irregularidades de grandes comprimentos de onda causarão oscilações de baixa frequência no vagão. Como a frequência natural dos vagões costuma estar próxima de 1Hz (KOUROUSSIS et al., 2015), a ressonância pode ocorrer devido a essas irregularidades. Além disso, essas irregularidades são de difícil detecção nos equipamentos de inspeção (XIN; WANG; DING, 2019). A figura 10 mostra como que o comprimento de onda muda o formato das irregularidades.

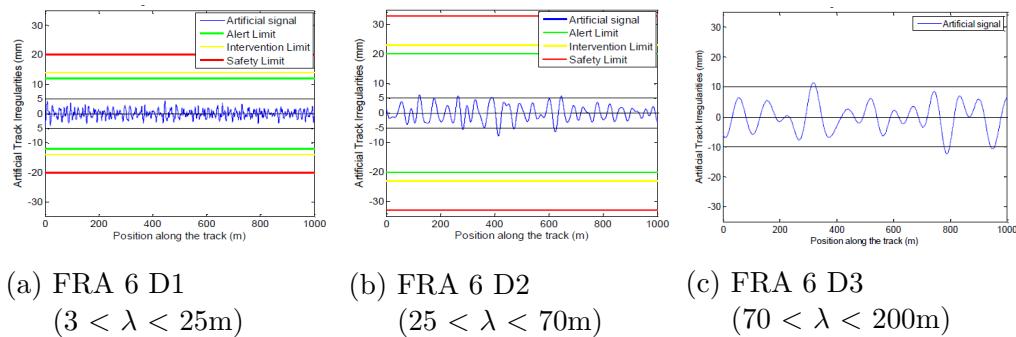


Figura 10 – Influência do comprimento de onda na geração das irregularidades - (BERAWI, 2013)

É importante ter em mente que as normas sobre classificação das irregularidades são similares, mas o intervalo do comprimento de onda é diferente (XIA; ZHANG; GUO, 2018). Então dependendo da norma utilizada, os limites mudarão, mas o conceito por trás da divisão será bem parecido.

4 Metodologia

A figura 11 mostra o fluxograma da metodologia adotada. Para realizar a simulação dinâmica, é necessário definir cinco parâmetros: macrogeometria da via, perfil de roda + trilho, perfil de velocidade do vagão, o modelo do vagão e as irregularidades geométricas. Mais informações sobre esses parâmetros constam no capítulo 5. Após a simulação, obtém-se as variáveis que um típico IRV seria capaz de medir (seção 2.2) e também o L/Q de cada roda do truque dianteiro.

A partir desse conjunto de dados, é feito a análise exploratória de dados (caixas azuis - 6.1.1 seção), explicabilidade do modelo (caixas roxas - seção 6.2.1) e o modelo de aprendizado de máquina é criado (seção 6.2.2). O modelo de aprendizado de máquina busca achar a função que melhor correlaciona os dados de entrada (variáveis do IRV) com os de saída (L/Q). Após o treinamento, o modelo é validado de acordo com sua capacidade de correlacionar dados nunca vistos (dados de teste).

Finalmente, os resultados envolvem a comparação entre diferentes modelos de ML em termos de sua precisão e taxa de amostragem.

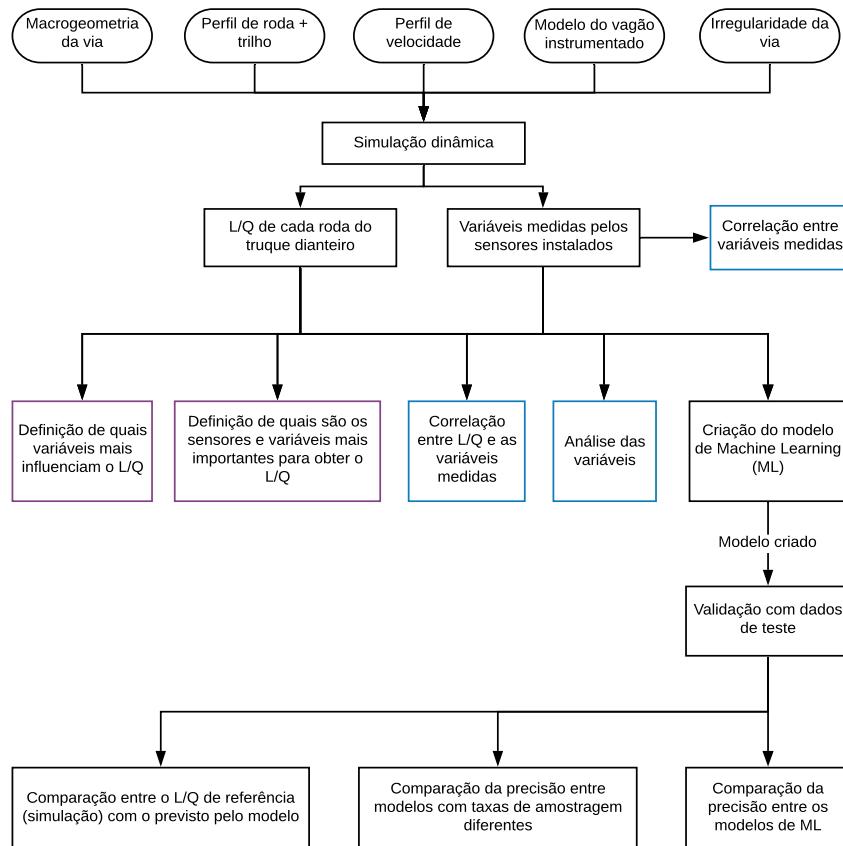


Figura 11 – Fluxograma do processo

5 Simulação Dinâmica

5.1 Modelo do vagão instrumentado

Para conseguir examinar a dinâmica de um veículo, ele primeiro deve ser descrito como um modelo mecânico ([KNOTHE; STICHEL, 2017](#)). Softwares como o *ADAMS RAIL*, *GENSYS*, *SIMPACK*, *VAMPIRE*, *UNIVERSAL MECHANISM* não só facilitam o trabalho do engenheiro na formulação e solução das equações de movimento, mas também ajudam no pós-processamento para calcular variáveis importantes para julgar o conforto e as forças da interface roda-trilho. A figura 12 mostra o vagão GDE enquanto que a figura 13 possui mais detalhes sobre os componentes do truque.

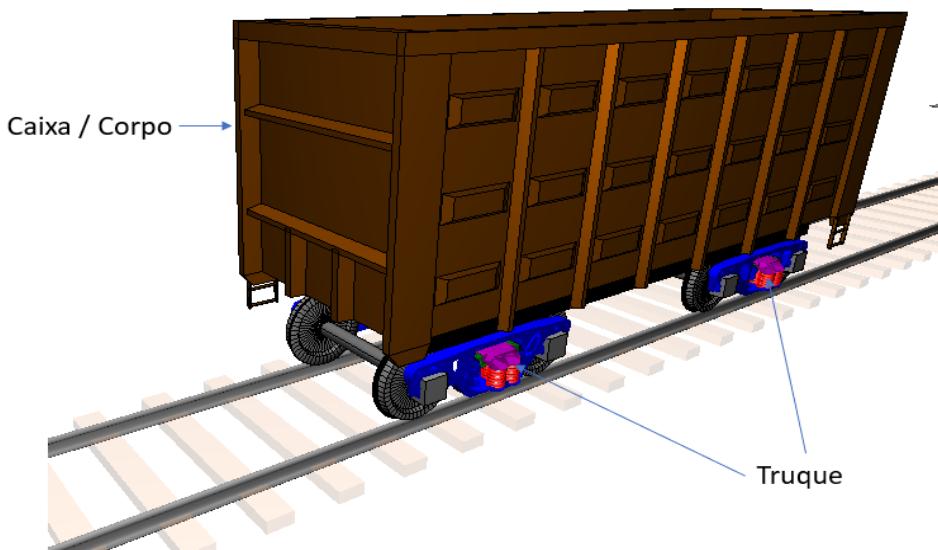


Figura 12 – Componentes do vagão GDE

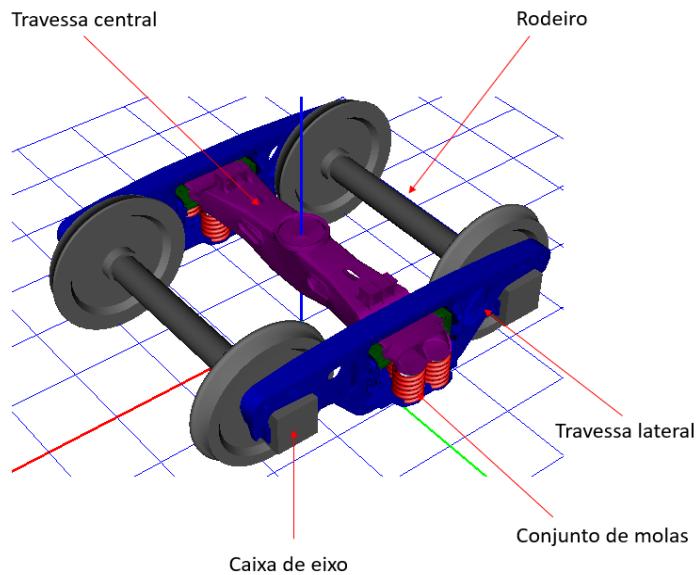


Figura 13 – Principais constituintes do truque

O vagão GDE utilizado é composto por uma caixa, dois truques e quatro rodeiros rígidos. Entre a caixa e o truque, uma suspensão secundária é instalada e entre o truque e os rodeiros, existe uma suspensão primária. Ambas as suspensões consistem de ligações entre os elementos por molas e amortecedores. Como um vagão instrumentado é um vagão de serviço com sensores e a ferrovia BRA1 utiliza o modelo GDE com *padding* (possui um), é possível utilizar um modelo GDE e obter as variáveis pelo *software*, o que representaria aquelas obtidas na realidade.

Para contextualizar, um vagão é normalmente modelado como tendo seis graus de liberdade ou modos de oscilação ([KNOTHE; STICHEL, 2017](#)), ilustrado na figura 14. São três modos de translação: longitudinal, vertical ou galope (bounce) e lateral (sway), e três de rotação: rolagem (roll), arfagem (pitch) e guinada (yaw). Segundo [SILVA \(2019\)](#), os modos de translação são facilmente estimados pelos dados de aceleração e velocidade nos determinados eixos pelos sensores como acelerômetro e giroscópio.

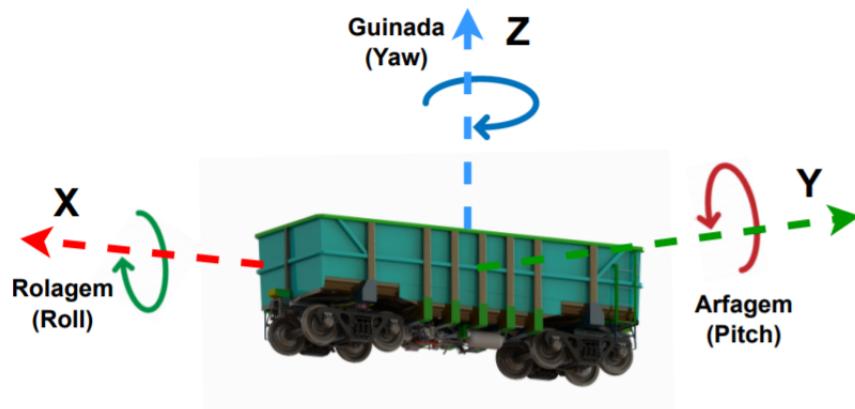


Figura 14 – Seis graus de liberdade de um vagão ferroviário

A ferrovia BRA1 já utiliza um vagão instrumentado cuja instrumentação pode ser descrita como possuindo os seguintes sensores:

- Acelerômetro triaxial na caixa;
- Acelerômetro uniaxial da travessa lateral alinhado com a linha de centro do rodeiro dianteiro;
- Célula de carga para medir o deslocamento vertical da suspensão secundária;
- Haste instrumentada para medição das forças do engate entre vagões;
- Pressão da linha de freio;
- GPS.

Os autores ([DARBY et al., 2005](#); [COWIE et al., 2015](#); [HARDIE et al., 2016](#); [THOMPSON et al., 2016](#)) mostraram nos seus respectivos trabalhos os benefícios e as maneiras de visualizar os dados medidos pelos vagão instrumentado, além de uma descrição detalhada dos sensores e sua posição no vagão. Para efeito de comparação, todas os sensores citados acima existem nos vagões desses quatro autores, no entanto, alguns vagões possuem mais sensores como *IMUs*, que são capazes de medir *roll*, *pitch*, *yaw* do truque e também superelevação e torção da via através de um modelo matemático. [Hardie et al. \(2016\)](#) criaram um modelo para obter o valor das irregularidades verticais a partir do acelerômetro vertical da caixa de eixo.

É possível afirmar então que o vagão instrumentado GDE real não mede todas as variáveis possíveis, no entanto, é possível obter todas essas variáveis no modelo virtual já que não depende da instalação física. Baseado no discutido na seção 2, a simulação dinâmica fornecerá as seguintes variáveis do truque dianteiro:

- Aceleração Y e Z da caixa;
- Aceleração Y e Z da travessa lateral;
- Aceleração Y e Z da caixa de eixo;
- *Roll* e *Pitch* do truque;

- Deslocamento da suspensão secundária;
- L/Q das quatro rodas do truque dianteiro.

5.1.1 Posição dos sensores

O sensor virtual do UM é descrito como um ponto com coordenadas parametrizadas relativo a algum corpo rígido. Durante a simulação, o usuário obtém o valor das características cinemáticas de um ponto do corpo como posição, velocidade e aceleração. A principal vantagem é que a posição desse sensor com relação ao sistema de coordenadas do corpo pode ser parametrizado por expressões. Então a posição do sensor é alterada ao mudar o identificador correspondente. As posições dos sensores foram baseados no desenho técnico do vagão instrumentado GDE.

É importante destacar que as variáveis que servirão de entrada para o modelo de ML pode ser classificadas em dois tipos: variáveis reais e variáveis virtuais (ou adicionais). Variáveis reais são aquelas que o vagão instrumentado BRA1 consegue de medir com sua instrumentação. Variáveis virtuais são aquelas que um IRV é capaz de medir, mas o BRA1 não mede devido à falta de instrumentação necessária. Apesar disso, é possível obter essas variáveis virtualmente pela simulação. Um exemplo de sensor que não tem no BRA1 é o IMU, que forneceria os giros do truque em torno dos eixos X, Y e Z.

A figura 15 mostra a localização do sensor onde estariam os acelerômetros lateral e vertical da caixa de eixo enquanto que a figura 18 mostra um exemplo real utilizado no trabalho de (GÓMEZ et al., 2020). Apesar desses sensores não existirem no vagão instrumentado GDE real, as variáveis podem ser geradas artificialmente pela simulação e utilizado no modelo de ML justamente para ver se são importantes para a determinação do L/Q. Sendo específico, as variáveis medidas pelos acelerômetros da caixa de eixo:

1. Rodeiro 1 (dianteiro)
 - Roda esquerda e direita: aceleração vertical e lateral;
2. Rodeiro 2
 - Roda esquerda e direita: aceleração vertical e lateral.

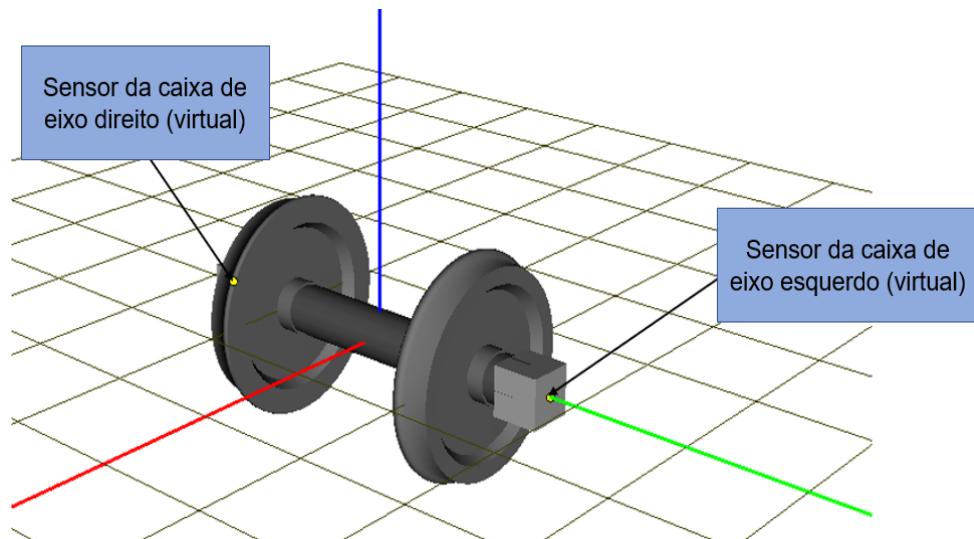


Figura 15 – Posição dos sensores da caixa de eixo

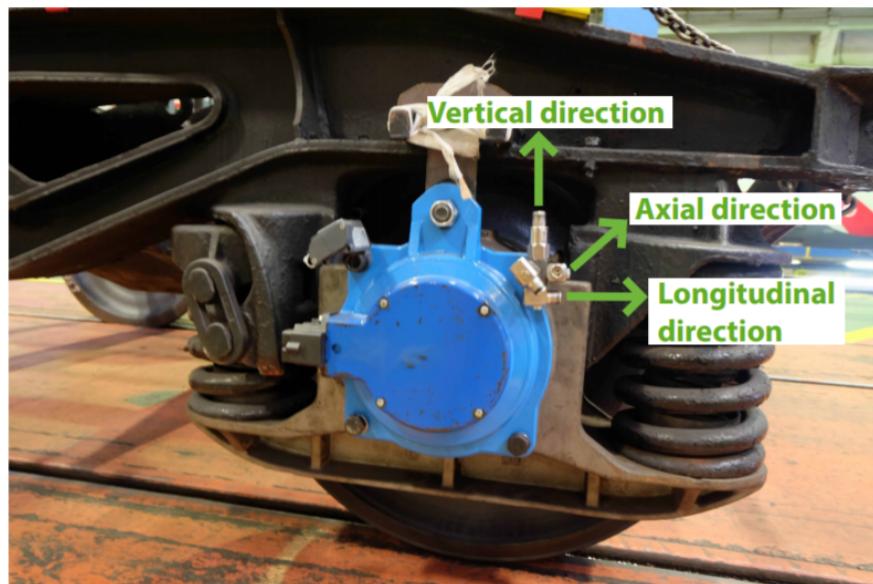


Figura 16 – Exemplo de instalação de sensores na caixa de rolamento do rodeiro - (GÓMEZ et al., 2020)

A figura 17 mostra a posição dos sensores que estariam na travessa lateral do truque e a figura 18 mostra um exemplo real. É possível ver a existência de dois acelerômetros, no entanto, apenas o mais próximo do rodeiro 1 existe no vagão BRA1 real. Foi criado um sensor virtual próximo do rodeiro 2 para verificar se essa mudança de posição afetaria o resultado do modelo de ML. As variáveis medidas por esses sensores são:

1. Travessa lateral esquerda

- Acelerômetro real (rodeiro 1): aceleração vertical e lateral;
- Acelerômetro virtual (rodeiro 2): aceleração vertical e lateral;

2. Travessa lateral direita

- Acelerômetro real (rodeiro 1): aceleração vertical e lateral;
- Acelerômetro virtual (rodeiro 2): aceleração vertical e lateral.

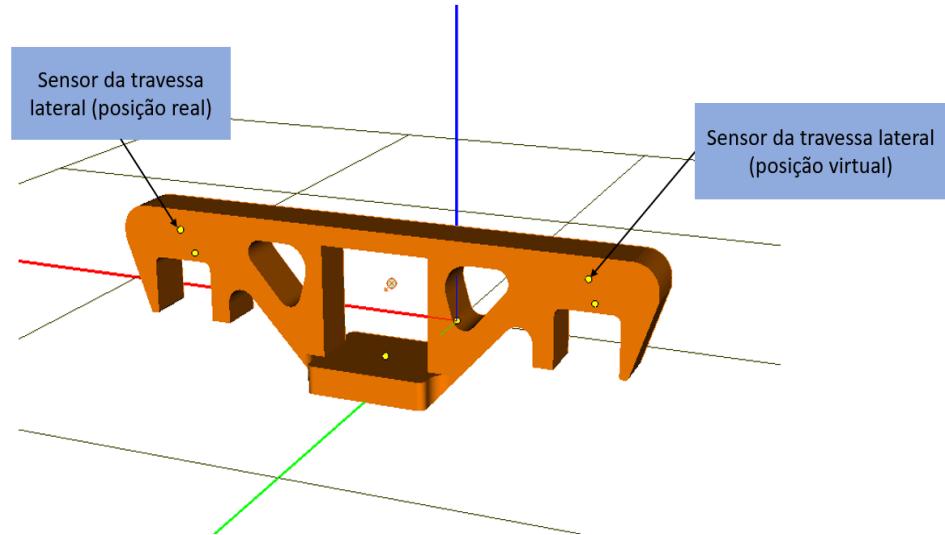


Figura 17 – Posição dos sensores da travessa lateral

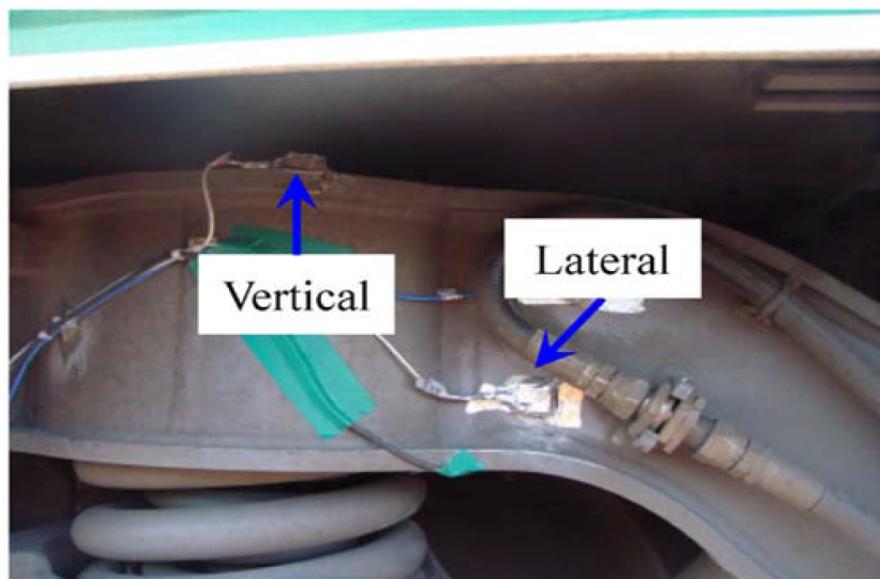


Figura 18 – Exemplo de posicionamento dos acelerômetros na travessa lateral - (LEE et al., 2011b)

A figura 19 mostra a posição do acelerômetro triaxial da caixa. Foi utilizado os componentes Y e Z desse sensor.

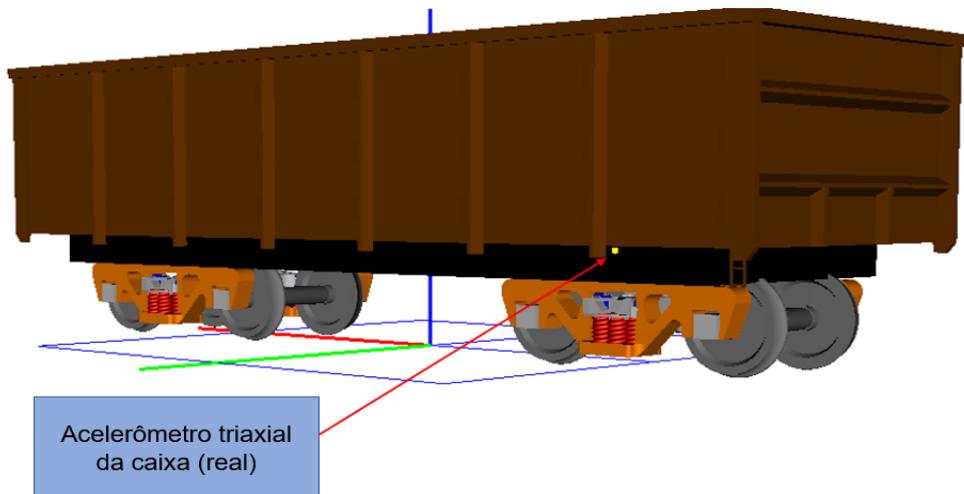


Figura 19 – Posição do acelerômetro triaxial da caixa do vagão

Nenhum componente X de aceleração foi utilizado pois ele é insensível a curvatura da via, permanecendo assim em valores muito baixos.

5.2 Macrogeometria da via

A geometria dos trechos curvos no ambiente de simulação deve ser descrita conforme a figura 20, onde:

- L = Comprimento do trecho tangente, se existir (m);
- P = Comprimento da região de transição tangente-curva (m);
- S = Comprimento da curva de raio constante (m);
- R = Raio da curva (m);
- h = Superelevação (mm)
- O subscrito 0 se refere ao trecho inicial;
- O subscrito 1 refere-se a uma curva à direita enquanto o 2 refere-se à esquerda.

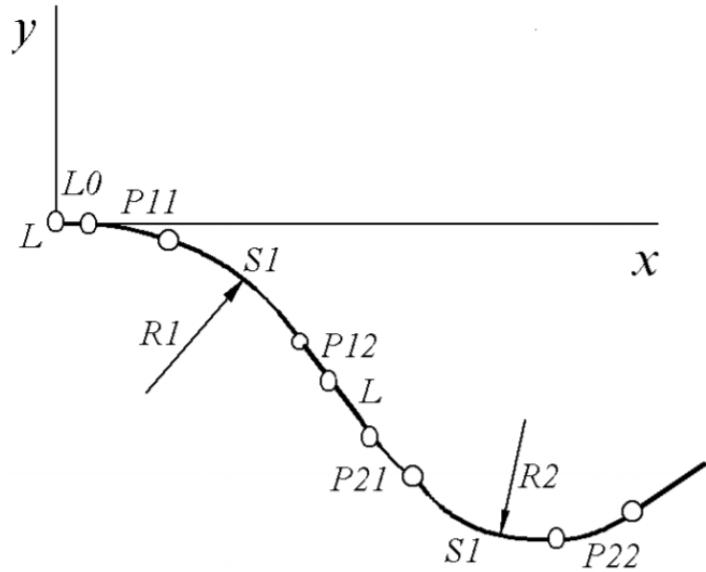


Figura 20 – Descrição dos parâmetros que compõem a curva - ([LOCOMOTIVES, 2019](#))

A macrogeometria utilizada na simulação foi criada a partir de um arquivo excel que possui a planta da linha BRA1. Os engenheiros da BRA1 sugeriram como primeiro teste utilizar a linha tronco número um. Nessa linha, foi utilizado o quilômetro 43,536 até 49,802, totalizando 6,266 km de via. Consta na planta da linha o tipo de curva, valor do raio, grau e superelevação, no entanto, não tem o comprimento da transição. Após conversa com os engenheiros de via da BRA1, foi sugerido multiplicar o grau da via por 20 como estimativa da transição da via. A tabela 7 mostra os parâmetros utilizados na criação da macrogeometria enquanto que a figura 21 mostra a curvatura da via.

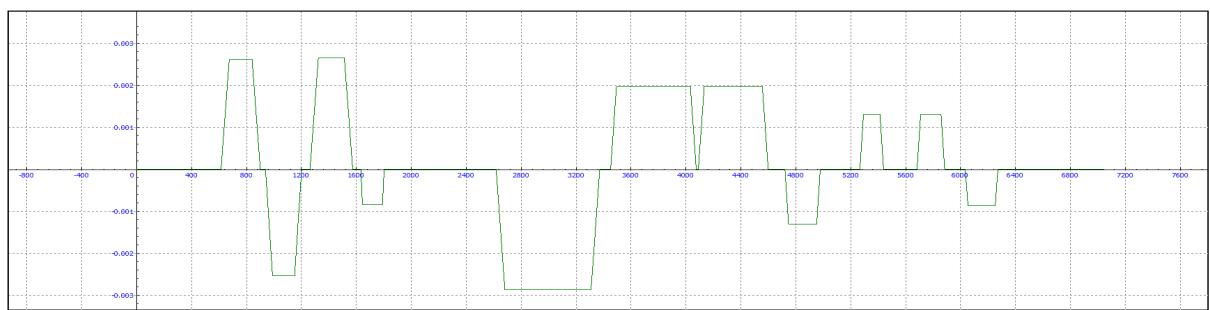


Figura 21 – Curvatura da macrogeometria da via

5.3 Perfil de roda + trilho

O perfil de roda usado é o TTCI enquanto o de trilho é o TR68. Ambos os perfis utilizados são novos pois o objetivo é verificar se é possível obter as forças do rodeiro através das variáveis típicas medidas pelo vagão instrumentado.

Para aplicações mais próximas da realidade, é importante verificar o impacto que o

Nº	Raio (m)	Orientação	P (m)	S (m)	h (mm)	Grau (°)
1	0	Tangente	0	614	0	0.00
2	381.99	Esquerda	60	166	49	3.00
3	0	Tangente	0	38	0	0.00
4	395.16	Direita	51	161	48	2.54
5	0	Tangente	0	61	0	0.00
6	375.72	Esquerda	61	189	50	3.03
7	0	Tangente	0	59	0	0.00
8	1185.48	Direita	12	146	16	0.58
9	0	Tangente	0	816	0	0.00
10	349.02	Direita	63	628	54	3.17
11	0	Tangente	0	79	0	0.00
12	505.57	Esquerda	43	538	37	2.16
13	0	Tangente	0	15	0	0.00
14	505.57	Esquerda	43	423	37	2.16
15	0	Tangente	0	122	0	0.00
16	763.97	Direita	26	205	25	1.30
17	0	Tangente	0	289	0	0.00
18	763.97	Esquerda	26	120	25	1.30
19	0	Tangente	0	244	0	0.00
20	763.97	Esquerda	26	149	25	1.30
21	0	Tangente	0	150	0	0.00
21	1145.96	Direita	20	198	16	1.00
22	0	Tangente	0	765	0	0.00

Tabela 7 – Macrogeometria da via

desgaste da roda ou trilho possui na medição.

5.4 Perfil de velocidade

O vagão executou a trajetória com uma velocidade constante de 65 km/h. Para uma simulação mais realística, seria necessário utilizar um perfil de velocidades do vagão instrumentado real, no entanto, não foi fornecido essa informação antes da conclusão deste trabalho.

5.5 Irregularidades da via

Modelando as irregularidades como sendo estocásticas (ou randômicas), é possível descrever o seu conteúdo no domínio da frequência através da densidade espectral de potência do sinal ou *power spectral density* (PSD) em inglês. O PSD é muito utilizado para descrever as irregularidades (GARG, 2012; BERAWI, 2013; FRÝBA, 1996; LOCOMOTIVES, 2019).

A palavras em inglês utilizadas na sigla PSD descrevem bem cada componente que compõe a análise. A sigla *P* representa potência e é possível afirmar que a potência instantânea de um sinal é proporcional ao sinal elevado ao quadrado. Um exemplo disso é que a potência é proporcional ao quadrado da corrente ou voltagem em um circuito elétrico. Não é de interesse ter um valor instantâneo para descrever a potência do sinal e sim um valor mais global, então é feito uma média do sinal em um intervalo de tempo, obtendo a potência média do sinal, considerando a constante de proporcionalidade igual a 1. É importante frisar que essa potência não se refere à quantidade física medida em watts.

A sigla *S* se refere ao *spectrum* ou espectro do sinal. A definição de espectro é a distribuição da amplitude e fase do sinal em termos da frequência, ou seja, o gráfico apresentará essas informações.

A sigla *D* se refere a densidade no seu conceito probabilístico. A magnitude da distribuição frequencial depende do número de bandas da distribuição. Quanto menor a largura de banda, maior o número de bandas, ou seja, uma largura de 3Hz terá mais bandas que uma largura de 12Hz e isso afetará o espectro do sinal. Para corrigir esse dependência existente, o PSD divide a potência média pela largura da banda ou taxa de amostragem, obtendo assim um valor independente (VRU, 2019). Pode-se dizer também que a magnitude do PSD foi normalizada para um filtro de espessura igual a 1Hz. Quanto maior o valor do PSD, pior a qualidade da pista (BERAWI, 2013).

Vários países como os Estados Unidos, China, França e Alemanha já modelaram o espectro de irregularidades do seu respectivo país. Cada padrão de PSD possui diferentes características como a velocidade e comprimento de onda de interesse (BERAWI, 2013). Essas funções obtidas com dados medidos geralmente já são filtradas e suavizadas por métodos estatísticos, como consequência, elas representam uma informação média das irregularidades (FRÝBA, 1996). Mais informações sobre os tipos de PSD usados com comparações podem ser vistos no trabalho de (BERAWI, 2013). Dado a fórmula matemática do espectro das irregularidades, é possível realizar um processo inverso para obter as irregularidades artificiais no domínio do tempo. O software UM realiza exatamente esse procedimento.

A ferrovia BRA1 possui características muito parecidas com a da FRA (Federal Railroad Administration) dos Estados Unidos, então este critério foi o utilizado. A FRA

utiliza nove classes para descrever a qualidade da ferrovia (primeira classe é o pior caso enquanto a nona classe é o melhor caso) ([LOCOMOTIVES, 2019](#)). As primeiras cinco classes (1 a 5) correspondem a ferrovias de velocidade normal, e as últimas (6 a 9) são usadas para estradas de alta velocidade, com velocidade acima de 145 km/h para trens de passageiros e acima de 130 km/h para trens de carga.

As funções PSD das primeiras 6 classes (1,2...6) estão descritos pelas equações (5.1), (5.2) e (5.3). A equação (5.1) representa a PSD da meia soma das irregularidades horizontais para os trilhos direito e esquerdo enquanto a equação (5.2) representa a PSD da meia soma das irregularidades verticais para ambos os trilhos. Já a equação (5.3) descreve a função PSD da meia diferença tanto para as irregularidades horizontais e verticais de ambos os trilhos.

$$\Phi(\Omega) = k * \frac{A_a * \Omega_c^2}{\Omega^2 * (\Omega^2 + \Omega_c^2)}, \quad \Omega > 0 \quad (5.1)$$

$$\Phi(\Omega) = k * \frac{A_v * \Omega_c^2}{\Omega^2 * (\Omega^2 + \Omega_c^2)}, \quad \Omega > 0 \quad (5.2)$$

$$\Phi(\Omega) = k * \frac{4 * A_v * \Omega_c^2}{(\Omega^2 + \Omega_c^2) * (\Omega^2 + \Omega_s^2)}, \quad \Omega > 0 \quad (5.3)$$

Nas equações acima, $\Omega = 2\pi/\lambda_r$ [rad/m] denota a frequência espacial, λ_r o comprimento de onda da irregularidade [m], $k = 0,25$, $A_v[\text{cm}^2.\text{rad}/\text{m}]$, $A_a[\text{cm}^2.\text{rad}/\text{m}]$, Ω_c [rad/m] e Ω_s [rad/m] são parâmetros dados pela tabela 8. De posse dessa tabela e sabendo que a velocidade nominal do vagão é de aproximadamente 65 km/h, as classes 3 até 6 foram utilizadas, igual ao trabalho de ([VAZ et al., 2018](#)).

Classe	Velocidade máxima (km/h)			Parâmetros		
	Transporte de carga	Passageiro	A_v ($\text{cm}^2.\text{rad}/\text{m}$)	A_a ($\text{cm}^2.\text{rad}/\text{m}$)	Ω_c^2 (rad/m)	Ω_s^2 (rad/m)
1	16	24	1,2107	3,3634	0,6046	0,8245
2	40	48	1,0181	1,2107	0,9308	0,8245
3	64	97	0,6816	0,4128	0,852	0,8245
4	97	129	0,5376	0,3027	1,1312	0,8245
5	129	145	0,2095	0,0762	0,8209	0,8245
6		177	0,0339	0,0339	0,4380	0,8245

Tabela 8 – Parâmetros da função PSD para diferentes classes de via - ([BERAWI, 2013](#)) modificado

Para criar as irregularidades no UM, é necessário especificar manualmente qual o método baseado no espectro, a classe desejada, o valor do escalar k , o limite superior e inferior do comprimento da irregularidade (λ_r), e o número de harmônicos. Neste trabalho, utilizou-se as seguintes informações:

- Fórmula do espectro = FRA;

- Classe das irregularidades = 6;
- Valor do fator $k = 0,25$;
- Limite superior de 25m e inferior de 3m (tabela da seção 3.4.1 - D1);
- Número de harmônicos = 3000 (default do software);
- Extensão = 6.266 km.

Ao inserir essas informações como entrada no software, o UM aplica as equações referentes às irregularidades no domínio da frequência obtendo como saída os arquivos contendo as irregularidades laterais e verticais que servirão de entrada para a simulação.

6 Machine Learning

O aprendizado de máquina (*Machine Learning* - ML) é o campo de estudo que fornece aos computadores a habilidade de aprenderem sem serem programados explicitamente (GÉRON, 2019). Esses algoritmos são capazes de gerar modelos matemáticos através de um conjunto de dados com o objetivo de realizar previsões, decisões ou identificar padrões e comportamentos existentes nos dados.

Atualmente, as ferrovias coletam quantidades enormes de dados através de veículos de inspeção, sistemas de monitoramento e inspeções visuais (ATTOH-OKINE, 2017). Por conta do desenvolvimento de sensores cada vez mais avançados e da tecnologia da informação, a tendência é que a quantidade de dados coletados seja cada vez maior. Isso contribui para a existência de coleções de dados tão grandes que é impossível fazer análises e inferências, também chamado de *Big Data* (ATTOH-OKINE, 2014). Para a implementação do vagão instrumentado real, será necessário desenvolver estratégias para lidar com o *Big Data* além de definir uma taxa de amostragem ideal (seção 2.3). No caso da simulação, a quantidade de dados é pequeno e é possível definir a taxa de amostragem através do passo do *solver*.

Um projeto típico de aprendizado de máquina para modelagem preditiva pode ser visto conforme a figura 22. Os dados brutos da simulação são importados para o *Python*, onde é feito o pré-processamento dos dados para depois dividí-los em um conjunto dados de treino e teste. Cada conjunto possui variáveis do vagão instrumentado e o respectivo L/Q. Um algoritmo de aprendizado de máquina é treinado primeiramente com os dados de treino. Depois este modelo é validado a partir de dados nunca vistos, ou seja, os dados de teste. Com isso, é possível comparar a saída do modelo de aprendizado de máquina com a referência através de uma métrica de avaliação (seção 6.2).

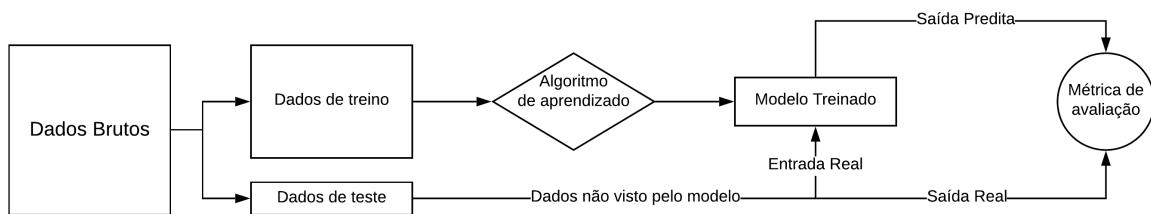


Figura 22 – Etapas para execução de um modelo de aprendizagem de máquina

6.1 Pré-processamento dos dados

Na maioria dos casos, os conjuntos de dados recebidos para análise são brutos. É necessário fazer um pré-processamento para eliminar possíveis erros ou incoerências nos dados a fim de garantir a precisão e confiança nos modelos aprendizado de máquina. As ações que foram realizadas nessa etapa foram:

1. **Limpeza dos dados:** eliminar erros, aplicar filtros e remover informações desnecessárias no conjunto de dados bruto;
2. **Análise exploratória dos dados:** investigações iniciais sobre os dados a fim de descobrir padrões, detectar anomalias, testar hipóteses e verificar hipóteses estatísticas.

No caso da limpeza dos dados, observou-se um grande pico no início da simulação causado pela computação do equilíbrio estático. Os 5 primeiros dados foram removidos nesse caso.

6.1.1 Análise exploratória dos dados (AED)

Analistas de dados usam técnicas para explorar os dados antes de qualquer análise formal e modelagem a fim de detectar ou explorar comportamentos interessantes como, por exemplo, anomalias no conjunto de dados ([ATTOH-OKINE, 2017](#)). Informações como a distribuição dos dados e o desvio padrão são críticos.

A tabela 9 mostra a descrição dos parâmetros utilizados nos modelos, conforme definido nas seções 5.1 e 5.1.1, assim como alguns parâmetros estatísticos.

Tipo	Localização	Sensor	Variável	Média	Desvio padrão	Valor Máximo	Valor Mínimo
Real	Travessa Lateral	Aceleração Vertical Rodeiro 1 Esquerdo	z_r1_esq_real	0.014006	0.469942	17.866680	-12.250832
		Aceleração Vertical Rodeiro 1 Direito	z_r1_dir_real	0.014272	0.438773	19.209372	-11.528461
		Aceleração Vertical Rodeiro 2 Esquerdo	z_r2_esq	0.013852	0.425356	13.624756	-10.251805
		Aceleração Vertical Rodeiro 2 Direito	z_r2_dir	0.015081	0.441424	12.139716	-13.511668
		Aceleração Lateral Rodeiro 1 Esquerdo	y_r1_esq	0.023808	0.597162	10.742339	-8.770859
		Aceleração Lateral Rodeiro 1 Direito	y_r2_esq	0.027407	0.610559	9.420689	-15.134421
		Aceleração Lateral Rodeiro 2 Esquerdo	y_r1_dir	0.028829	0.585036	9.977056	-9.402102
		Aceleração Lateral Rodeiro 2 Direito	y_r2_dir	0.028759	0.601546	15.830776	-11.126881
Virtual	Caixa	Aceleração Lateral	triaxial-y	0.025858	0.458494	-1.220729	1.064237
		Aceleração Vertical	triaxial-z	0.011876	0.058824	-0.261632	0.293802
	Truque 1	Deslocamento esquerdo da suspensão secundária	s1_mola1	-0.000024	0.000664	-0.003223	0.003077
		Deslocamento direito da suspensão secundária	s1_mola2	-0.000057	0.000652	-0.002879	0.002939
	Truque 2	Deslocamento esquerdo da suspensão secundária	s2_mola1	0.000006	0.000582	-0.002470	0.001905
		Deslocamento direito da suspensão secundária	s2_mola2	-0.000018	0.000579	-0.002154	0.002373
Virtual	Caixa de Eixo	Aceleração Lateral Rodeiro 1 Esquerdo	y_eixo_r1_esq	0.025170	0.466620	1.770769	-1.631845
		Aceleração Vertical Rodeiro 1 Esquerdo	z_eixo_r1_esq	-0.042693	1.031058	26.492109	-14.329530
		Aceleração Lateral Rodeiro 1 Direito	y_eixo_r1_dir	0.026506	0.466371	1.773849	-1.631454
		Aceleração Vertical Rodeiro 1 Direito	z_eixo_r1_dir	0.067333	0.982803	12.698752	-9.687345
		Aceleração Lateral Rodeiro 2 Esquerdo	y_eixo_r2_esq	0.025667	0.463452	1.757522	-5.738002
		Aceleração Vertical Rodeiro 2 Esquerdo	z_eixo_r2_esq	-0.044313	0.991893	12.040787	-15.390460
		Aceleração Lateral Rodeiro 2 Direito	y_eixo_r2_dir	0.027000	0.463193	1.758673	-5.733393
		Aceleração Vertical Rodeiro 2 Direito	z_eixo_r2_dir	0.072107	1.149081	64.180527	-38.361023
	Truque	Roll	roll	-0.001766	0.025913	0.051627	-0.047292
		Pitch	pitch	-0.000360	0.008234	0.023629	-0.033417
L/Q	L/Q	Rodeiro 1 Esquerdo	L/Q_1_esq	0.071493	0.056200	0.206511	-0.004122
		Rodeiro 1 Direito	L/Q_1_dir	0.069397	0.056098	0.243229	-0.002365
		Rodeiro 2 Esquerdo	L/Q_2_esq	0.023877	0.034305	0.156683	-0.044507
		Rodeiro 2 Direito	L/Q_2_dir	0.026996	0.032177	0.141985	-0.061818

Tabela 9 – Descrição dos sensores e parâmetros estatísticos calculados após a simulação dinâmica

As figuras 23, 24 e 25 mostram alguns dos dados plotados adquiridos na simulação com irregularidades, onde é comparado a taxa de aquisição de 100 Hz em azul com o de 1 Hz em vermelho. Visto a grande quantidade de variáveis, algumas das visualizações estão no corpo deste trabalho enquanto que os outros estarão disponíveis nos anexos. No caso da figura 24, o *roll* e *pitch* para ambas as taxas não apresentam ruído visto a modelagem do giroscópio realizado, no entanto, é esperado esse ruído na prática.

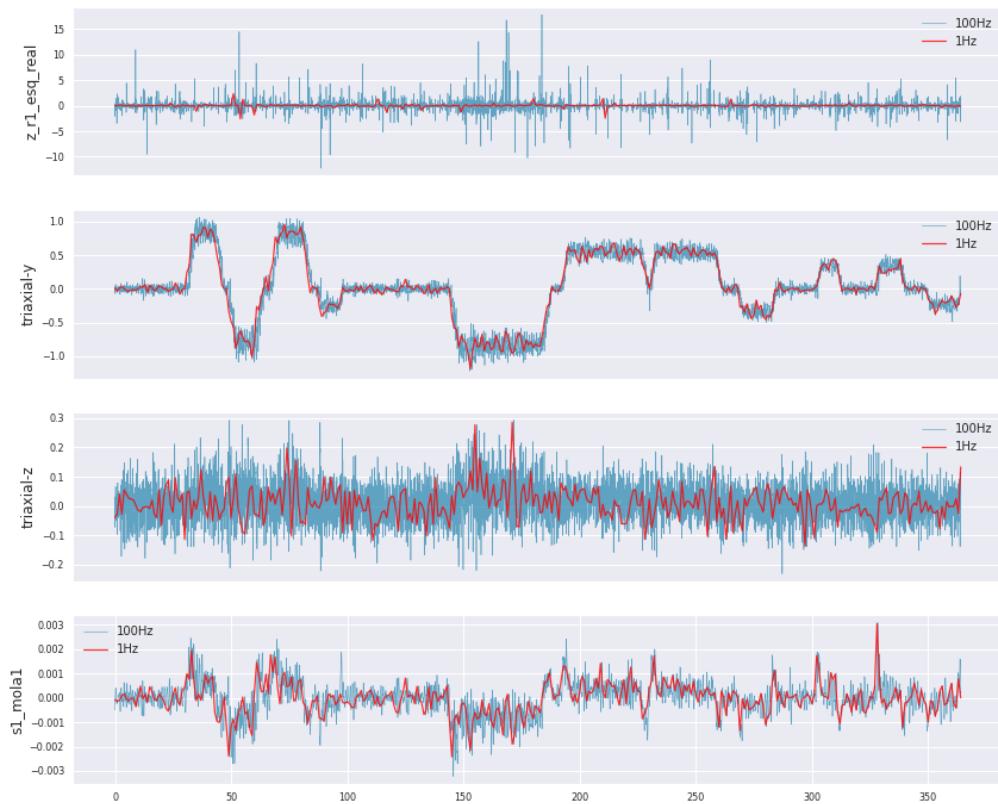


Figura 23 – Variáveis medidos pelos sensores reais

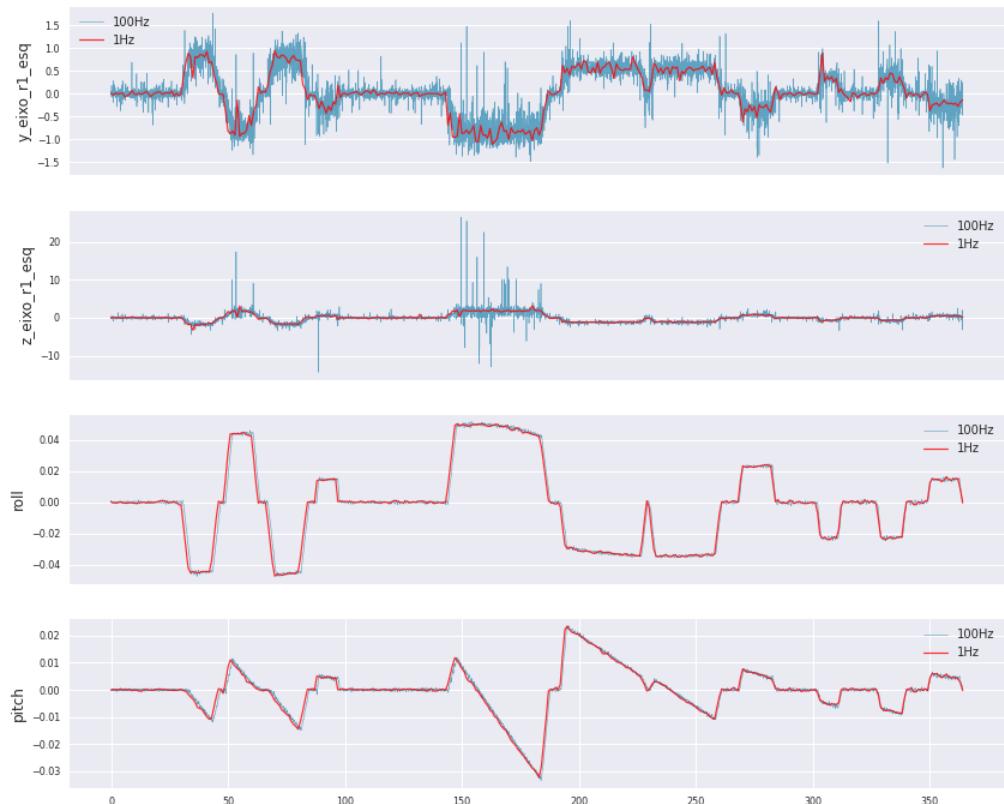


Figura 24 – Variáveis medidos pelos sensores virtuais

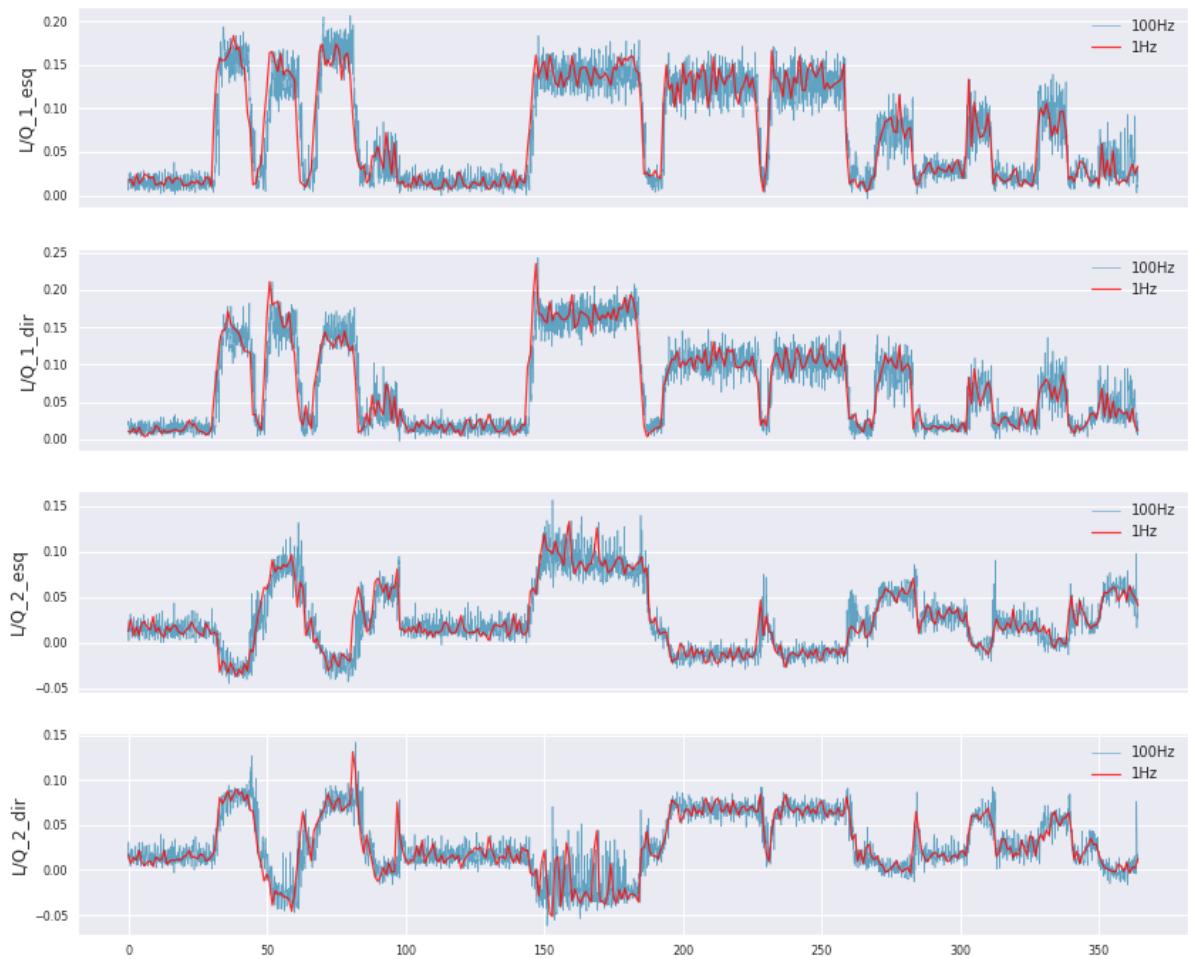


Figura 25 – Valores do L/Q

Sabendo que uma taxa de aquisição de 100 Hz representa melhor a realidade do que o de 1 Hz visto a maior resolução, é possível tirar três conclusões importantes:

- A taxa de 1 Hz consegue acompanhar o comportamento médio dos dados de 100 Hz;
- A taxa de 1 Hz subestima o valor das variáveis medidas comparado com os de 100 Hz;
- A taxa de 1 Hz tem mais dificuldades para detectar os picos de alta frequência das variáveis visto sua menor resolução.

A expressão inglesa *garbage in, garbage out* (lixo entra, lixo sai) resume bem a ideia de que os dados de entrada tem que corresponder com a realidade e suficientemente tratados. Altas taxas de amostragem tendem a representar a situação real da via com maior confiança, ou seja, se esses dados forem alimentados para o modelo de aprendizado de máquina, a saída também seria representativo da ferrovia. Se fosse utilizado a taxa de 1 Hz, os dados de entrada do modelo não representariam bem a situação da via pois não capta bem as informações de alta frequência comparado ao de 100 Hz. Nesse caso, existe o risco do modelo ser alimentado com lixo e a saída não fazer sentido.

É possível afirmar então que, apesar da taxa de 1 Hz acompanhar a tendência dos dados de 100 Hz, ela não é capaz de fornecer os valores mais críticos e realistas de L/Q. Isso é confirmado observando os picos de L/Q que a taxa de 1 Hz subestima na figura 25. Outras desvantagens que advém de uma taxa de aquisição baixa já foram discutidas na seção 2.3.

A figura 26 mostra os histogramas das variáveis das figuras 23 e 24, sendo que a primeira linha são os sensores reais, enquanto que a segunda linha são os sensores virtuais.

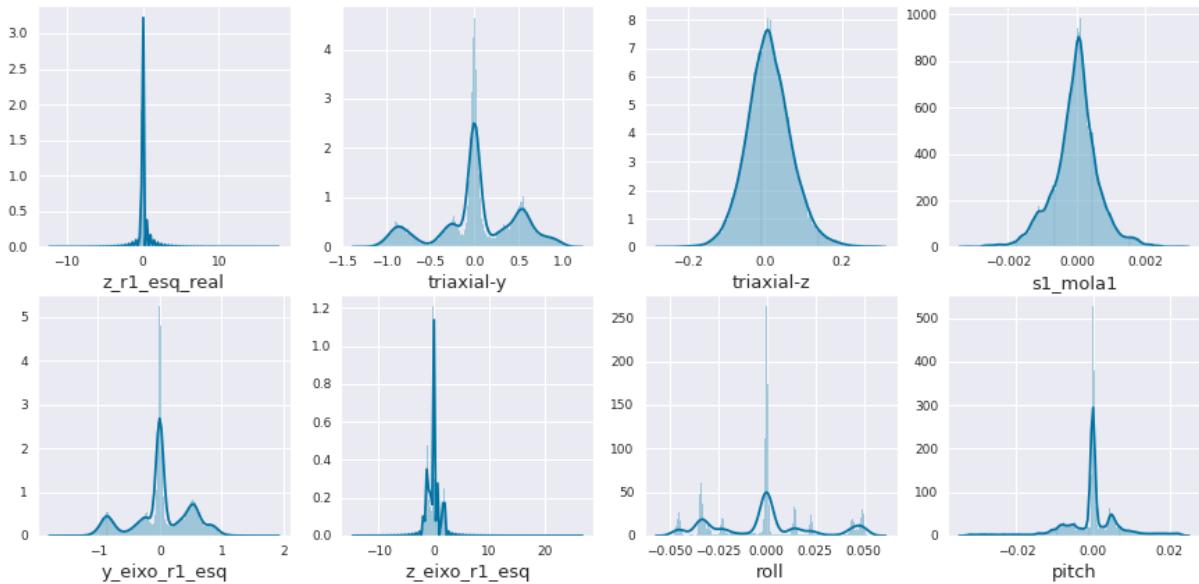


Figura 26 – Histograma dos sensores reais e virtuais

É observado que todas as distribuições apresentam média da distribuição próxima de zero (trecho tangente). No caso dos sensores que correspondem aos movimentos laterais (y_eixo_r1_esq, triaxial-y, roll) apresentam outros picos na distribuição, na qual ocorrem devido ao vagão assumindo uma posição diferente durante a execução das curvas, assim, apresenta-se um valor médio diferentes nessas curvas, o que causa uma distribuição não-gaussiana. Já os sensores que correspondem aos movimentos verticais (z_r1_esq_real, z_eixo_r1_esq, triaxial-z, pitch, s1_mola1) seguem uma distribuição normal. Entretanto, as gaussianas dessas variáveis são diferentes devido ao efeito de filtro que as suspensões possuem. Isso pode ser observado na variável triaxial-z e s1_mola1 que está acima de ambas as suspensões enquanto que o sinal de z_r1_esq_real e z_eixo_r1_esq é filtrado apenas pela suspensão primária.

A figura 27 mostra o *boxplot* das variáveis das figuras 23 e 24. Esta visualização é utilizado para detectar valores discrepantes (*outliers*) nos dados extraídos e pode ser interpretado como uma outra maneira de visualizar o histograma.

Essa visualização resume os dados em cinco números estatísticos: o mínimo, o primeiro quartil (Q1), a mediana, o terceiro quartil (Q3) e o máximo. A altura do retângulo

é definida pelos quartis Q1 e Q3 e representa 50% do conjunto de dados. As semirretas ligam respectivamente os quartis Q1 e Q3 ao valor mínimo e ao máximo do conjunto de dados. Os dados que não se encontram dentro das semirretas são considerados dados discrepantes e devem ser melhor estudados. Quando é possível comprovar que os dados discrepantes não possuem significado físico, isto é, são causados provavelmente por um erro de medição ou gravação, recomenda-se que eles sejam corrigidos ou deletados ([ATTOH-OKINE, 2017](#)). Caso contrário, eles devem ser mantidos, a não ser que não seja interessante para aplicações futuras considerar aquela situação. No caso deste trabalho, eles foram mantidos.

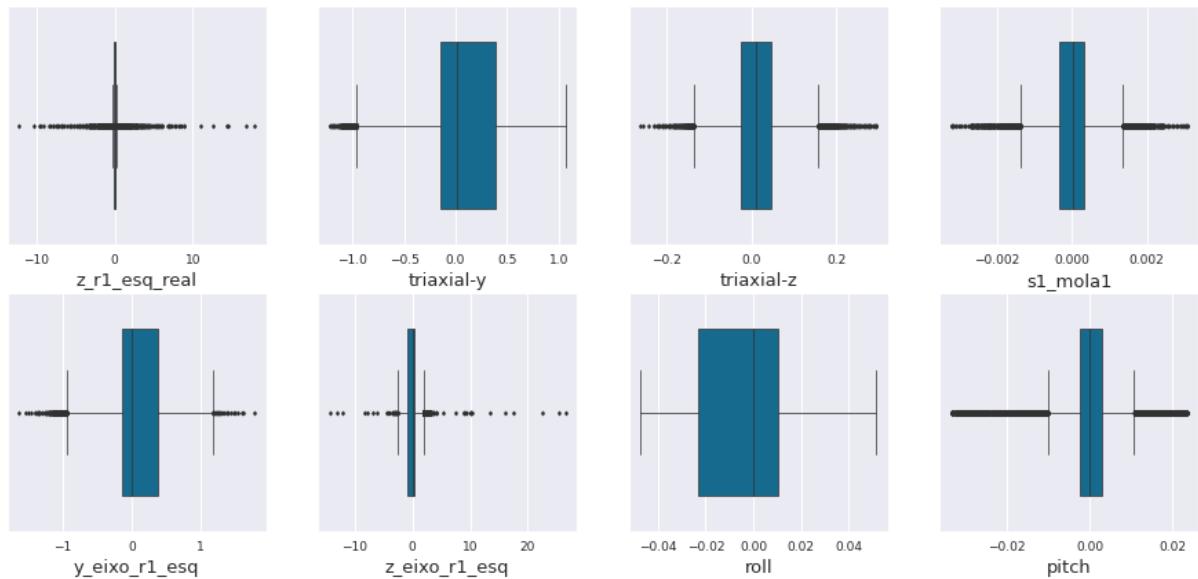


Figura 27 – Boxplot dos sensores reais e virtuais

Observa-se a diferença do *boxplot* dos sensores verticais devido ao efeito de filtro das suspensão secundária, como explicado no caso da figura [26](#). Os sensores abaixo das suspensões possuem muitos *outliers* devido à maior vibração (*z_r1_esq_real*), e os parâmetros dos sensores acima dessa suspensão possuem poucos pontos fora da distribuição. É importante frisar que utilizou-se todos os valores das variáveis neste trabalho.

É verificado a interdependência ou correlação entre os sensores utilizando teste de *Person* para correlações lineares e *Predict Power Score* (PPS) para correlações não lineares, conforme mostrado no *heatmap* da figura [28](#). Mais detalhes sobre esta visualização podem ser vistas em ([KAPPELMAN, 2018](#)). Os valores plotados estão entre -1 e 1 e representam a dependência entre as variáveis. Existem três casos importantes:

1. Se o valor for positivo, a dependência é positiva;
2. Se o valor for negativo, a dependência é negativa;
3. Se o valor for próximo de 0, as variáveis são independentes.

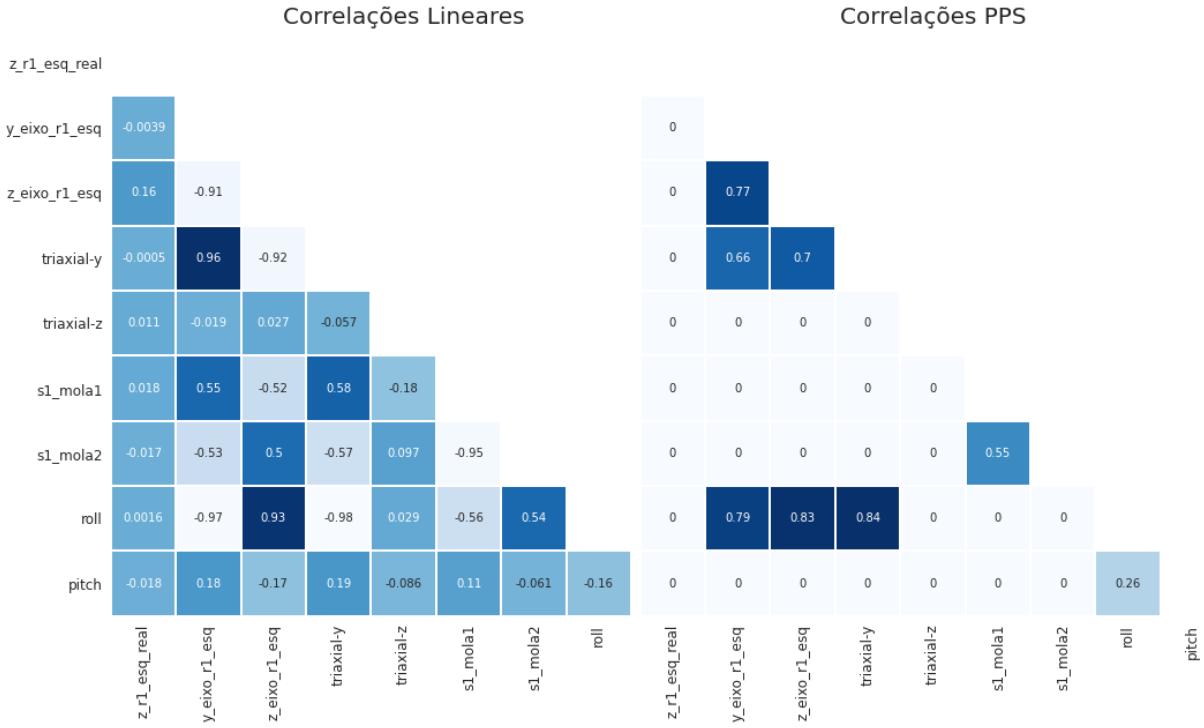


Figura 28 – Heatmap da interdependência entre os sensores reais e virtuais

A partir da figura 28, é possível tirar as seguintes conclusões:

- Existem altas correlações entre os sensores laterais (triaxial-y, roll e y_eixo_r1_esq);
- Deslocamento da mola esquerda possui correlação positiva com sensores laterais;
- Deslocamento da mola direita possui correlação negativa com sensores laterais;
- Roll possui correlação negativa com sensores laterais;
- Sensores verticais da travessa lateral, triaxial z e pitch não possuem correlação boa com outros sensores. Portanto, essas variáveis podem fornecer uma visão única do problema.

As figuras 29 e 30 mostra gráficos de correlação com os sensores reais para os rodeiros 1 e dois respectivamente. Pela figura 29, é possível tirar as seguintes conclusões:

1. Triaxial em Z correlaciona positivamente com o L/Q do rodeiro dianteiro;
2. Triaxial em Y possui correlação positiva para o L/Q esquerda e negativo para o Nadal direito;
3. O deslocamento da suspensão secundária direita possui correlação negativa com o L/Q esquerdo;
4. O deslocamento da suspensão secundária esquerda possui correlação negativo com o L/Q direito;
5. As suspensões do truque traseiro não possuem grande correlação com o L/Q;

6. A aceleração vertical da travessa lateral não possui grande correlação com o L/Q.

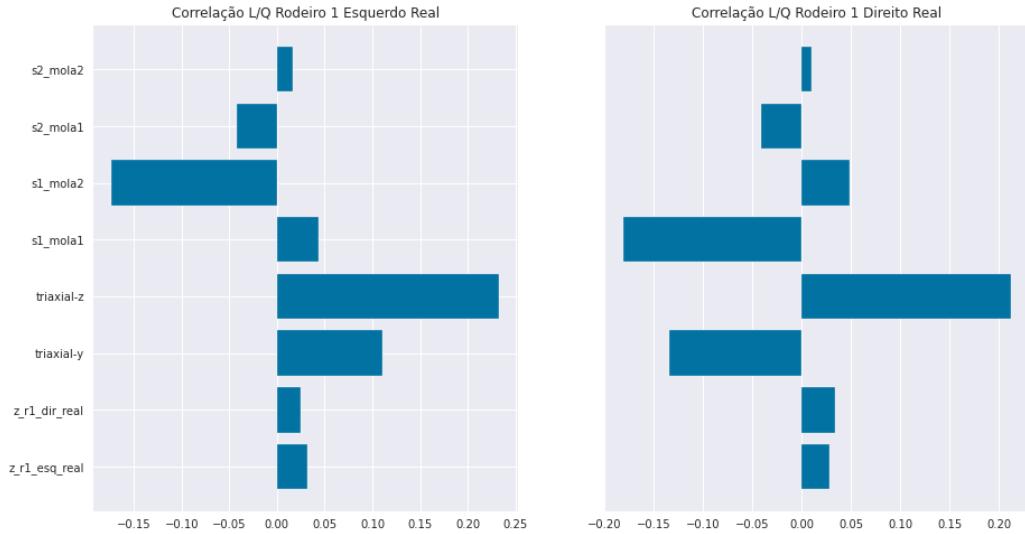


Figura 29 – Correlação do L/Q do rodeiro 1 para sensores reais

Já na figura 30, é possível tirar as seguintes conclusões:

1. Triaxial em Z não possui correlação
2. Triaxial em Y possui correlação negativa para o L/Q esquerda e positivo para o L/Q direito
3. O deslocamento da suspensão secundária direita do truque dianteiro possui correlação positiva com o L/Q esquerdo e negativa para o direito
4. O deslocamento da suspensão secundária esquerda do truque dianteiro possui correlação negativo com o L/Q esquerdo e positivo com o L/Q direito
5. As suspensões do truque traseiro possui grande correlação com o L/Q.
6. A aceleração vertical da travessa lateral não afeta substancialmente o L/Q.

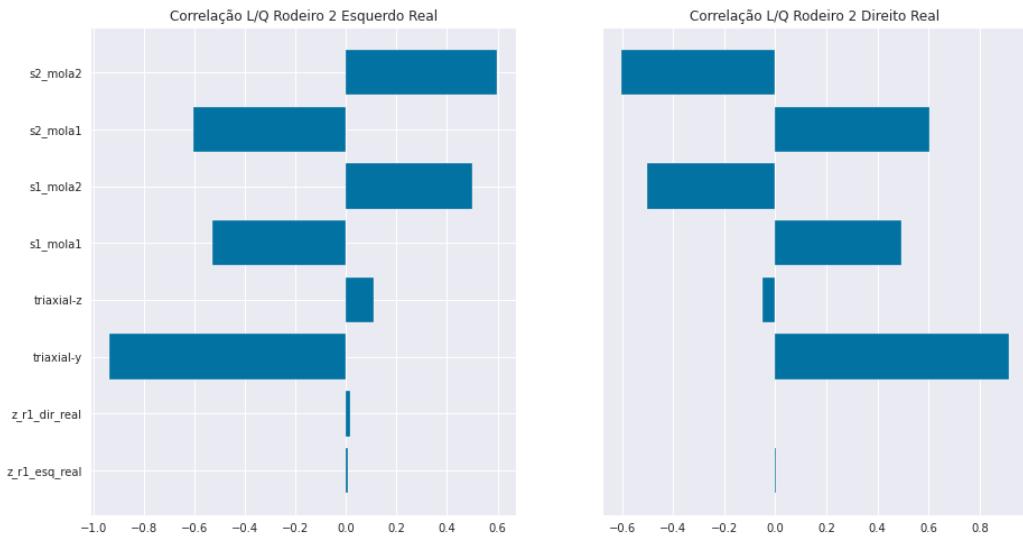


Figura 30 – Correlação do L/Q do rodeiro 2 para sensores reais

Juntando então as conclusões das figuras 29 e 29, é possível visualizar um padrão no que tange ao acelerômetro vertical da travessa. Visto a baixa correlação para ambos os rodeiros, é possível afirmar que é alto a chance dele não ser importante para o modelo de aprendizado de máquina.

No apêndice 8.7 pode ser encontrado as figuras com as correlações referentes aos sensores virtuais.

6.2 Modelagem/Aprendizagem

Os dados foram divididos utilizando a técnica de validação cruzada (BROWNLEE, 2019). Esse procedimento possui um único parâmetro "K" que se refere ao número de grupos na qual a amostra de dados deve ser dividida, sendo que este parâmetro varia com o modelo. Após essa divisão, o algoritmo de aprendizado de máquina é treinado e validado através de métricas de avaliação.

Como o objetivo é a resposta dinâmica da via por meio do valor do L/Q, modelos de regressão foram utilizados para investigar a relação entre variáveis dependentes. Utilizou-se as seguintes métricas para quantificar a precisão desses modelos:

- Erro Quadrático Médio

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_{pred} - \hat{y}_{real})^2 \quad (6.1)$$

- Erro Médio Absoluto

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_{pred} - \hat{y}_{real}| \quad (6.2)$$

- Coeficiente de Determinação

$$SQ_{exp} = \sum_{i=1}^N (\hat{y} - \bar{y}) \quad (6.3)$$

$$SQ_{res} = \sum_{i=1}^N (y - \hat{y}) \quad (6.4)$$

$$SQ_{tot} = SQ_{exp} + SQ_{res} \quad (6.5)$$

$$R^2 = \frac{SQ_{exp}}{SQ_{tot}} \quad (6.6)$$

6.2.1 Explicabilidade do modelo

Os modelos de aprendizado de máquina são geralmente caixas pretas, ou seja, são sistemas de complexidade potencialmente alta no qual sua estrutura interna é desconhecida ou não é levado em consideração em sua análise (KRAFT; CAUSSE; MARTINEZ, 2019). Esse modelo não tem um significado físico, o que interessa são os estímulos dados na entrada e a resposta produzida na saída.

Mesmo assim, é importante entender e interpretar esses modelos para obter conhecimento além da predição. Para fins de compreensão, foi treinado um modelo utilizando o *Random Forest Regressor* com hiperparâmetros padrões, que consiste em um modelo de árvore *ensemble* (Zenko; Todorovski; Dzeroski, 2001). Apesar de serem utilizados outros algoritmos na seção 6.2.2, eles são do mesmo tipo (árvore), então a análise servirá como referência para o entendimento dos modelos. Foi utilizado o *Shapley Additive Explanation (SHAP)* e o *SelectKBest* para a análise deste modelo já treinado.

Desenvolvido por Lundberg e Lee (2017), SHAP utiliza a teoria de jogos para explicar a saída de qualquer modelo de aprendizado de máquina. Ele estima a contribuição de cada variável da amostra analisada e estende-se a análise para todo o conjunto de dados. Para exemplificar, é apresentado a seguir os valores de SHAP para os sensores reais e virtuais utilizando o algoritmo *Random Forest Regressor* para o L/Q do rodeiro dianteiro esquerdo.

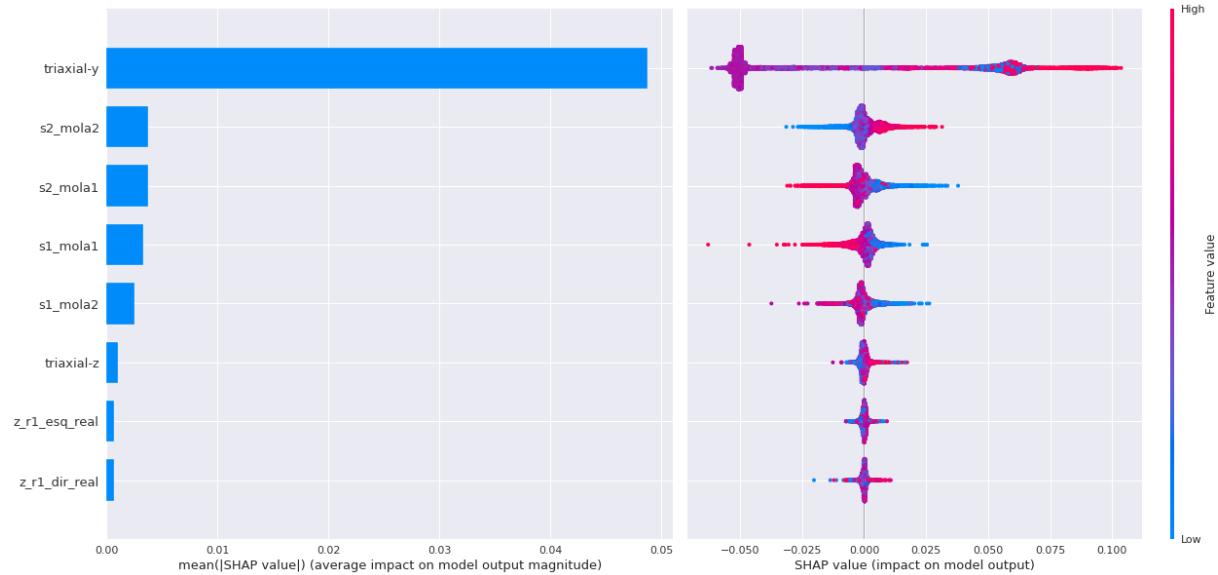


Figura 31 – Valor médio de SHAP para os sensores reais

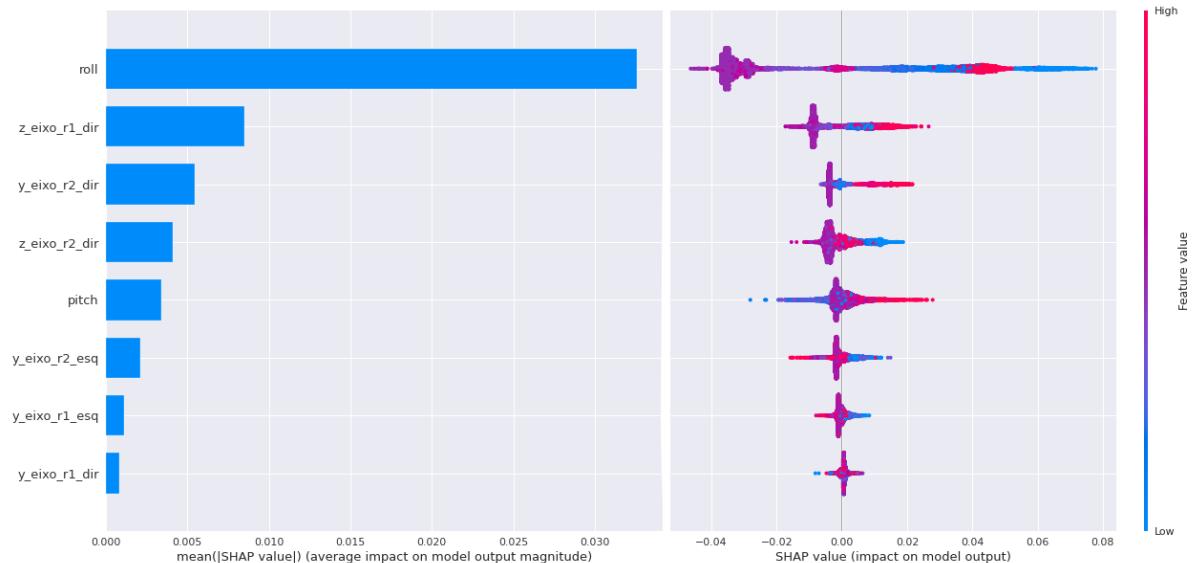


Figura 32 – Valor médio de SHAP para os sensores virtuais

Utilizando o SHAP, é possível compreender quais sensores mais impactam ou contribuem para o valor de L/Q. Em termos mais práticos, o SHAP permite definir melhor quais sensores devem ser observados com mais atenção.

Com relação a figura 31, o triaxial-y é a variável que mais impacta ou contribui para o L/Q, em seguida os deslocamentos das suspensões, o triaxial-z e os acelerômetros verticais. Então as variáveis do sensor triaxial devem ser tomadas como referência durante a elaboração do modelo. Na figura do lado direito, é quantificado a contribuição global dos valores de cada variável para o L/Q, onde as cores frias (azul) exemplificam valores baixos da variável e cores quentes (vermelho) valores altos. Além disso a espessura das

linhas horizontais descreve a densidade da variável em determinado valor. O triaxial-y da figura 31, por exemplo, mostra uma alta distribuição com valores médios (roxo) e o impacto negativo que esse valor tem sobre a saída do modelo.

No caso da figura 32, é possível visualizar que o *roll* é a variável que mais contribui para o valor de L/Q, sendo que ele possui uma contribuição predominantemente negativo. Então nos modelos que utilizam sensores virtuais, deve-se ter atenção na contribuição do giroscópio.

Visto a importância global, é necessário realizar uma análise local, vendo qual a contribuição das variáveis para empurrar a saída média do modelo (*base value*) para a saída do modelo. É tratado a situação da viagem sobre a curva como também o trecho tangente, conforme mostrado nas figura 34 e 33 respectivamente. As variáveis que aumentam a previsão são mostrados em vermelho, aqueles que diminuem a previsão estão em azul. Em ambos os casos, é possível observar que o triaxial-y é de grande influência em curvas e em tangentes.

Como é de interesse analisar os grandes valores de L/Q, foi feito a análise do maior valor de L/Q do rodeiro 1 esquerdo identificado durante a simulação, exemplificado na figura 34. O valor base de 0.07149 é empurrado para o valor da saída do modelo de 0.19, e grande parte dessa contribuição foi pelo triaxial-y, aproximadamente 80 % da contribuição total.



Figura 33 – Valor local de SHAP em uma tangente



Figura 34 – Valor local de SHAP em uma curva

No apêndice 8.5 pode ser encontrado as figuras com os valores de SHAP referentes a todos os L/Q.

Visto quais sensores mais contribuem para o L/Q, o próximo passo é verificar qual combinação de variáveis forneceria o melhor modelo simplificado. O algoritmo *SelectKBest* desenvolvido por Pedregosa et al. (2011) foi utilizado com o objetivo de selecionar as melhores combinações de variáveis de acordo com o número total K . Essa seleção é feita a partir dos valores de *F-Regression*, que consiste em um teste univariado de regressão

linear.

A tabela 10 contém os valores do coeficiente de determinação R^2 utilizando apenas os sensores reais. O número ótimo de parâmetros K varia de 2 até 8. Não se observou *overfitting* com o aumento do número de variáveis para o caso da análise consistindo apenas de sensores reais. Nesse caso, apenas $K = 2$ não leva a um modelo preciso. Existe nesse caso um *trade-off* entre o número de variáveis do modelo e a precisão. Quanto maior o número de variáveis, maior o custo computacional e gasto em armazenamento de dados, mas aumenta-se a precisão.

Número de Variáveis (K)	2	3	4	5	6	7	8
Rodeiro 1 Esquerdo	0.1272	0.9191	0.9477	0.9572	0.9577	0.9582	0.9640
Rodeiro 1 Direito	0.076	0.9237	0.9403	0.9593	0.9601	0.9602	0.9645
Rodeiro 2 Esquerdo	0.9258	0.9463	0.9649	0.9715	0.9732	0.9729	0.9724
Rodeiro 2 Direito	0.9143	0.9353	0.9598	0.9676	0.9693	0.9681	0.9688

Tabela 10 – Seleção KBest com sensores reais

A tabela 11 retorna qual foi a melhor combinação de variáveis para o modelo. Por exemplo, quando o valor da classificação for 1, a coluna mostra a variável mais importante. Se a classificação tiver valor 2, mostra-se a segunda variável mais importante e assim sucessivamente.

Classificação	1	2	3	4	5	6	7	8
Rodeiro 1 Direito	triaxial-z	s1_mola1	triaxial-y	s1_mola2	s2_mola1	z_r1_dir_real	z_r1_esq_real	s2_mola2
Rodeiro 1 Esquerdo	triaxial-z	s1_mola2	triaxial-y	s1_mola1	s2_mola1	z_r1_esq_real	z_r1_dir_real	s2_mola2
Rodeiro 2 Direito	triaxial-y	s2_mola1	s2_mola2	s1_mola2	s1_mola1	triaxial-z	z_r1_esq_real	z_r1_dir_real
Rodeiro 2 Esquerdo	triaxial-y	s2_mola1	s2_mola2	s1_mola1	s1_mola2	triaxial-z	z_r1_dir_real	z_r1_esq_real

Tabela 11 – Ranking das variáveis selecionadas com SelectKBest

Com isso, pode-se notar semelhanças com o que foi observado nas figuras 29 e 30, onde observa-se a relevância do acelerômetro triaxial e do deslocamento da suspensão secundária e a interdependência do lado direito com o esquerda, ou vice-versa, em relação a suspensão.

É possível notar uma discrepância na variável de classificação 1 do rodeiro 1 (tabela 20) e a variável mais impactante do SHAP (figura 31). Enquanto que o SHAP aponta o triaxial-y como a variável mais impactante de uma maneira global, o *SelectKBest* retorna o triaxial-z como a variável mais correlacionada com o L/Q. É possível verificar essa afirmação na figura 29 devido à alta correlação do triaxial-z com o L/Q do rodeiro dianteiro e também pela figura 30 que mostra o maior valor de correlação para o triaxial em y.

6.2.2 Algoritmo de *Machine Learning*

Para a escolha do modelo de *Machine Learning*, foi utilizado o *Tree-based Pipeline Optimization Tool* (TPOT) (LE; FU; MOORE, 2020). O TPOT é uma *pipeline* ou uma arquitetura onde utiliza algoritmo genético para otimizar a escolha das transformações no conjunto de dados, as melhores combinações de variáveis e os hiperparâmetros do modelo.

Um modelo otimizado é criado para o L/Q de cada roda, considerando a taxa de amostragem, existência de irregularidade e a combinação de variáveis. Já que existe quatro previsões para o L/Q, duas taxas de amostragem, duas classes de irregularidade e duas combinações de variáveis, totalizando um total teórico de 32 modelos. Não foi utilizado os dados de 1 Hz sem irregularidade, portanto, o total de 32 modelos cai para 24. Todos os algoritmos de *Machine Learning*, pré-processadores e selecionador de variáveis utilizados no TPOT está listado na tabela 12.

É importante frisar que o TPOT é automatizado, ou seja, ele cobre todos os passos no desenvolvimento do modelo de aprendizado de máquina, desde o dado bruto até o modelo em si. Sendo assim, a ferramenta permite que pessoas implementem os modelos e técnicas de ML sem ser especializado nessa área.

Algoritmos de Aprendizado de Máquina	Pré-processadores	Seleção de Variáveis
ElasticNetCV ExtraTreesRegressor GradientBoostingRegressor AdaBoostRegressor DecisionTreeRegressor KNeighborsRegressor LassoLarsCV LinearSVR RandomForestRegressor RidgeCV XGBRegressor SGDRegressor	Binarizer FastICA FeatureAgglomeration MaxAbsScaler MinMaxScaler Normalizer Nystroem PCA PolynomialFeatures PolynomialFeatures RobustScaler StandardScaler ZeroCount OneHotEncoder	SelectFwe SelectPercentile VarianceThreshold SelectFromModel

Tabela 12 – Algoritmos e transformações utilizados pelo TPOT

Os algoritmos de ML da tabela 12 são capazes de fornecer o valor de L/Q do rodeiro, no entanto, existe um benefício ao aproveitar os recursos de vários modelos treinados para fazer previsões do que usar um modelo separado do conjunto. Visto isso, é interessante achar a melhor combinação das previsões dos modelos para a fim de aumentar a confiabilidade e diminuir *overfitting*.

Foi utilizado modelos de empilhamento (*stacking*) proposto por [Zenko, Todorovski e Dzeroski \(2001\)](#) para a criação do modelo final, conforme mostrado na figura 35. O modelo de empilhamento utiliza as saídas dos modelos de primeiro nível (*Base model*) e cria um novo conjunto de dados que servirá como entrada de um modelo de ML de segundo nível (*Meta model*). O modelo de segundo nível fornece a melhor combinação dos modelos de primeiro nível para prever o L/Q. No apêndice 8.6 é mostrado em detalhe todos os algoritmos utilizados e os devidos hiperparâmetros.

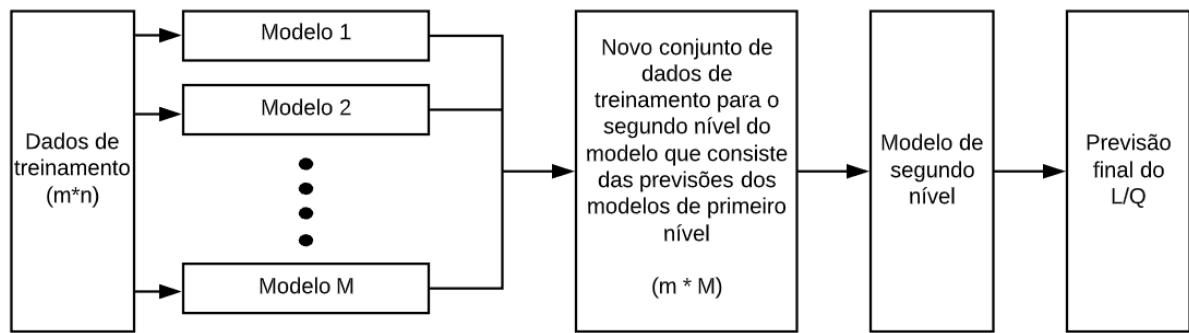


Figura 35 – Implementação do modelo de empilhamento

7 Resultados

As tabelas 13, 14, 15 e 16 mostram a precisão dos modelos de acordo com a taxa de aquisição dos dados e o conjunto de sensores.

As figuras 36, 38, 40 e 42 mostram gráficos dos resíduos da previsão do L/Q. Um gráfico de resíduo mensura o erro entre o valor previsto e o observado (gabarito do valor). O valor desse erro está no eixo Y, enquanto que o valor predito está no eixo X (GOHAR, 2020). O ideal seria que os pontos plotados fossem o mais próximo do resíduo de valor 0. Supõe-se que os erros são independentes e possuem distribuição normal.

Também é mostrado nas figuras 37, 39, 41 e 43 a comparação dos valores reais de L/Q com os valores preditos pelo modelo. Onde em vermelho é o valor real e em azul o valor predito.

7.1 Nadal rodeiro 1 esquerdo

Taxa de Aquisição	Sensores	Pipeline	R^2
100Hz com Irregularidades	Real	Base-Model (ExtraTreesRegressor) Meta-Model(XGBRegressor)	0.9729
	Real + Virtual	Base-Model (SGDRegressor, ExtraTreesRegressor) Meta-Model(RandomForestRegressor)	0.9875
100Hz sem Irregularidades	Real	Base-Model (ExtraTreesRegressor, ExtraTreesRegressor) Meta-Model(RandomForestRegressor)	0.9985
	Real + Virtual	Base-Model (AdaBoostRegressor, PolynomialFeatures) Meta-Model(GradientBoostingRegressor)	0.9993
1Hz com Irregularidades	Real	RandomForestRegressor	0.9298
	Real + Virtual	Base-Model (LassoLarsCV) Meta-Model(XGBRegressor)	0.9370

Tabela 13 – Modelos - L/Q Rodeiro 1 Esquerdo

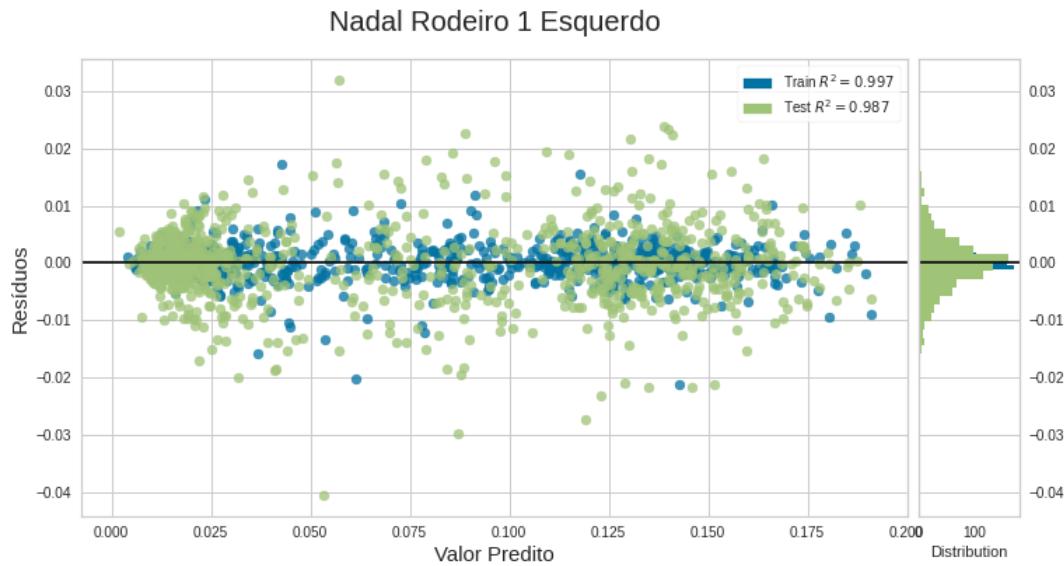


Figura 36 – Resíduos do L/Q do rodeiro 1 esquerdo - 100Hz com irregularidades

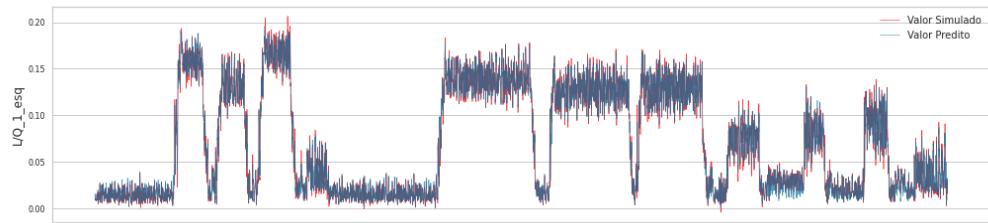


Figura 37 – Comparação do L/Q do rodeiro 1 esquerdo predito com o real

7.2 L/Q rodeiro 1 direito

Taxa de Aquisição	Sensores	Pipeline	R^2
100Hz com Irregularidades	Real	Base-Model (PolynomialFeatures, ExtraTreesRegressor) Meta-Model (RandomForestRegressor)	0.9785
	Real + Virtual	RandomForestRegressor	0.9855
100Hz sem Irregularidades	Real	RobustScaler, RandomForestRegressor	0.9973
	Real + Virtual	Base-Model (LassoLarsCV) Meta-Model (ExtraTreesRegressor)	0.9869
1Hz com Irregularidades	Real	RandomForestRegressor	0.8972
	Real + Virtual	SelectFwe, RandomForestRegressor	0.8925

Tabela 14 – Modelos - L/Q Rodeiro 1 Direito

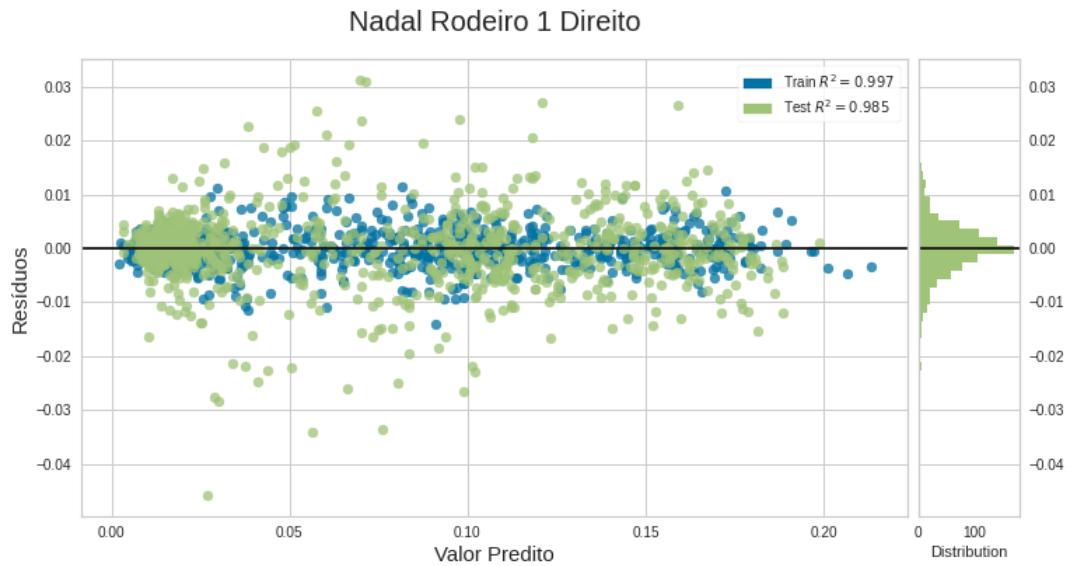


Figura 38 – Resíduos do L/Q do rodeiro 1 direito - 100Hz com irregularidades

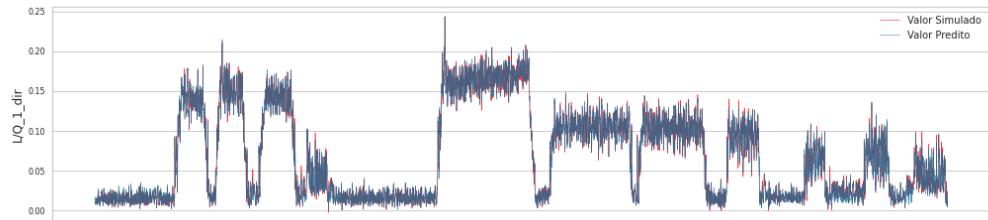


Figura 39 – Comparaçāo do L/Q rodeiro 1 direito predito com o real

7.3 L/Q rodeiro 2 esquerdo

Taxa de Aquisição	Sensores	Pipeline	R^2
100Hz com Irregularidades	Real	Base-Model (PolynomialFeatures, ExtraTreesRegressor) Meta-Model (RandomForestRegressor)	0.9785
	Real + Virtual	RandomForestRegressor	0.9855
100Hz sem Irregularidades	Real	RobustScaler, RandomForestRegressor	0.9973
	Real + Virtual	Base-Model (LassoLarsCV) Meta-Model (ExtraTreesRegressor)	0.9869
1Hz com Irregularidades	Real	RandomForestRegressor	0.8972
	Real + Virtual	SelectFwe, RandomForestRegressor	0.8925

Tabela 15 – Modelos - L/Q Rodeiro 2 Esquerdo

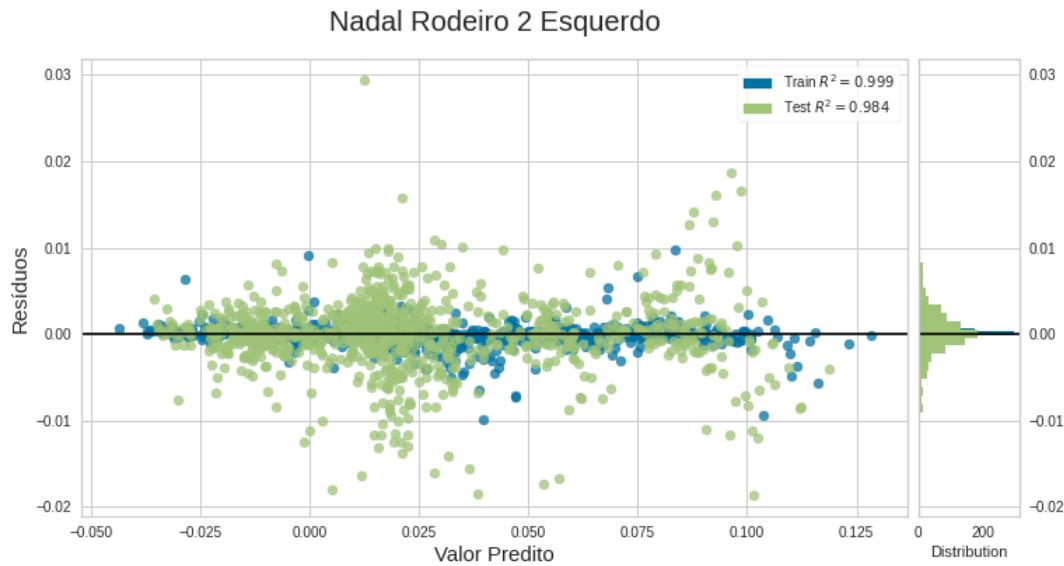


Figura 40 – Resíduos do L/Q do rodeiro 2 esquerdo - 100Hz com irregularidades

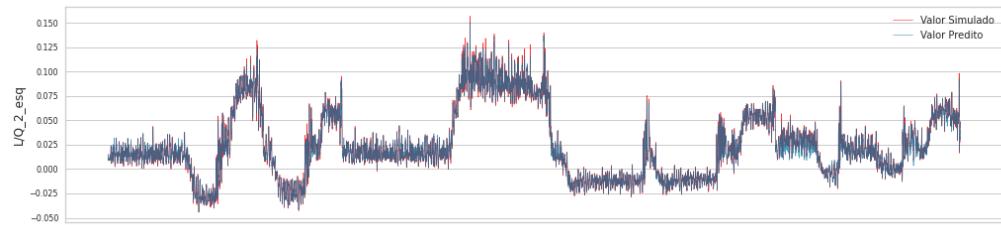


Figura 41 – Comparaçāo do L/Q do rodeiro 2 esquerdo predito com o real

7.4 L/Q rodeiro 2 direito

Taxa de Aquisição	Sensores	Pipeline	R^2
100Hz com Irregularidades	Real	Base-Model (StandardScaler, LassoLarsCV) Meta-Model (RandomForestRegressor)	0.9747
	Real + Virtual	ExtraTreesRegressor	0.9838
100Hz sem Irregularidades	Real	RandomForestRegressor	0.9969
	Real + Virtual	SelectPercentile, PolynomialFeatures, ExtraTreesRegressor	0.9988
1Hz com Irregularidades	Real	Base-Model (LassoLarsCV) Meta-Model (RandomForestRegressor)	0.9166
	Real + Virtual	Base-Model (LassoLarsCV) Meta-Model (RandomForestRegressor)	0.9166

Tabela 16 – Modelos - L/Q Rodeiro 2 Direito

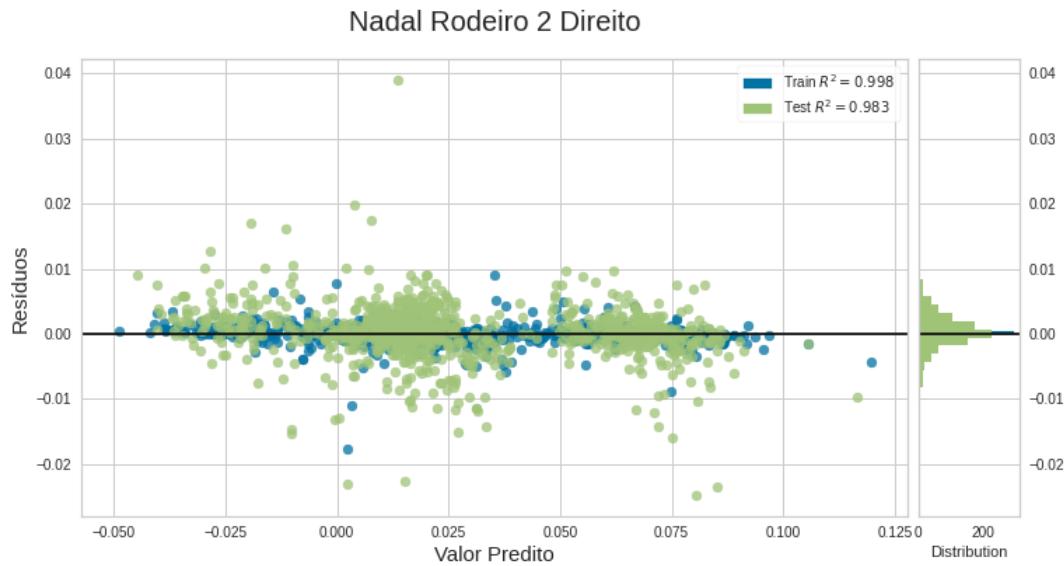


Figura 42 – Resíduos do L/Q do rodeiro 2 direito - 100Hz com irregularidades

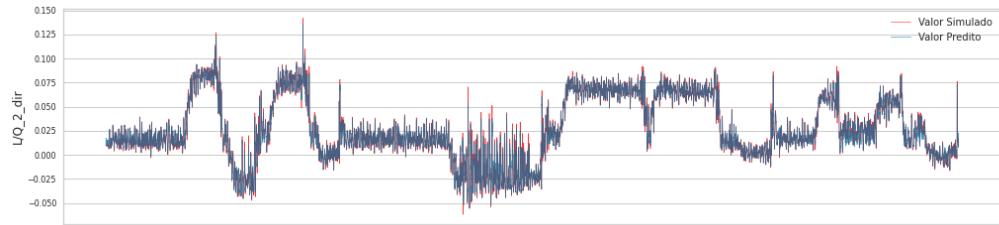


Figura 43 – Comparaçāo do L/Q do rodeiro 2 direito predito com o real

7.5 Conclusão

Com base na tabela 17, 18 e o discutido na seção 6.1, a seguir estão as respostas dos objetivos específicos da seção 1.3.1.

		Rodeiro 1 Esquerdo	Rodeiro 1 Direito	Rodeiro 2 Esquerdo	Rodeiro 2 Direito
100Hz com Irregularidades	Real	0.9729	0.9714	0.9747	0.9785
	Real + Virtual	0.9861	0.9861	0.9837	0.9854
100Hz sem Irregularidades	Real	0.9985	0.9977	0.9973	0.9969
	Real + Virtual	0.9993	0.9992	0.9869	0.9988
1Hz com Irregularidades	Real	0.9298	0.9346	0.8972	0.9166
	Real + Virtual	0.9370	0.9314	0.8925	0.9111

Tabela 17 – Resultados dos Modelos utilizando R-quadrado como Métrica

		Rodeiro 1 Esquerdo	Rodeiro 1 Direito	Rodeiro 2 Esquerdo	Rodeiro 2 Direito
100Hz com Irregularidades		Real	0.00593	0.00544	0.00319
		Real + Virtual	0.00429	0.00441	0.00264
100Hz sem Irregularidades		Real	0.00062	0.00072	0.00043
		Real + Virtual	0.00037	0.00039	0.00246
1Hz com Irregularidades		Real	0.01113	0.0097	0.00691
		Real + Virtual	0.00918	0.00932	0.00731

Tabela 18 – Resultados dos Modelos utilizando Erro absoluto médio como Métrica

1. Verificar o efeito da taxa de amostragem na precisão do modelo;

A taxa de aquisição de 1 Hz possui uma precisão menor que o de 100 Hz. Portanto, a taxa de aquisição atual do vagão BRA1 afetará negativamente a precisão do L/Q.

2. Verificar a efeito da taxa de amostragem no valor dos dados obtidos;

Foi visto que a taxa de aquisição de 1 Hz, apesar de acompanhar o valor médio do L/Q com 100 Hz, ele subestima o seu valor visto a sua dificuldade em captar as vibrações de alta frequência causadas pelas irregularidades da via. Isso reforça a ideia de que é necessário trocar a taxa de amostragem para obter o L/Q com maior confiança.

Além disso, a taxa de 1 Hz limita algumas possíveis aplicações como detecção de cargas de impacto e defeitos na via visto a sua baixa resolução, apesar da instrumentação do vagão BRA1 ser suficiente.

3. Determinar quais são os sensores e as variáveis mais importantes para o modelo de ML;

Os sensores mais importantes são o acelerômetro triaxial da caixa e depois as suspensões. As variáveis mais importantes são os componentes Y e Z do acelerômetro triaxial e os quatro deslocamentos das molas. O acelerômetro da travessa lateral não é muito importante para a determinação do L/Q.

Se fosse para considerar os sensores reais com os virtuais, os mais importantes seriam o triaxial, giroscópio e os acelerômetros da caixa de eixo, sendo este último pouco prático. O apêndice 8.8 traz estas informações.

4. Verificar se a instrumentação atual do vagão instrumentado é capaz de fornecer a razão entre a força lateral e vertical do contato roda trilho;

A instrumentação atual do vagão instrumentado BRA1 é capaz de fornecer o valor de L/Q através da metodologia estabelecida neste trabalho.

5. Comparar o desempenho de diferentes modelos de ML.

Os modelos de aprendizado de máquina para as quatro rodas do truque dianteiro consegue fornecer o valor de L/Q com R^2 acima de 0.97, considerando os dados de 100

Hz. Apesar das respostas lidas pelos sensores terem ruído devido às irregularidades, os modelos de aprendizado de máquina conseguem garantir uma precisão alta.

7.6 Disponibilização do código utilizado

Todo o código utilizado pode ser encontrado no repositório [GitHub](#).

Referências

- 13848-5, E. *Railway applications—track—track geometry quality—part 5: Geometric quality levels*. [S.l.]: European Committee for Standardization (CEN) Brussels, 2008. Citado na página 34.
- ATTOH-OKINE, N. Big data challenges in railway engineering. In: IEEE. *2014 IEEE International conference on big data (Big Data)*. [S.l.], 2014. p. 7–9. Citado na página 49.
- ATTOH-OKINE, N. O. *Big data and differential privacy: Analysis strategies for railway track engineering*. [S.l.]: John Wiley & Sons, 2017. Citado 5 vezes nas páginas 22, 31, 49, 50 e 55.
- BAI, L. et al. Markov-based model for the prediction of railway track irregularities. *Proceedings of the Institution of Mechanical Engineers, Part F: Journal of rail and rapid transit*, SAGE Publications Sage UK: London, England, v. 229, n. 2, p. 150–159, 2015. Citado 3 vezes nas páginas 15, 21 e 31.
- BARBOSA, R. S. Evaluation of railway track safety with a new method for track quality identification. *Journal of Transportation Engineering*, American Society of Civil Engineers, v. 142, n. 11, p. 04016053, 2016. Citado na página 30.
- BARBOSA, R. S. New method for railway track quality identification through the safety dynamic performance of instrumented railway vehicle. *Journal of the Brazilian Society of Mechanical Sciences and Engineering*, Springer, v. 38, n. 8, p. 2265–2275, 2016. Citado 3 vezes nas páginas 15, 21 e 27.
- BARBOSA, R. S. *Segurança em sistemas metro-ferroviários*. Tese (Doutorado) — Universidade de São Paulo, 2017. Citado 3 vezes nas páginas 14, 15 e 30.
- BERAWI, A. R. B. Improving railway track maintenance using power spectral density (psd). 2013. Citado 6 vezes nas páginas 6, 8, 34, 35, 46 e 47.
- BERNAL, E.; SPIRYAGIN, M.; COLE, C. Onboard condition monitoring sensors, systems and techniques for freight railway vehicles: a review. *IEEE Sensors Journal*, IEEE, v. 19, n. 1, p. 4–24, 2018. Citado 2 vezes nas páginas 22 e 25.
- BROWNLEE, J. *A Gentle Introduction to k-fold Cross-Validation*. [S.l.], 2019. Disponível em: <<https://machinelearningmastery.com/k-fold-cross-validation/>>. Citado na página 58.
- CAZZULANI, G. et al. A new approach for the evaluation and the improvement of the metrological characteristics of an instrumented wheelset for the measure of wheel–rail contact forces. *Proceedings of the Institution of Mechanical Engineers, Part F: Journal of Rail and Rapid Transit*, SAGE Publications Sage UK: London, England, v. 231, n. 4, p. 381–393, 2017. Citado na página 28.
- CHONG, T. et al. Defining rail track input conditions using an instrumented revenue vehicle. *Procedia Engineering*, Elsevier, v. 188, p. 479–485, 2017. Citado na página 17.

- COWIE, J. et al. Use of instrumented revenue vehicle to manage 40 tonne axle load operation at fortescue metals group ltd. *IHHA2015, Perth Australia, June*, 2015. Citado 2 vezes nas páginas 22 e 39.
- DARBY, M. et al. The development of an instrumented wagon for continuously monitoring track condition. In: *AusRAIL PLUS 2003, 17-19 November 2003, Sydney, NSW, Australia*. [S.l.: s.n.], 2003. Citado na página 21.
- DARBY, M. et al. Track condition monitoring: the next generation. In: *International Heavy Haul Association Conference 2005*. [S.l.: s.n.], 2005. Citado 2 vezes nas páginas 25 e 39.
- DERAILMENT, U. *Universal Mechanism, Numerical Simulation of Railway Vehicle Derailments*. [S.l.]. Citado 2 vezes nas páginas 6 e 27.
- EN, B. 13848: 1 railway applications/track. track geometry quality. characterisation of track geometry. *British Standard Institution: London*, 2003. Citado 3 vezes nas páginas 8, 32 e 35.
- FERROVIÁRIOS), A. A. N. dos T. *Avanço na produtividade das ferrovias brasileiras*. [S.l.], 2019. Disponível em: <<https://www.antf.org.br/informacoes-gerais/>>. Citado na página 14.
- FRÝBA, L. *Dynamics of railway bridges*. [S.l.]: Thomas Telford Publishing, 1996. Citado na página 46.
- GARG, V. *Dynamics of railway vehicle systems*. [S.l.]: Elsevier, 2012. Citado na página 46.
- GÉRON, A. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems*. [S.l.]: O'Reilly Media, 2019. Citado na página 49.
- GOHAR, U. *How to use Residual Plots for regression model validation*. [S.l.], 2020. Disponível em: <<https://towardsdatascience.com/how-to-use-residual-plots-for-regression-model-validation-c3c70e8ab378>>. Citado na página 65.
- GÓMEZ, M. J. et al. Railway axle condition monitoring technique based on wavelet packet transform features and support vector machines. *Sensors, Multidisciplinary Digital Publishing Institute*, v. 20, n. 12, p. 3575, 2020. Citado 4 vezes nas páginas 6, 24, 40 e 41.
- HAIGERMOSEN, A. et al. Describing and assessing track geometry quality. *Vehicle System Dynamics*, Taylor & Francis, v. 52, n. sup1, p. 189–206, 2014. Citado na página 30.
- HAIGERMOSEN, A. et al. Road and track irregularities: measurement, assessment and simulation. *Vehicle system dynamics*, Taylor & Francis, v. 53, n. 7, p. 878–957, 2015. Citado 4 vezes nas páginas 15, 30, 31 e 32.
- HARDIE, G. et al. The use of instrumented revenue vehicle data to calculate track geometry parameters. *CORE 2016: Maintaining the Momentum*, Railway Technical Society of Australasia, p. 238, 2016. Citado 2 vezes nas páginas 25 e 39.

- HODGE, V. J. et al. Wireless sensor networks for condition monitoring in the railway industry: A survey. *IEEE Transactions on Intelligent Transportation Systems*, IEEE, v. 16, n. 3, p. 1088–1106, 2014. Citado 3 vezes nas páginas [8](#), [18](#) e [19](#).
- HUNG, C.; HSU, W. Influence of long-wavelength track irregularities on the motion of a high-speed train. *Vehicle system dynamics*, Taylor & Francis, v. 56, n. 1, p. 95–112, 2018. Citado na página [35](#).
- JENKINS, H. et al. The effect of track and vehicle parameters on wheel/rail vertical dynamic forces. *Railway Engineering Journal*, v. 3, n. 1, 1974. Citado na página [14](#).
- KAPPELMAN, E. *What is Seaborn and why should you use it for data visualization?* [S.l.], 2018. Disponível em: <<https://hub.packtpub.com/what-is-seaborn-and-why-should-you-use-it-for-data-visualization/>>. Citado na página [55](#).
- KARIS, T. *Correlation between Track Irregularities and Vehicle Dynamic Response Based on Measurements and Simulations*. Tese (Doutorado) — KTH Royal Institute of Technology, 2018. Citado 5 vezes nas páginas [6](#), [16](#), [17](#), [31](#) e [34](#).
- KNOTHE, K.; STICHEL, S. *Rail vehicle dynamics*. [S.l.]: Springer, 2017. Citado 2 vezes nas páginas [37](#) e [38](#).
- KOUROUSSIS, G. et al. Modelling the environmental effects of railway vibrations from different types of rolling stock: a numerical study. *Shock and Vibration*, Hindawi, v. 2015, 2015. Citado na página [35](#).
- KRAFT, S.; CAUSSE, J.; COUDERT, F. Vehicle response-based track geometry assessment using multi-body simulation. *Vehicle System Dynamics*, Taylor & Francis, v. 56, n. 2, p. 190–220, 2018. Citado 2 vezes nas páginas [28](#) e [30](#).
- KRAFT, S.; CAUSSE, J.; MARTINEZ, A. Black-box modelling of nonlinear railway vehicle dynamics for track geometry assessment using neural networks. *Vehicle System Dynamics*, Taylor & Francis, v. 57, n. 9, p. 1241–1270, 2019. Citado na página [59](#).
- LASISI, A.; ATTOH-OKINE, N. An unsupervised learning framework for track quality index and safety. *Transportation Infrastructure Geotechnology*, Springer, p. 1–12, 2019. Citado na página [30](#).
- LEE, T. T.; FU, W.; MOORE, J. H. Scaling tree-based automated machine learning to biomedical big data with a feature set selector. *Bioinformatics*, Oxford University Press, v. 36, n. 1, p. 250–256, 2020. Citado na página [63](#).
- LEE, J. et al. Track condition monitoring by in-service trains: a comparison between axle-box and bogie accelerometers. IET, 2011. Citado 2 vezes nas páginas [21](#) e [24](#).
- LEE, J. S. et al. A mixed filtering approach for track condition monitoring using accelerometers on the axle box and bogie. *IEEE Transactions on Instrumentation and Measurement*, IEEE, v. 61, n. 3, p. 749–758, 2011. Citado 4 vezes nas páginas [6](#), [21](#), [24](#) e [42](#).
- LI, D. et al. Relating track geometry to vehicle performance using neural network approach. *Proceedings of the Institution of Mechanical Engineers, Part F: Journal of*

- Rail and Rapid Transit*, SAGE Publications Sage UK: London, England, v. 220, n. 3, p. 273–281, 2006. Citado 5 vezes nas páginas 6, 15, 21, 30 e 31.
- LI, D. et al. Implementation of performance-based track geometry inspection on north american railroads. In: *Proceedings of 8th International Heavy Haul Conference, Rio de Janeiro, Brazil*. [S.l.: s.n.], 2005. p. 14–16. Citado na página 21.
- LINGAMANAIK, S. N. et al. Using instrumented revenue vehicles to inspect track integrity and rolling stock performance in a passenger network during peak times. *Procedia Engineering*, Elsevier, v. 188, p. 424–431, 2017. Citado 2 vezes nas páginas 21 e 24.
- LOCOMOTIVES, U. *Universal Mechanism, Simulation of Rail Vehicle Dynamics User Manual*. [S.l.], 2019. Disponível em: <http://www.universalmechanism.com/download/80/eng/08_um_loco.pdf>. Citado 4 vezes nas páginas 6, 44, 46 e 47.
- LUBER, B. Railway track quality assessment method based on vehicle system identification. *e & i Elektrotechnik und Informationstechnik*, Springer, v. 126, n. 5, p. 180–185, 2009. Citado na página 21.
- LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: *Advances in neural information processing systems*. [S.l.: s.n.], 2017. p. 4765–4774. Citado na página 59.
- MATSUMOTO, A. et al. A new measuring method of wheel–rail contact forces and related considerations. *Wear*, Elsevier, v. 265, n. 9-10, p. 1518–1525, 2008. Citado na página 21.
- MATSUMOTO, A. et al. Continuous observation of wheel/rail contact forces in curved track and theoretical considerations. *Vehicle system dynamics*, Taylor & Francis, v. 50, n. sup1, p. 349–364, 2012. Citado na página 21.
- MELO, L. R. T. *Estudo de efeitos dinâmicos de pontes ferroviárias considerando interação veículo-estrutura*. Tese (Doutorado) — Universidade de São Paulo, 2016. Citado 2 vezes nas páginas 8 e 32.
- MUINDE, M. *Railway track geometry inspection optimization*. 2018. Citado na página 21.
- NADARAJAH, N. et al. Prediction of railway vehicles' dynamic behaviour with machine learning algorithms. In: RAILWAY TECHNICAL SOCIETY OF AUSTRALASIA (RTSA); TECHNICAL SOCIETY OF *CORE 2018: Conference on Railway Excellence*. [S.l.], 2018. p. 452. Citado 2 vezes nas páginas 21 e 24.
- NGAMKHANONG, C.; KAEWUNRUEN, S.; COSTA, B. J. A. State-of-the-art review of railway track resilience monitoring. *Infrastructures*, Multidisciplinary Digital Publishing Institute, v. 3, n. 1, p. 3, 2018. Citado na página 18.
- PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Citado na página 61.
- PODWÓRNA, M. Modelling of random vertical irregularities of railway tracks. *International Journal of Applied Mechanics and Engineering*, De Gruyter Open, v. 20, n. 3, p. 647–655, 2015. Citado 2 vezes nas páginas 8 e 35.

- RAVITHARAN, R. Instrumented revenue vehicles drive track maintenance efficiencies. *Railway Gazette International*, p. 35, 2018. Citado na página 17.
- REALITYAI. *THE COMPLETE GUIDE TO MACHINE LEARNING FOR SENSORS AND SIGNAL DATA*. [S.l.], 2020. Disponível em: <<https://reality.ai/machine-learning-for-sensors-and-signal-data/>>. Citado 2 vezes nas páginas 22 e 24.
- REICHL, P.; RIBEIRO, H. V.; SANTOS, G. Improving the efficiency of vale's efc line through the use of continuously measured operational data. In: *International Heavy Haul Conference*. [S.l.: s.n.], 2015. Citado na página 21.
- REZENDE, S. X. R. *ANÁLISE DE FALHAS DAS FRATURAS DE TRILHOS: O CASO DA FERROVIA DO AÇO*. [S.l.], 2008. Disponível em: <<http://transportes.ime.eb.br/etfc/monografias/MON044.pdf>>. Citado na página 16.
- SANTOS, G. F. M. d. *Análise de segurança de veículo ferroviário de carga em tangente considerando a excitação periódica da via permanente*. Tese (Doutorado) — Universidade de São Paulo, 2015. Citado 7 vezes nas páginas 6, 14, 15, 16, 27, 28 e 30.
- SANTOS, G. F. M. dos; REICHL, P. et al. Visualizing rail data using integrated tools to enhance understanding and planning. *CORE 2014: Rail Transport For A Vital Economy*, Railway Technical Society of Australasia, p. 549, 2014. Citado 3 vezes nas páginas 6, 17 e 18.
- SILVA, P. *Protótipo para Monitoramento da Dinâmica de Vagões Ferroviários*. Tese (Doutorado) — CEFET-MG, 2019. Citado na página 38.
- SUN, Y. Q.; COLE, C.; SPIRYAGIN, M. Monitoring vertical wheel–rail contact forces based on freight wagon inverse modelling. *Advances in Mechanical Engineering*, SAGE Publications Sage UK: London, England, v. 7, n. 5, p. 1687814015585431, 2015. Citado na página 21.
- THOMPSON, C. et al. Predictive maintenance approaches based on continuous monitoring systems at rio tinto. *CORE 2016: Maintaining the Momentum*, Railway Technical Society of Australasia, p. 652, 2016. Citado na página 39.
- TSUNASHIMA, H. et al. Development of track condition monitoring system using on-board sensing device. *Railway Research: Selected Topics on Development, Safety and Technology*, BoD–Books on Demand, p. 145, 2015. Citado 2 vezes nas páginas 21 e 24.
- TSUNASHIMA, H. et al. Condition monitoring of railway track using in-service vehicle. *Reliability and safety in railway*, InTech Rijeka, Croatia, v. 12, p. 334–356, 2012. Citado 2 vezes nas páginas 21 e 24.
- VAZ, L. G. et al. Desenvolvimento de metamodelo para a analise de desempenho de um veículo ferroviario. *Proceeding Series of the Brazilian Society of Computational and Applied Mathematics*, v. 6, n. 2, 2018. Citado 4 vezes nas páginas 6, 14, 32 e 47.
- VRU. *Descrição dos termos do PSD*. [S.l.], 2019. Disponível em: <<https://vru.vibrationresearch.com/lesson/what-is-the-psd/>>. Citado na página 46.
- WARD, C. P. et al. Condition monitoring opportunities using vehicle-based sensors. *Proceedings of the Institution of Mechanical Engineers, Part F: Journal of Rail and Rapid*

- Transit*, SAGE Publications Sage UK: London, England, v. 225, n. 2, p. 202–218, 2011. Citado 3 vezes nas páginas [8](#), [22](#) e [23](#).
- WEI, L. et al. Indirect method for wheel–rail force measurement and derailment evaluation. *Vehicle System Dynamics*, Taylor & Francis, v. 52, n. 12, p. 1622–1641, 2014. Citado na página [21](#).
- WESTEON, P. et al. Monitoring vertical track irregularity from in-service railway vehicles. *Proceedings of the institution of mechanical engineers, Part F: Journal of Rail and Rapid Transit*, SAGE Publications Sage UK: London, England, v. 221, n. 1, p. 75–88, 2007. Citado 2 vezes nas páginas [21](#) e [24](#).
- WESTON, P. et al. Monitoring lateral track irregularity from in-service railway vehicles. *Proceedings of the Institution of Mechanical Engineers, Part F: Journal of Rail and Rapid Transit*, SAGE Publications Sage UK: London, England, v. 221, n. 1, p. 89–100, 2007. Citado 2 vezes nas páginas [21](#) e [24](#).
- XIA, F.; COLE, C.; WOLFS, P. An inverse railway wagon model and its applications. *Vehicle system dynamics*, Taylor & Francis, v. 45, n. 6, p. 583–605, 2007. Citado na página [27](#).
- XIA, F.; COLE, C.; WOLFS, P. Grey box-based inverse wagon model to predict wheel–rail contact forces from measured wagon body responses. *Vehicle System Dynamics*, Taylor & Francis, v. 46, n. S1, p. 469–479, 2008. Citado na página [21](#).
- XIA, H.; ZHANG, N.; GUO, W. Dynamic interaction of train-bridge systems in high-speed railways. Springer, 2018. Citado na página [35](#).
- XIN, T.; WANG, P.; DING, Y. Effect of long-wavelength track irregularities on vehicle dynamic responses. *Shock and Vibration*, Hindawi, v. 2019, 2019. Citado na página [35](#).
- YEO, G. J. *Monitoring railway track condition using inertial sensors on an in-service vehicle*. Tese (Doutorado) — University of Birmingham, 2017. Citado 2 vezes nas páginas [21](#) e [25](#).
- Zenko, B.; Todorovski, L.; Dzeroski, S. A comparison of stacking with meta decision trees to bagging, boosting, and stacking with other methods. In: *Proceedings 2001 IEEE International Conference on Data Mining*. [S.l.: s.n.], 2001. p. 669–670. Citado 2 vezes nas páginas [59](#) e [64](#).
- ZHAI, W. *Vehicle-track coupled dynamics*. [S.l.]: Springer, 2015. Citado 6 vezes nas páginas [6](#), [8](#), [31](#), [32](#), [34](#) e [35](#).

8 Apêndice

8.1 Apêndice A

		Correlações Lineares																				
		z_r1_esq_real	z_r1_dir_real	z_r2_esq	z_r2_dir	y_r1_esq	y_r2_esq	y_r1_dir	y_r2_dir	y_eixo_r1_esq	y_eixo_r1_dir	y_eixo_r2_esq	y_eixo_r2_dir	triaxial-y	triaxial-z	roll	pitch	s1_mola1	s1_mola2	s2_mola1	s2_mola2	
z_r1_dir_real	-0.043																					
z_r2_esq	0.32	0.028																				
z_r2_dir	-0.053	0.37	-0.049																			
y_r1_esq	-0.01	0.0054	0.011	-0.012																		
y_r2_esq	-0.0043	-0.025	-0.0098	0.022	0.72																	
y_r1_dir	-0.027	0.019	0.0069	-0.0079	0.59	0.57																
y_r2_dir	0.0082	0.0082	-0.02	0.011	0.57	0.56	0.72															
y_eixo_r1_esq	-0.0039	-2.2e-05	0.00019	-0.015	0.77	0.73	0.78	0.73														
y_eixo_r1_dir	0.16	-0.014	-0.031	0.0055	-0.73	-0.7	-0.75	-0.7	-0.91													
y_eixo_r2_esq	-0.0038	8e-05	0.00034	-0.015	0.77	0.73	0.76	0.73	1	-0.91												
y_eixo_r2_dir	-0.035	0.066	-0.0051	0.03	0.76	0.73	0.77	0.73	0.96	-0.94	0.96											
y_eixo_r2_esq	0.0051	-0.021	0.022	0.0062	0.75	0.75	0.77	0.75	0.96	-0.91	0.96	0.95										
y_eixo_r2_dir	-0.023	0.01	0.039	0.0016	-0.74	-0.74	-0.75	-0.74	-0.95	0.9	0.95	-0.94	-0.94									
y_eixo_r2_dir	0.0052	-0.021	-0.022	0.0063	0.75	0.75	0.77	0.75	0.96	-0.91	0.96	0.95	1	-0.94								
z_eixo_r2_dir	0.0023	-0.035	-0.012	0.02	0.63	0.63	0.64	0.64	0.81	-0.77	0.81	0.8	0.77	-0.9	0.77							
triaxial-y	0.0005	0.014	0.0047	-0.011	0.75	0.74	0.76	0.74	0.96	-0.92	0.96	0.95	0.97	-0.95	0.97	0.81						
triaxial-z	0.011	0.0091	0.062	-0.0055	-0.012	-0.033	-0.015	-0.032	-0.019	0.027	-0.018	-0.033	-0.039	0.052	-0.038	-0.03	-0.057					
roll	0.0016	0.012	0.0055	0.01	-0.76	-0.75	-0.77	-0.75	-0.97	0.93	-0.97	-0.97	-0.97	0.96	-0.97	-0.82	-0.98	0.029				
pitch	-0.018	-0.0096	-0.02	-0.01	0.14	0.14	0.15	0.14	0.18	-0.17	0.18	0.18	0.18	-0.19	0.18	0.16	0.19	-0.086	-0.16			
s1_mola1	0.018	-0.019	0.013	0.03	0.42	0.42	0.43	0.42	0.55	-0.52	0.55	0.54	0.56	-0.55	0.56	0.46	0.58	-0.18	-0.56	0.11		
s1_mola2	0.017	0.022	-0.019	0.0034	-0.41	-0.41	-0.42	-0.41	-0.53	0.5	-0.53	-0.52	-0.54	0.52	-0.54	-0.46	-0.57	0.097	0.54	0.061	0.95	
s2_mola1	-0.018	0.008	-0.037	0.022	0.42	0.42	0.43	0.43	0.53	-0.52	0.53	0.54	0.55	-0.55	0.55	0.46	0.58	-0.21	-0.54	0.13	-0.17	0.22
s2_mola2	0.018	0.007	0.026	0.03	-0.42	-0.42	-0.42	-0.43	-0.53	0.51	-0.53	-0.53	-0.54	0.53	-0.54	-0.46	-0.57	0.02	0.53	-0.12	0.2	0.94

Figura 44 – Correlações Lineares

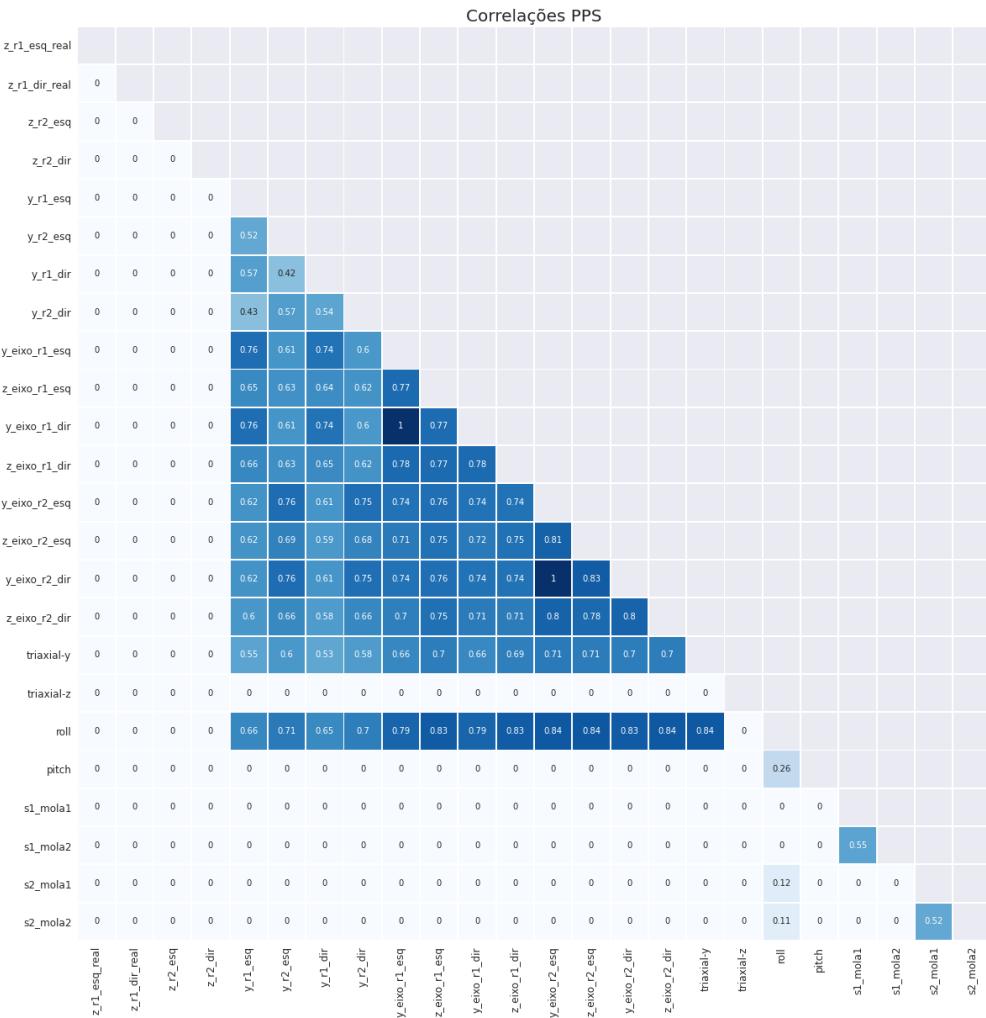


Figura 45 – Correlações PPS

8.2 Apêndice B

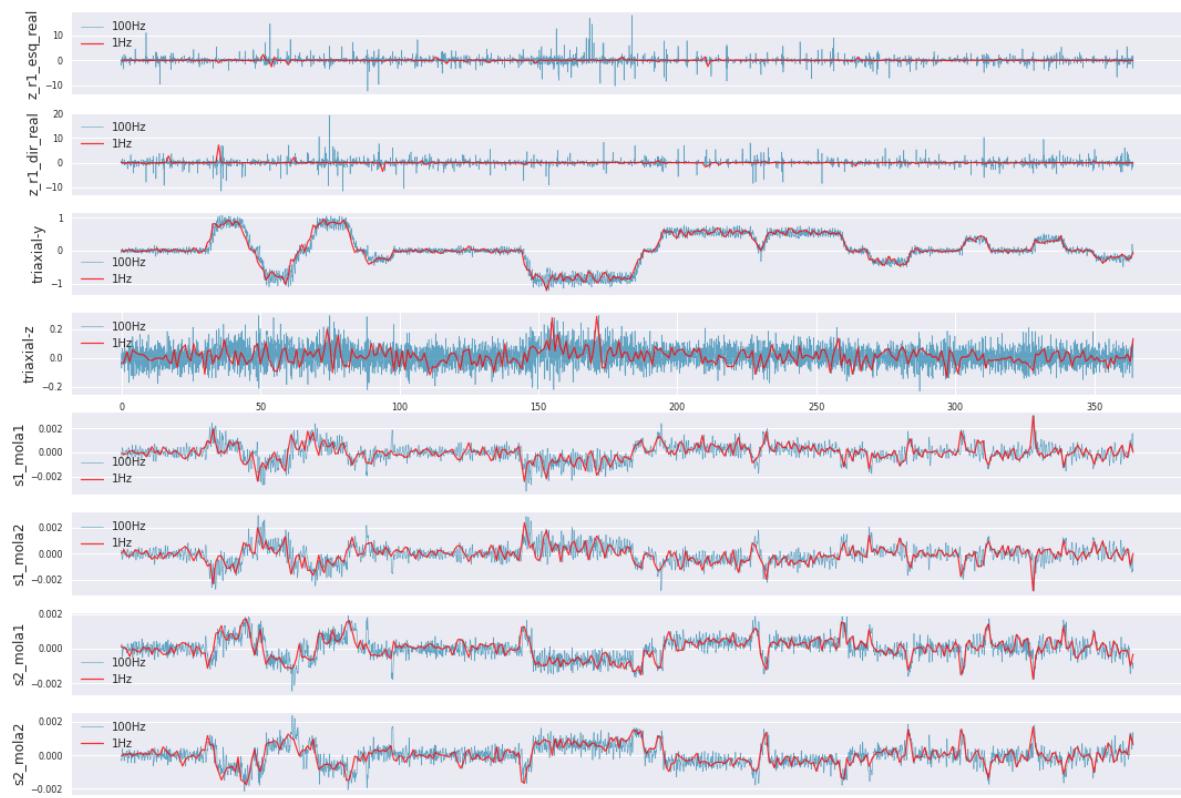


Figura 46 – Lineplots Reais

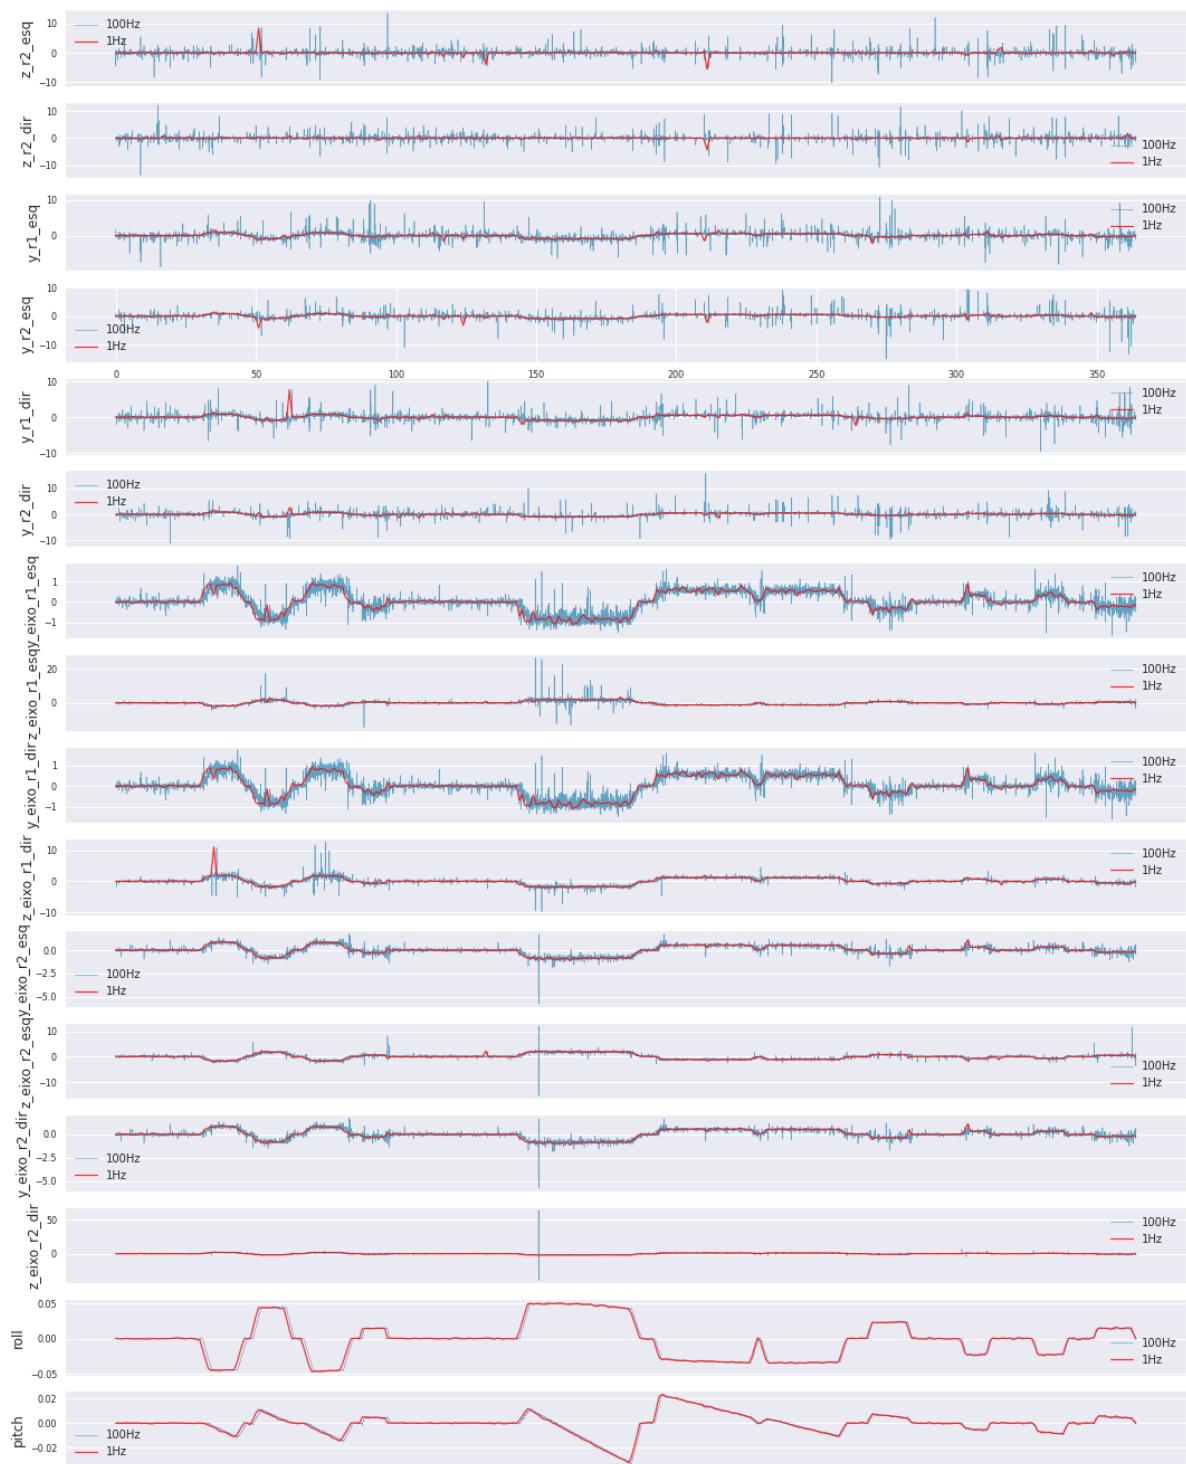


Figura 47 – Lineplots Virtuais

8.3 Apêndice C

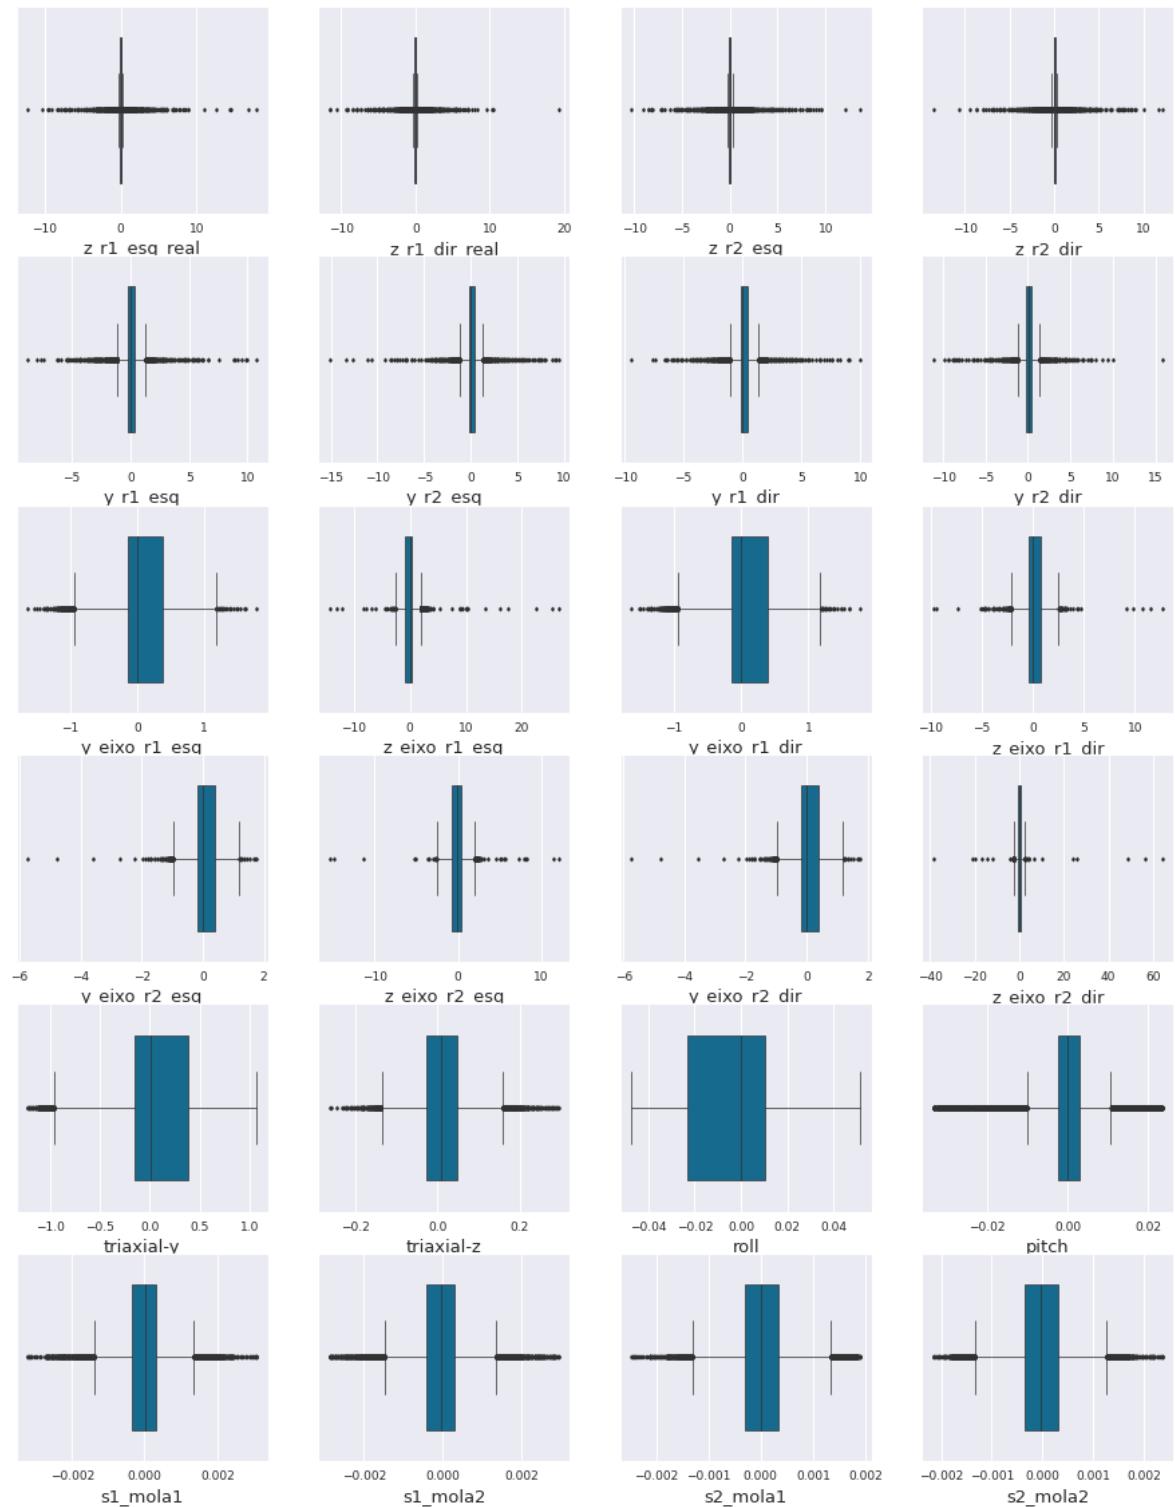


Figura 48 – Boxplot

8.4 Apêndice D

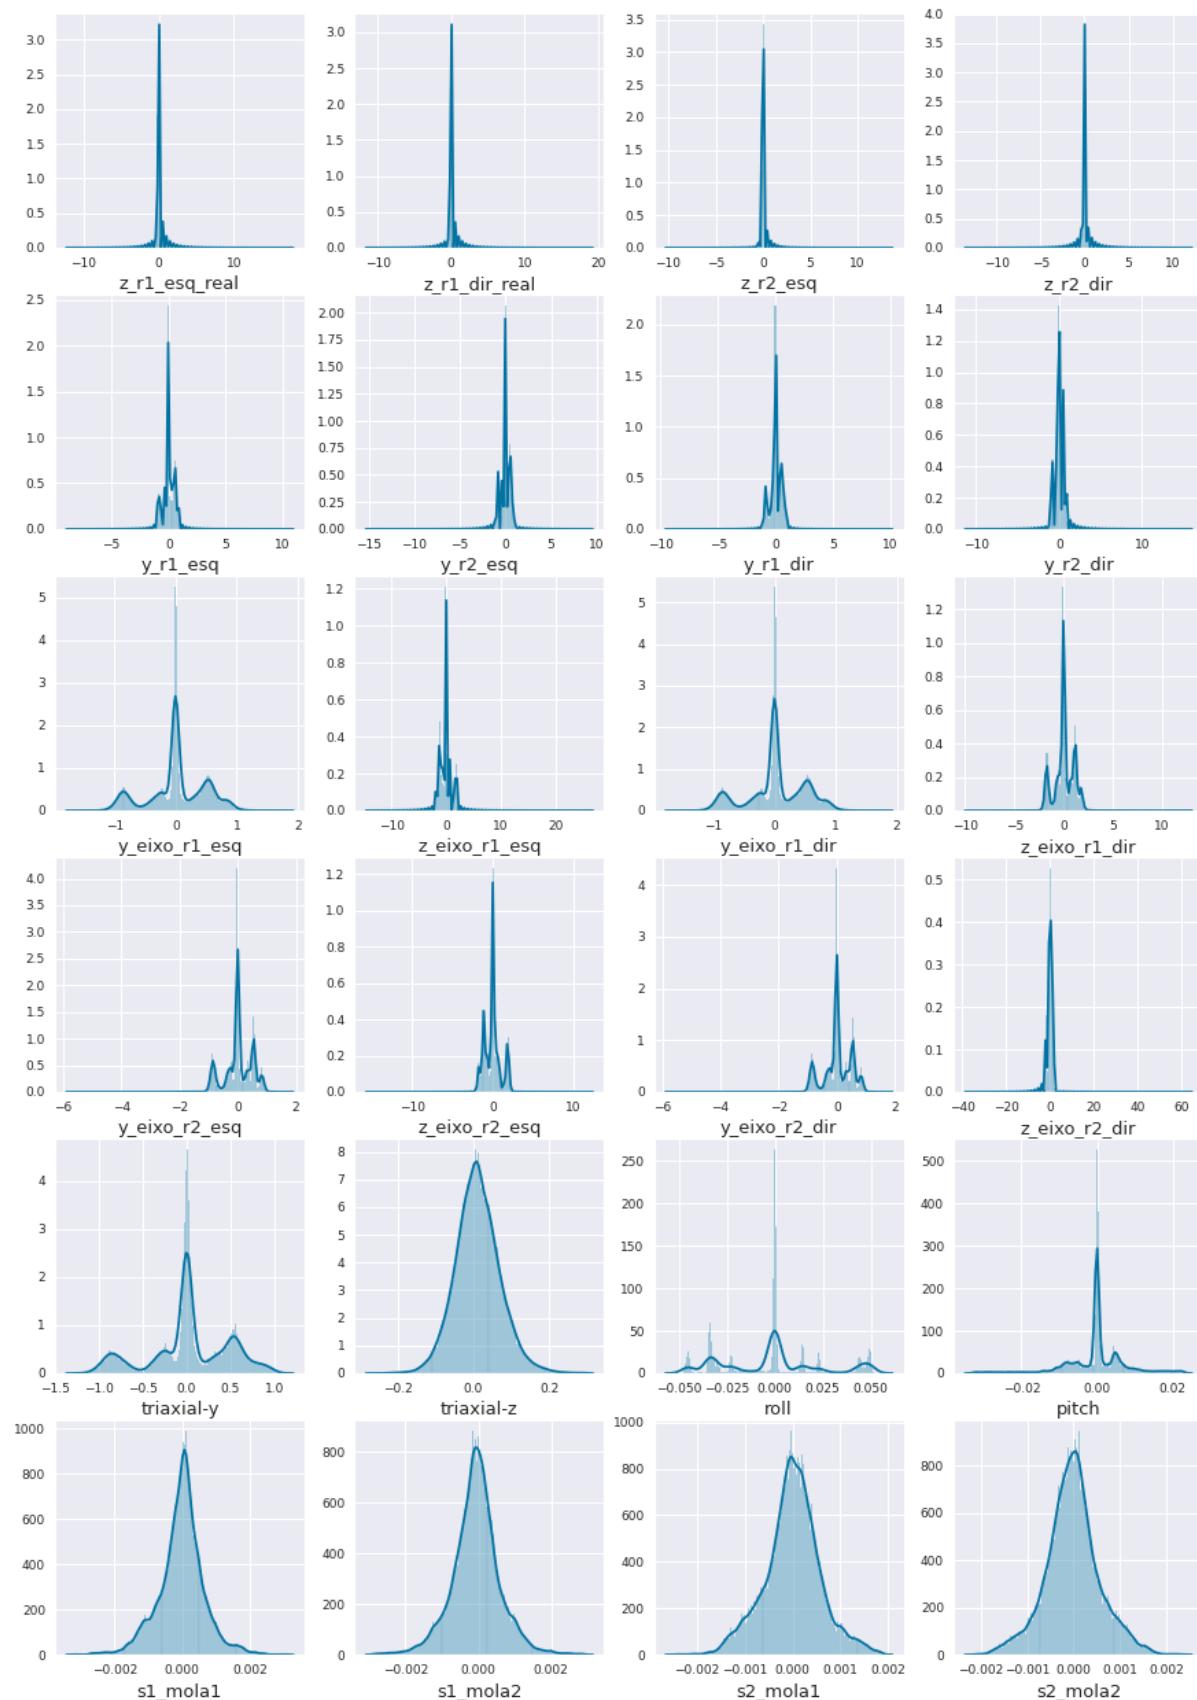


Figura 49 – Histograma

8.5 Apêndice E

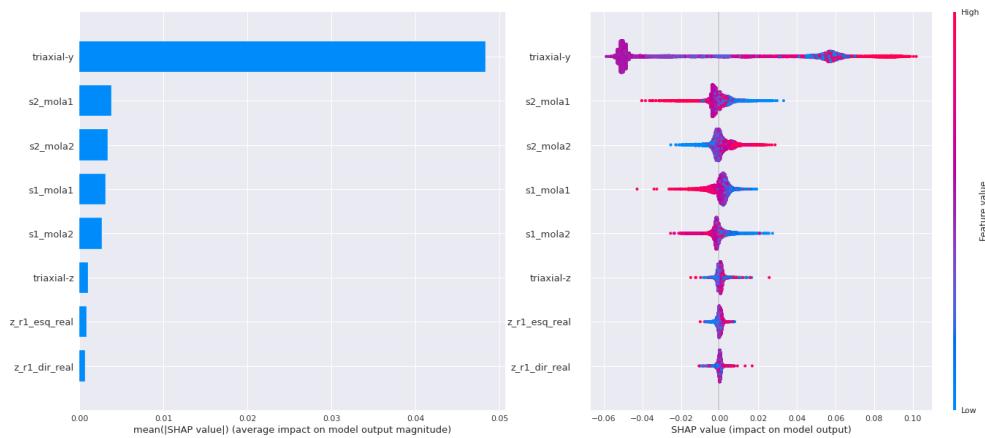


Figura 50 – SHAP Real Rodeiro 1 Esquerdo

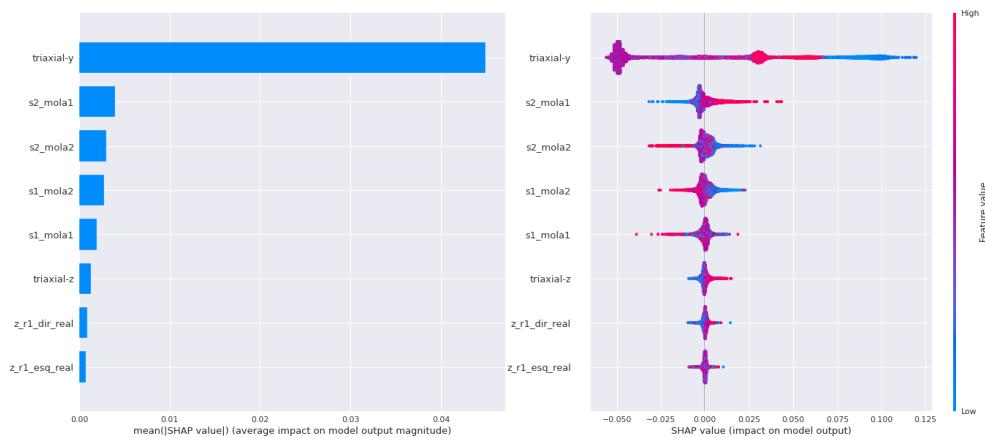


Figura 51 – SHAP Real Rodeiro 1 Direito

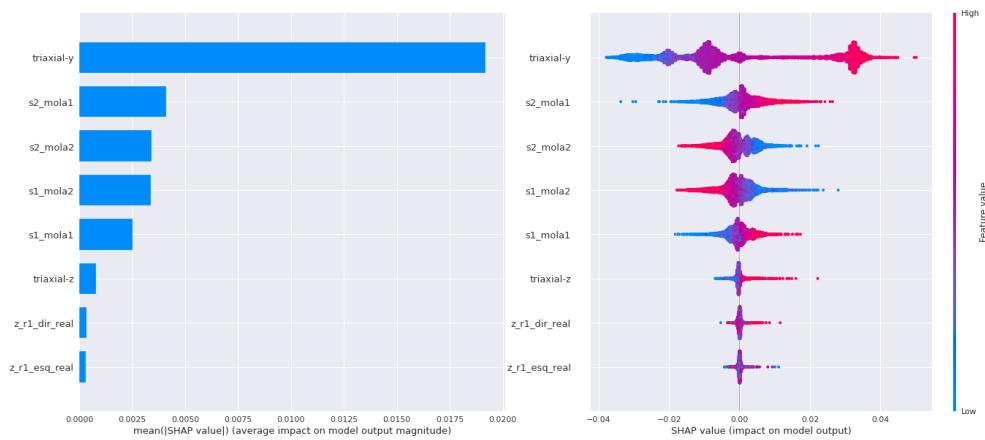


Figura 52 – SHAP Real Rodeiro 2 Esquerdo

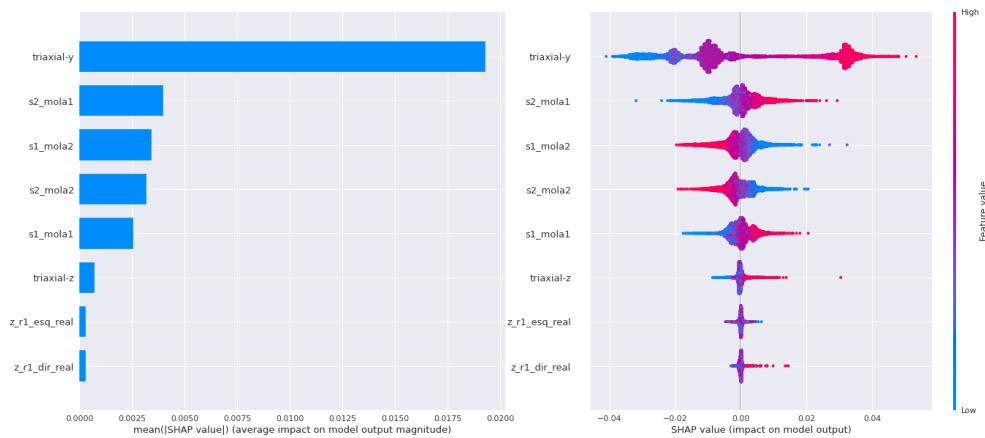


Figura 53 – SHAP Real Rodeiro 2 Direito

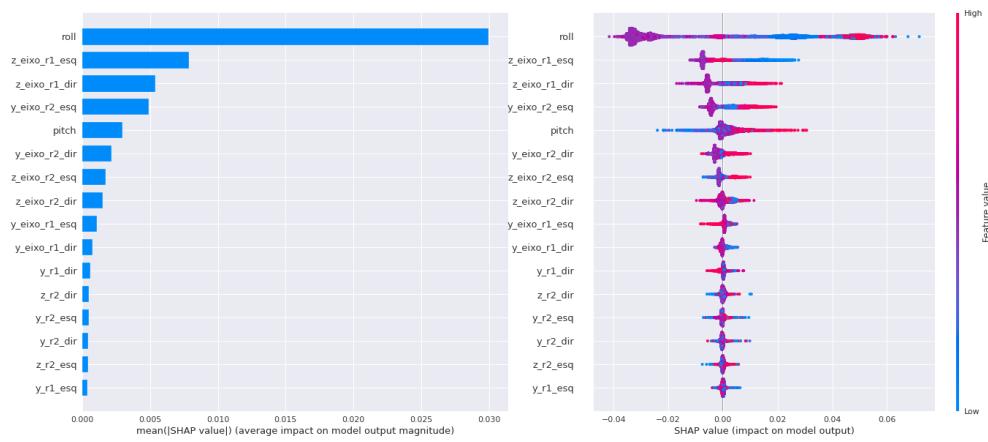


Figura 54 – SHAP Virtual Rodeiro 1 Esquierdo

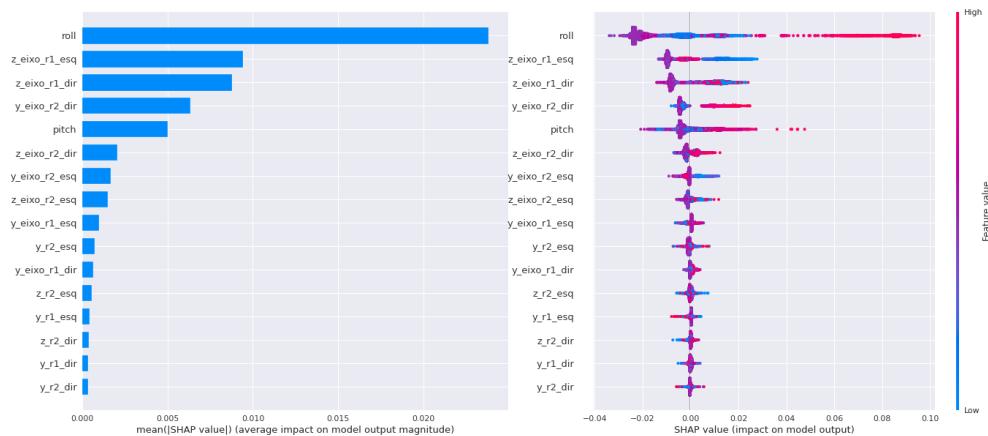


Figura 55 – SHAP Virtual Rodeiro 1 Direito

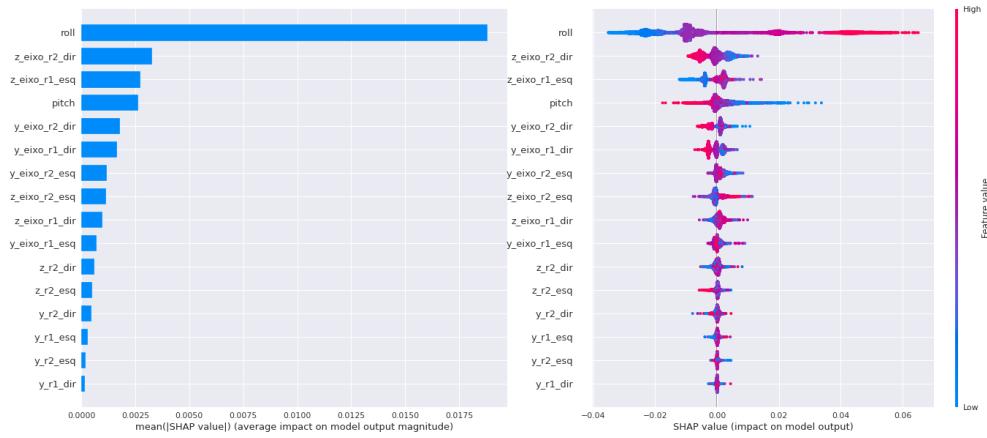


Figura 56 – SHAP Virtual Rodeiro 2 Esquerdo

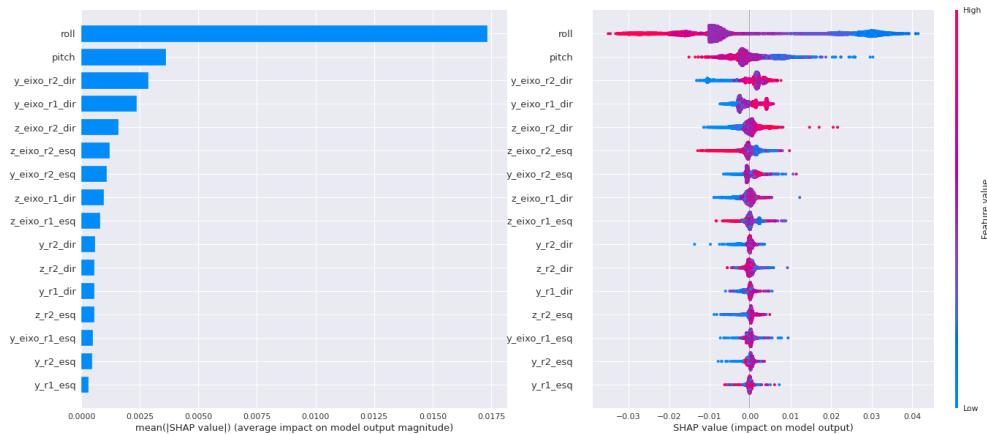


Figura 57 – SHAP Virtual Rodeiro 2 Direito

8.6 Apêndice F

Tabela 19 – Modelos - Nadal Rodeiro 2 Esquerdo

nadal_1_dir_real	make_pipeline(StackingEstimator(estimator=RandomForestRegressor(bootstrap=False, max_features=0.8, min_samples_leaf=2, min_samples_split=6, n_estimators=100)), XGBRegressor(learning_rate=0.1, max_depth=6, min_child_weight=15, n_estimators=100, nthread=1, objective='reg:squarederror', subsample=0.3500000000000003))
nadal_1_dir_real_1	make_pipeline(make_union(FunctionTransformer(copy), FunctionTransformer(copy)) ExtraTreesRegressor(bootstrap=False, max_features=0.9500000000000001, min_samples_leaf=3, min_samples_split=3, n_estimators=100))
nadal_1_dir_real_100_no	RandomForestRegressor(bootstrap=False, max_features=0.7000000000000001, min_samples_leaf=2, min_samples_split=4, n_estimators=100)
nadal_1_dir_tudo	make_pipeline(StackingEstimator(estimator=RandomForestRegressor(bootstrap=True, max_features=0.8, min_samples_leaf=2, min_samples_split=16, n_estimators=100)), XGBRegressor(learning_rate=0.5, max_depth=4, min_child_weight=3, n_estimators=100, nthread=1, objective='reg:squarederror', subsample=0.45))
nadal_1_dir_tudo_1	make_pipeline(MinMaxScaler(), KNeighborsRegressor(n_neighbors=7, p=1, weights='distance'))
nadal_1_dir_tudo_100_no	make_pipeline(RobustScaler(), SelectFwe(score_func=f_regression, alpha=0.015), RandomForestRegressor(bootstrap=False, max_features=0.6500000000000001, min_samples_leaf=4, min_samples_split=5, n_estimators=100))
nadal_1_esq_real	make_pipeline(StackingEstimator(estimator=ExtraTreesRegressor(bootstrap=False, max_features=1.0, min_samples_leaf=3, min_samples_split=2, n_estimators=100)), XGBRegressor(learning_rate=0.1, max_depth=7, min_child_weight=17, n_estimators=100, nthread=1, objective='reg:squarederror', subsample=0.2))
nadal_1_esq_real_1	RandomForestRegressor(bootstrap=True, max_features=0.8500000000000001, min_samples_leaf=1, min_samples_split=5, n_estimators=100)
nadal_1_esq_real_100_no	make_pipeline(make_union(StackingEstimator(estimator=ExtraTreesRegressor(bootstrap=False, max_features=0.5, min_samples_leaf=9, min_samples_split=15, n_estimators=100)), FunctionTransformer(copy)) StackingEstimator(estimator=ExtraTreesRegressor(bootstrap=True, max_features=0.6500000000000001, min_samples_leaf=5, min_samples_split=8, n_estimators=100)), RandomForestRegressor(bootstrap=False, max_features=0.3, min_samples_leaf=3, min_samples_split=14, n_estimators=100))
nadal_1_esq_tudo	make_pipeline(StackingEstimator(estimator=SGDRegressor(alpha=0.01, eta0=0.01, fit_intercept=True, l1_ratio=0.25, learning_rate='invscaling', loss='squared_loss', penalty='elasticnet', power_t=0.1)), StackingEstimator(estimator=ExtraTreesRegressor(bootstrap=False, max_features=0.8, min_samples_leaf=5, min_samples_split=17, n_estimators=100)), RandomForestRegressor(bootstrap=True, max_features=0.7500000000000001, min_samples_leaf=11, min_samples_split=13, n_estimators=100))
nadal_1_esq_tudo_1	make_pipeline(StackingEstimator(estimator=LassoLarsCV(normalize=True)), XGBRegressor(learning_rate=0.1, max_depth=7, min_child_weight=4, n_estimators=100, nthread=1, objective='reg:squarederror', subsample=0.55))
nadal_1_esq_tudo_100_no	make_pipeline(StackingEstimator(estimator=AdaBoostRegressor(learning_rate=0.1, loss='linear', n_estimators=100)), PolynomialFeatures(degree=2, include_bias=False, interaction_only=False), GradientBoostingRegressor(alpha=0.99, learning_rate=0.1, loss='ls', max_depth=10, max_features=0.45, min_samples_leaf=1, min_samples_split=4, n_estimators=100, subsample=0.9500000000000001))
nadal_2_dir_real	make_pipeline(StandardScaler(), StackingEstimator(estimator=LassoLarsCV(normalize=True)), RandomForestRegressor(bootstrap=False, max_features=0.45, min_samples_leaf=2, min_samples_split=4, n_estimators=100))
nadal_2_dir_real_1	make_pipeline(StackingEstimator(estimator=LassoLarsCV(normalize=True)), RandomForestRegressor(bootstrap=False, max_features=0.3, min_samples_leaf=3, min_samples_split=14, n_estimators=100))
nadal_2_dir_real_100_no	RandomForestRegressor(bootstrap=False, max_features=0.8500000000000001, min_samples_leaf=1, min_samples_split=5, n_estimators=100)
nadal_2_dir_tudo	ExtraTreesRegressor(bootstrap=False, max_features=0.7500000000000001, min_samples_leaf=2, min_samples_split=6, n_estimators=100)
nadal_2_dir_tudo_1	make_pipeline(make_union(FunctionTransformer(copy), FunctionTransformer(copy)) GradientBoostingRegressor(alpha=0.99, learning_rate=0.1, loss='ls', max_depth=2, max_features=0.7000000000000001, min_samples_leaf=1, min_samples_split=4, n_estimators=100, subsample=0.8))
nadal_2_dir_tudo_100_no	make_pipeline(SelectPercentile(score_func=f_regression, percentile=81), PolynomialFeatures(degree=2, include_bias=False, interaction_only=False), ExtraTreesRegressor(bootstrap=False, max_features=0.9000000000000001, min_samples_leaf=2, min_samples_split=8, n_estimators=100))
nadal_2_esq_real	make_pipeline(PolynomialFeatures(degree=2, include_bias=False, interaction_only=False), StackingEstimator(estimator=ExtraTreesRegressor(bootstrap=False, max_features=0.6500000000000001, min_samples_leaf=2, min_samples_split=15, n_estimators=100)), RandomForestRegressor(bootstrap=False, max_features=0.3, min_samples_leaf=10, min_samples_split=14, n_estimators=100))
nadal_2_esq_real_1	make_pipeline(StackingEstimator(estimator=LassoLarsCV(normalize=False)), ExtraTreesRegressor(bootstrap=False, max_features=0.6500000000000001, min_samples_leaf=3, min_samples_split=13, n_estimators=100))
nadal_2_esq_real_100_no	make_pipeline(RobustScaler(), RandomForestRegressor(bootstrap=False, max_features=0.45, min_samples_leaf=2, min_samples_split=2, n_estimators=100))
nadal_2_esq_tudo	RandomForestRegressor(bootstrap=False, max_features=0.6500000000000001, min_samples_leaf=4, min_samples_split=5, n_estimators=100)
nadal_2_esq_tudo_1	make_pipeline(SelectFwe(score_func=f_regression, alpha=0.015), RandomForestRegressor(bootstrap=False, max_features=0.6500000000000001, min_samples_leaf=13, min_samples_split=15, n_estimators=100))
nadal_2_esq_tudo_100_no	make_pipeline(MaxAbsScaler(), StackingEstimator(estimator=LinearSVR(C=0.0001, dual=True, epsilon=0.01, loss='epsilon_insensitive', tol=0.01)), RandomForestRegressor(bootstrap=False, max_features=0.45, min_samples_leaf=1, min_samples_split=2, n_estimators=100))

8.7 Apêndice G

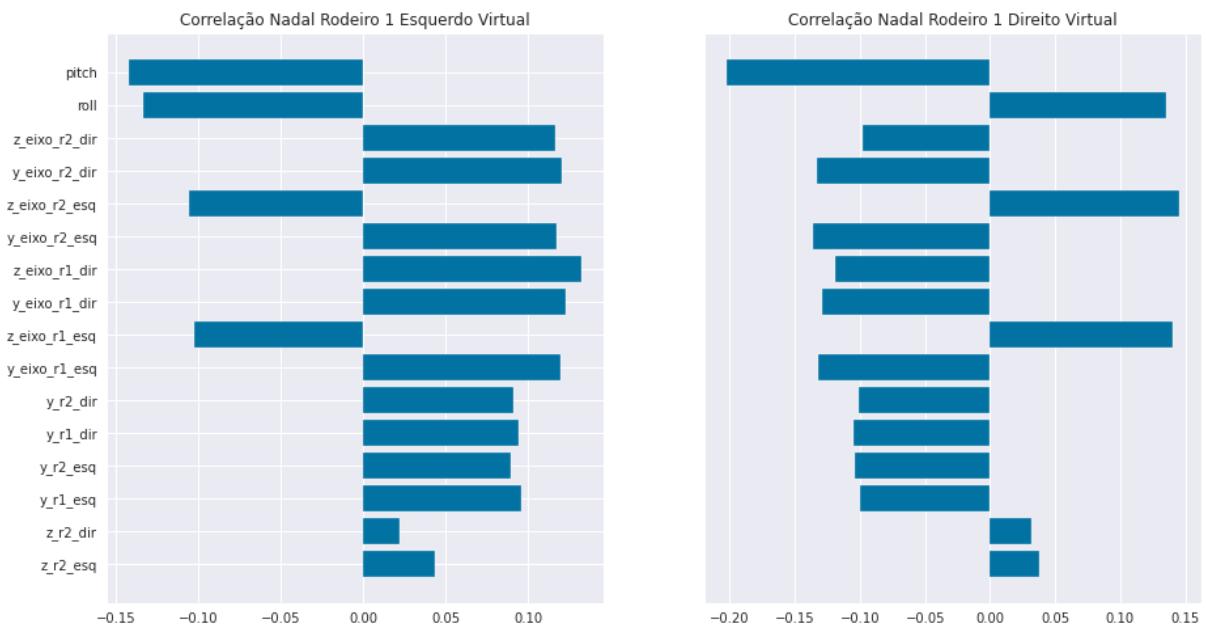


Figura 58 – Correlação Nadal Rodeiro 1 Virtual

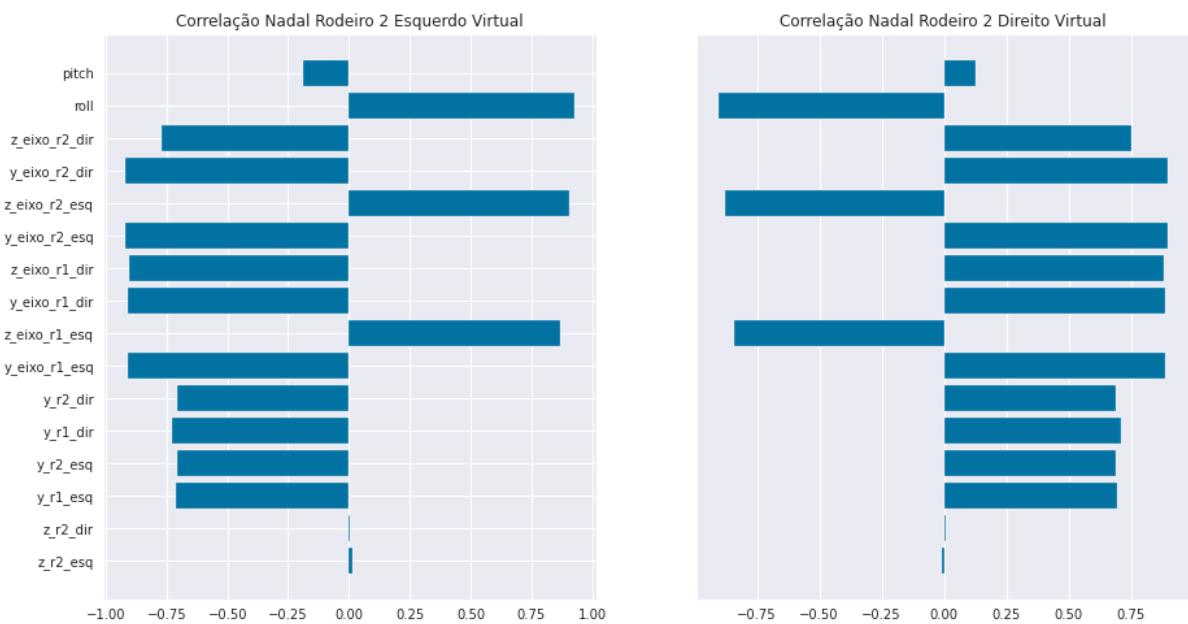


Figura 59 – Correlação Nadal Rodeiro 2 Virtual

8.8 Apêndice H

Classificação	Rodeiro 1 Esquerdo	Rodeiro 1 Direito	Rodeiro 2 Direito	Rodeiro 2 Esquerdo
1	triaxial-z	triaxial-z	triaxial-y	triaxial-y
2	s1_mola2	pitch	roll	roll
3	pitch	s1_mola1	y_eixo_r2_dir	y_eixo_r2_esq
4	roll	z_eixo_r2_esq	y_eixo_r2_esq	y_eixo_r2_dir
5	z_eixo_r1_dir	z_eixo_r1_esq	y_eixo_r1_dir	y_eixo_r1_esq
6	y_eixo_r1_dir	y_eixo_r2_esq	y_eixo_r1_esq	y_eixo_r1_dir
7	y_eixo_r2_dir	roll	z_eixo_r1_dir	z_eixo_r2_esq
8	y_eixo_r1_esq	triaxial-y	z_eixo_r2_esq	z_eixo_r1_dir
9	y_eixo_r2_esq	y_eixo_r2_dir	z_eixo_r1_esq	z_eixo_r1_esq
10	y_eixo_r2_dir	y_eixo_r2_esq	z_eixo_r2_dir	z_eixo_r2_dir

Tabela 20 – Ranking das variáveis selecionadas com SelectKBest utilizando sensores reais e virtuais